

Tema 1: Introducción al aprendizaje automático

Proceso de generación de un modelo

El proceso de generación de un modelo se puede resumir en:

1. Definición del conjunto de datos
2. Preprocesamiento
3. Separación de conjunto de datos
4. Entrenamiento
5. Validación y ajuste de hiperparámetros
6. Puesta en producción

Definición del conjunto de datos

- Identificación de la variable respuesta

Preprocesado

- Revisión de valores faltantes
- Codificación de variables categóricas
- Escalado (si fuera necesario)

Separación de conjuntos de datos

Se separan los datos entre entrenamiento y validación, siguiendo la norma 80-20%.

Entrenamiento

Se entrena la muestra.

Validación

Métodos de validación:

- Validación cruzada (CV)
 - Validación cruzada de k pliegos (k-fold)

Ver también métricas usadas.

Puesta en producción

Explotación del modelo.

Métricas usadas

- Clasificación
 - Basadas en matriz de confusión
 - * Exactitud/*accuracy*
 - * Precisión/*Precision*
 - * Sensibilidad/*Recall*
 - * F1
 - * Especificidad/*Specificity*
 - Basadas en probabilidades
 - * ROC
 - * AUC-ROC
 - * Log-loss (cross-entropy)
- Regresión
 - Basadas en error
 - * Mean Absolute Error (MAE)
 - * Mean Squared Error (MSE)
 - * RMSE
 - * Median Absolute Error
 - Basadas en varianza explicada
 - * R^2
 - * Adjusted R^2

Métricas de clasificación

Exactitud o *accuracy* es la proporción de predicciones correctas.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

Precisión o *precision* predice como positivo, cuántos son correctos.

$$Precision = \frac{TP}{TP+FP}$$

Se usa cuando los falsos positivos son costosos.

La sensibilidad o *recall* indica de los positivos reales cuántos detecta el modelo:

$$Recall = \frac{TP}{TP+FN}$$

Se usa cuando los falsos negativos son costosos.

La puntuación F1 o *F1 score* es la media armónica entre precision y recall. Se usa cuando las clases están muy desbalanceadas.

$$F1 = 2 \frac{Precision \cdot Recall}{Precision + Recall}$$

Es la medida armónica entre precision y recall.

AUC-ROC se usa en clasificación binaria. Un clasificador perfecto tiene valor 1, uno igual al azar (inservible) vale 0.5 y menor acertaría menos que el azar.