

AAII - Tema 0: Modelos múltiples

Este tema presenta una definición y taxonomía de modelos múltiples, que son vistos en más detalle en los temas 1-3 de la asignatura.

A modo de adaptación, se comienza con otros temas de repaso que sirven de base y convención para la asignatura.

Este tema 0 solo existe en la parte práctica de la asignatura. Los apartados se corresponden con el orden en que se muestran los vídeos de la asignatura.

Introducción a los algoritmos ensembles

Bibliografía:

- Básica
 - [FAE]
 - Vídeo “Teoría - Introducción a los algoritmos ensembles” de la asignatura.

El *modelado múltiple* (en inglés, *multi-model approach*) se refiere a cualquier técnica que emplea varios modelos de aprendizaje.

Un *modelo múltiple* o *multi-modelo* (en inglés, *multiple model*) es aquel que emplea modelado múltiple, es decir, que utiliza varios modelos de aprendizaje.

El *aprendizaje conjunto* (en inglés, *ensemble learning*) es un grupo de técnicas dentro del modelado múltiple que se caracteriza por combinar varios modelos a nivel matemático.

Un *ensemble* (en inglés, *ensemble model*) es un modelo basado en aprendizaje conjunto, es decir, un modelo que combina varios otros.

Taxonomía de modelos múltiples (vistos en la asignatura):

- Mezcla de expertos
- Ensembles
 - Bosques aleatorios
 - Bagging
 - Intensificación / *Boosting*
 - * AdaBoost
 - * XGBoost
 - * GBM
 - * LightGBM
 - Apilamiento / *Stacking*
 - Blending
 - Super Learner
 - Votación / *Voting*

Fases de un proyecto de aprendizaje automático completo, de acuerdo a la asignatura (aunque falta la referencia a dónde se explica exactamente):

1. Fase de análisis de datos
2. Fase de preprocesamiento de datos
3. Fase de modelado.
4. Fase de optimización.
5. Explicabilidad e interpretabilidad

De la Mezcla de expertos a los algoritmos ensembles

Bibliografía:

- Básica
 - Vídeo “Teoría -De la Mezcla de expertos a los algoritmos ensembles” de la asignatura.

Mezcla de expertos (en inglés, *mixture of experts*) combina varios modelos especializados, llamados expertos, junto con un mecanismo que decide cuánto debe influir cada uno en cada predicción. La idea general conecta con los métodos **ensemble**: en lugar de confiar en un único modelo, se aprovecha la combinación de varios modelos que pueden resolver mejor distintas partes del problema. La diferencia es que, en una mezcla de expertos, la combinación suele depender del ejemplo concreto.

One-vs-Rest y One-vs-One

Bibliografía:

- Básica
 - Vídeos “1. One-vs-Rest y One-vs-One” de la asignatura.

One-vs-Rest (OvR) y **One-vs-One (OvO)** son estrategias para resolver problemas multiclase utilizando clasificadores binarios. En **OvR** se entrena un clasificador por clase, distinguiendo esa clase frente al resto. En **OvO** se entrena un clasificador para cada pareja de clases y la decisión final se obtiene combinando sus resultados. **OvR** requiere menos modelos; **OvO** entrena más clasificadores, pero cada uno resuelve un problema más reducido.

Códigos de salida con corrección de errores

Bibliografía:

- Básica
 - Vídeo “2. Códigos de salida con corrección de errores” de la asignatura.

Los **códigos de salida con corrección de errores** (Error-Correcting Output Codes, ECOC) representan cada clase mediante un código binario y entrenan varios clasificadores binarios, uno por cada posición del código. Para predecir, se obtiene el código producido por los clasificadores y se asigna la clase cuyo código sea más próximo. La redundancia de los códigos puede permitir corregir algunos errores cometidos por clasificadores individuales.

Modelos de regresión de múltiples salidas

Bibliografía:

- Básica
 - Vídeo “3. Modelos de regresión de múltiples salidas” de la asignatura.

Los **modelos de regresión de múltiples salidas** predicen simultáneamente varias variables objetivo continuas para una misma observación. Por ejemplo, a partir de las características de una vivienda podrían predecirse a la vez su precio, consumo energético y coste de mantenimiento. Estos modelos pueden aprovechar relaciones entre las salidas, en lugar de entrenar una regresión completamente independiente para cada una.

4. Selección de clasificador dinámico

Bibliografía:

- Básica
 - Vídeo “4. Selección de clasificador dinámico” de la asignatura.

La **selección de clasificador dinámico** (Dynamic Classifier Selection, DCS) dispone de varios clasificadores entrenados, pero no utiliza siempre el mismo ni combina todos. Para cada nueva observación, estima qué clasificador parece más competente en su región del espacio de datos y utiliza únicamente ese modelo para producir la predicción final.

5. Selección dinámica de conjuntos

Bibliografía:

- Básica
 - Vídeo “5. Selección dinámica de conjuntos” de la asignatura.

La **selección dinámica de conjuntos** (Dynamic Ensemble Selection, DES) extiende la idea anterior: para cada observación nueva no selecciona un único clasificador, sino un subconjunto de modelos considerados competentes. Las predicciones de esos modelos se combinan para obtener la salida final. Así,

distintos ejemplos pueden ser resueltos por distintos ensembles según la zona del problema en la que se encuentren.

Cálculo de error de un modelo)

EXAM=(2021J2.11)

Calcular el error de un modelo sirve para dos objetivos relacionados:

- **evaluación de modelos:** estimar el rendimiento esperado del modelo;
- **selección de modelos:** comparar alternativas y elegir la más adecuada.

Por tanto, el error no solo mide cómo funciona un modelo, sino que también ayuda a decidir entre modelos, hiperparámetros o configuraciones.

Bibliografía

- Básica
 - [FAE] CASTILLO-LARA, Manuel, SARRO, Luis. Fundamentos de algoritmos Ensemble. UNED.

Licencia y atribución

License CC BY 4.0

Este trabajo está licenciado bajo la licencia **Creative Commons Atribución 4.0 Internacional**.

© 2026, Colaboradores de apuntes-muicd-uned.