

AAII - Tema 0: Modelos múltiples

Este tema presenta una definición y taxonomía de modelos múltiples, que son vistos en más detalle en los temas 1-3 de la asignatura.

A modo de adaptación, se comienza con otros temas de repaso que sirven de base y convención para la asignatura.

Fases de aprendizaje automático

Fases de un proyecto de aprendizaje automático completo, de acuerdo a la asignatura:

1. Fase de análisis de datos
2. Fase de preprocesamiento de datos
3. Fase de modelado.
4. Fase de optimización.
5. Explicabilidad e interpretabilidad

Introducción a los algoritmos ensembles

El *modelado múltiple* (en inglés, *multi-model approach*) se refiere a cualquier técnica que emplea varios modelos de aprendizaje.

Un *modelo múltiple* o *multi-modelo* (en inglés, *multiple model*) es aquel que emplea modelado múltiple, es decir, que utiliza varios modelos de aprendizaje.

El *aprendizaje conjunto* (en inglés, *ensemble learning*) es un grupo de técnicas dentro del modelado múltiple que se caracteriza por combinar varios modelos a nivel matemático.

Un *ensamble* (en inglés, *ensemble model*) es un modelo basado en aprendizaje conjunto, es decir, un modelo que combina varios otros.

Taxonomía de modelos múltiples (vistos en la asignatura):

- Mezcla de expertos
- Ensamblados
 - Bosques aleatorios
 - Bagging
 - Intensificación / *Boosting*
 - * AdaBoost
 - * XGBoost
 - * GBM
 - * LightGBM

- Apilamiento / *Stacking*
- Blending
- Super Learner
- Votación / *Voting*

De la Mezcla de expertos a los algoritmos ensembles

Mezcla de expertos (en inglés, *mixture of experts*) combina varios modelos especializados, llamados expertos, junto con un mecanismo que decide cuánto debe influir cada uno en cada predicción. La idea general conecta con los métodos **ensemble**: en lugar de confiar en un único modelo, se aprovecha la combinación de varios modelos que pueden resolver mejor distintas partes del problema. La diferencia es que, en una mezcla de expertos, la combinación suele depender del ejemplo concreto.

One-vs-Rest y One-vs-One

One-vs-Rest (OvR) y **One-vs-One (OvO)** son estrategias para resolver problemas multiclase utilizando clasificadores binarios. En **OvR** se entrena un clasificador por clase, distinguiendo esa clase frente al resto. En **OvO** se entrena un clasificador para cada pareja de clases y la decisión final se obtiene combinando sus resultados. **OvR** requiere menos modelos; **OvO** entrena más clasificadores, pero cada uno resuelve un problema más reducido.

Códigos de salida con corrección de errores

Los **códigos de salida con corrección de errores** (**Error-Correcting Output Codes**, **ECOC**) representan cada clase mediante un código binario y entrenan varios clasificadores binarios, uno por cada posición del código. Para predecir, se obtiene el código producido por los clasificadores y se asigna la clase cuyo código sea más próximo. La redundancia de los códigos puede permitir corregir algunos errores cometidos por clasificadores individuales.

Modelos de regresión de múltiples salidas

Los **modelos de regresión de múltiples salidas** predicen simultáneamente varias variables objetivo continuas para una misma observación. Por ejemplo, a partir de las características de una vivienda podrían predecirse a la vez su precio, consumo energético y coste de mantenimiento. Estos modelos pueden aprovechar relaciones entre las salidas, en lugar de entrenar una regresión completamente independiente para cada una.

4. Selección de clasificador dinámico

La **selección de clasificador dinámico** (Dynamic Classifier Selection, DCS) dispone de varios clasificadores entrenados, pero no utiliza siempre el mismo ni combina todos. Para cada nueva observación, estima qué clasificador parece más competente en su región del espacio de datos y utiliza únicamente ese modelo para producir la predicción final.

5. Selección dinámica de conjuntos

La **selección dinámica de conjuntos** (Dynamic Ensemble Selection, DES) extiende la idea anterior: para cada observación nueva no selecciona un único clasificador, sino un subconjunto de modelos considerados competentes. Las predicciones de esos modelos se combinan para obtener la salida final. Así, distintos ejemplos pueden ser resueltos por distintos ensembles según la zona del problema en la que se encuentren.

Licencia y atribución



Este trabajo está licenciado bajo la licencia **Creative Commons Atribución 4.0 Internacional**.

© 2026, Colaboradores de apuntes-muicd-uned.