

AAII - Tema 4: Aprendizaje no supervisado

En este tema se revisan técnicas de aprendizaje no supervisado.

4.1. Introducción al aprendizaje no supervisado

Bibliografía:

- Básica
 - [ESL] 14.1 “Introduction” Págs. 485-487
 - Presentación “ULAs” de la práctica de la asignatura
 - [ANS]

En el **aprendizaje no supervisado** (*unsupervised learning*) se dispone de observaciones descritas por variables de entrada, pero no existe una variable objetivo conocida ni etiquetas correctas que indiquen qué debe aprender el modelo.

Tipo de aprendizaje	Datos disponibles	Objetivo habitual
Supervisado	Variables de entrada X y respuesta conocida Y	Predecir Y a partir de X
No supervisado	Solo variables X	Descubrir estructura o patrones presentes en los datos

En aprendizaje supervisado puede pensarse que existe un “profesor”:

- el modelo produce una predicción;
- se conoce la respuesta correcta;
- puede medirse el error cometido mediante una función de pérdida.

En aprendizaje no supervisado se aprende **sin profesor**:

- no hay respuestas correctas para cada observación;
- no hay un error de predicción directamente observable;
- el objetivo es describir la estructura interna de los datos.

En términos generales, el aprendizaje no supervisado intenta inferir propiedades de la distribución de las variables observadas.

Dicho de forma práctica, busca responder preguntas como:

- ¿Existen grupos naturales de observaciones?
- ¿Hay variables que suelen comportarse conjuntamente?
- ¿Puede resumirse la información mediante menos dimensiones?
- ¿Existen patrones especialmente frecuentes en los datos?

ESL menciona, entre otras, las siguientes tareas no supervisadas:

Tarea	Idea
Componentes principales	Representar los datos mediante menos dimensiones
Reglas de asociación	Detectar valores o productos que aparecen conjuntamente con frecuencia
Análisis de grupos (<i>cluster analysis</i>)	Identificar regiones o grupos de observaciones similares
Modelos de mezclas	Representar los datos como mezcla de varios tipos de observaciones

En esta unidad, el interés principal estará en el **análisis de grupos o agrupamiento**.

El **agrupamiento** (*clustering*) intenta dividir las observaciones en grupos de forma que:

- las observaciones del mismo grupo sean parecidas entre sí;
- las observaciones de grupos distintos sean suficientemente diferentes.

Ejemplo:

Disponemos de información sobre clientes, como gasto medio, frecuencia de compra y tipos de producto adquiridos, pero no tenemos etiquetas de cliente. Un algoritmo de agrupamiento puede intentar descubrir perfiles diferenciados a partir de esas variables.

En aprendizaje supervisado existe una forma clara de medir el éxito:

- se comparan las predicciones con las respuestas reales;
- se calcula una pérdida o tasa de error;
- pueden compararse modelos mediante validación cruzada.

En aprendizaje no supervisado esto es más difícil:

- normalmente no existe una agrupación correcta conocida;
- no puede calcularse directamente un error de predicción respecto a una verdad observada;
- distintos algoritmos pueden descubrir estructuras distintas y razonables.

[ESL] destaca que la validez de las conclusiones obtenidas mediante algoritmos no supervisados es difícil de comprobar directamente. Por ello, la calidad de los resultados suele valorarse mediante criterios indirectos o heurísticos.

Un mismo conjunto de datos puede mostrar estructuras distintas según cómo se analice.

Por ejemplo, unos clientes podrían agruparse:

- por nivel de gasto;
- por frecuencia de compra;
- por preferencias de producto;
- por una combinación de esos criterios.

El resultado puede depender de:

- las variables utilizadas;
- la escala de esas variables;
- la medida de similitud o distancia;
- el algoritmo de agrupamiento;
- sus parámetros, como el número de grupos;
- la métrica utilizada para evaluar el resultado.

Por eso, en aprendizaje no supervisado no siempre existe una única solución “correcta”.

Dado que no suele existir una etiqueta real con la que comparar directamente las soluciones, no es recomendable seleccionar un modelo utilizando una única técnica o una única medida de evaluación.

La práctica recomendable es comparar los resultados obtenidos mediante diferentes algoritmos y diferentes métricas de evaluación, comprobando además si la estructura encontrada resulta interpretable y útil para el problema.

Al analizar una solución de agrupamiento conviene comprobar:

- si distintos algoritmos encuentran grupos parecidos;
- si el resultado es estable al cambiar parámetros;
- si distintas métricas favorecen la misma solución;
- si los grupos tienen sentido desde el punto de vista del problema estudiado.

No debe seleccionarse automáticamente el modelo:

- más rápido;
- que produzca el número de grupos esperado intuitivamente;
- que obtenga buen resultado en una única métrica;
- que se haya probado en primer lugar.

4.2. Análisis de grupos

Bibliografía:

- Básica
 - [ESL] 14.3 “Cluster Analysis”. Págs. 501-527

El objetivo del agrupamiento es dividir los datos de forma que exista:

- **alta similitud intra-cluster**: las observaciones del mismo grupo se parecen entre sí;
- **baja similitud inter-cluster**: las observaciones pertenecientes a grupos distintos son diferentes entre sí.

Por tanto:

La clasificación no supervisada o agrupamiento busca agrupar datos similares en las mismas clases y separar datos diferentes en clases distintas.

Ejemplo:

Si disponemos de datos sobre clientes, como frecuencia de compra, gasto medio y productos adquiridos, un método de agrupamiento puede intentar descubrir perfiles de clientes sin que previamente exista una etiqueta que indique a qué perfil pertenece cada uno.

El **objetivo principal** de la clasificación no supervisada es agrupar datos similares en las mismas clases y separar datos diferentes en clases distintas.

Aunque la pregunta utilice la expresión **clasificación no supervisada**, en este contexto se refiere a **agrupamiento**: las clases o grupos no están definidos antes de aplicar el algoritmo.

Todo método de clustering necesita alguna forma de decidir cuándo dos observaciones son parecidas o diferentes.

- Una **similitud** toma valores altos cuando dos observaciones se parecen mucho.
- Una **disimilitud** o distancia toma valores altos cuando dos observaciones son muy diferentes.

Un algoritmo de clustering no sabe por sí mismo qué significa que dos objetos sean parecidos: esa decisión depende de las variables elegidas, de la medida utilizada y del significado del problema.

Por ejemplo, para agrupar clientes podría ser importante:

- que tengan un gasto parecido;
- que compren productos similares;
- que visiten con frecuencia parecida;
- o alguna combinación de estos criterios.

En agrupamiento, definir adecuadamente la similitud o disimilitud puede ser tan importante o más que elegir el algoritmo de agrupamiento.

A veces los datos contienen grupos claramente separados; en ese caso puede

hablarse de **grupos naturales**.

Otras veces los grupos se solapan o no están claramente separados. En ese caso, el algoritmo sigue produciendo una partición, pero puede ser más correcto interpretarla como una **segmentación** útil de los datos que como el descubrimiento de clases naturales indiscutibles.

Por tanto:

- que un algoritmo produzca grupos no garantiza que esos grupos existan de forma clara en los datos;
- diferentes métodos o medidas de disimilitud pueden producir particiones diferentes;
- la interpretación del resultado sigue dependiendo del contexto del problema.

Estandarizar suele significar transformar cada variable para que tenga media 0 y varianza 1.

En muchos problemas se recomienda **estandarizar** las variables antes de calcular distancias, especialmente si unas variables tienen escalas mucho mayores que otras.

La motivación es sencilla:

- si una variable toma valores entre 0 y 100000;
- y otra toma valores entre 0 y 1;
- la primera puede dominar casi por completo una distancia numérica.

EXAM=(AAII.EX.2024S0.9)

Sin embargo, **en agrupamiento estandarizar no siempre es lo correcto**.

Si una variable presenta una gran variabilidad precisamente porque separa claramente los grupos naturales, reducir su influencia mediante estandarización puede ocultar la estructura que queremos descubrir.

Ejemplo conceptual:

Variable	Situación
X_1	Separa claramente dos grupos naturales
X_2	Tiene variación, pero no ayuda a distinguir grupos

Si se fuerza a ambas variables a influir igual en la distancia, X_2 puede ganar demasiada importancia y dificultar que el algoritmo detecte la separación real producida por X_1 .

En conclusión, estandarizar las variables para darles la misma importancia en el cálculo de la disimilitud puede empeorar la capacidad del algoritmo para distinguir grupos naturales.

4.3. Medidas de similitud y disimilitud

Los algoritmos de agrupamiento agrupan observaciones según una definición de qué significa que dos objetos sean **parecidos** o **diferentes**.

- Una **similitud** es mayor cuanto más parecidos son dos objetos.
- Una **disimilitud** es mayor cuanto más diferentes son dos objetos.
- Una **distancia** es un tipo particular de disimilitud que cumple propiedades matemáticas adicionales.

La idea fundamental es:

El algoritmo agrupa según la medida que se le proporcione; cambiar la disimilitud puede cambiar completamente los clústeres obtenidos.

Por ello, la elección de la medida de disimilitud debe depender del tipo de variables y del significado real del problema.

4.3.1. Matrices de proximidad

Bibliografía:

- [ESL] 14.3.1 “Proximity Matrixes”. Págs. 503

Una **matriz de proximidad** es una representación que asigna una medida de proximidad entre cada par de objetos

Una **matriz de disimilitud** es una matriz de proximidad en la que se usa una medida de disimilitud.

Si tenemos N objetos, la matriz de disimilitudes es una matriz $N \times N$:

\$\$

$$D = (d_{ii'})$$

\$\$

donde $d_{ii'}$ representa la disimilitud entre los objetos i e i' .

Ejemplo:

Objeto	A	B	C
A	0	2	8
B	2	0	6
C	8	6	0

En este ejemplo:

- A y B son relativamente parecidos, porque su disimilitud es pequeña;

- A y C son más diferentes, porque su disimilitud es mayor.

En algunos problemas no se dispone directamente de variables descriptivas para cada objeto, sino de una medida de proximidad entre cada par de objetos. Estas relaciones pueden organizarse en una matriz de proximidad.

En una matriz de disimilitudes se espera habitualmente que:

- la disimilitud sea no negativa;
- la disimilitud de un objeto consigo mismo sea cero;
- la matriz sea simétrica, es decir, $d_{ii'} = d_{i'i}$.

Concepto	Interpretación
Similitud alta	Los objetos se parecen mucho
Disimilitud alta	Los objetos son muy diferentes
Diagonal de una matriz de disimilitud	Vale 0, porque un objeto no difiere de sí mismo

Una **matriz de similitud** es una matriz de proximidad en la que se usa una medida de similitud.

Si inicialmente se dispone de similitudes, pueden transformarse en disimilitudes mediante una función que disminuya cuando aumenta la similitud.

Idea para recordar:

Una matriz de proximidad contiene la relación entre pares de objetos y puede utilizarse directamente como entrada de algunos algoritmos de clustering.

4.3.2. Disimilitudes según el tipo de atributo

Bibliografía:

- Básica
 - [ESL] 14.3.2 “Dissimilarities Based on Attributes” Pág. 503-504

Lo más habitual es que cada observación esté descrita por varios atributos o variables.

Para calcular la disimilitud entre dos observaciones, primero debe decidirse cómo medir su diferencia en cada atributo.

La medida adecuada depende del tipo de variable:

Tipo de variable	Ejemplo	Forma habitual de medir diferencia
Cuantitativa	Edad, peso, ingresos	Diferencia absoluta o diferencia cuadrática
Ordinal	Malo, regular, bueno, excelente	Convertir el orden a una escala numérica ordenada
Categorica	Color, país, tipo de producto	Igual o distinto, o costes específicos entre categorías

Las variables **cuantitativas** toman valores numéricos para los que tiene sentido medir diferencias.

Dos medidas habituales son:

Medida	Expresión para una variable	Característica
Diferencia absoluta	$\ x_i - x_{i'}\ $	Trata las diferencias de forma proporcional
Diferencia cuadrática	$(x_i - x_{i'})^2$	Penaliza especialmente las diferencias grandes

Ejemplo, si comparamos los valores 2 y 5:

- diferencia absoluta: 3;
- diferencia cuadrática: 9.

La diferencia cuadrática da más importancia a valores muy alejados y, por ello, puede ser más sensible a valores atípicos (*outliers*).

Las variables **ordinales** tienen categorías con un orden natural, pero las distancias entre categorías no están necesariamente definidas.

Ejemplos:

- bajo, medio, alto;
- suspenso, aprobado, notable, sobresaliente;
- muy insatisfecho, insatisfecho, neutral, satisfecho, muy satisfecho.

Una estrategia habitual consiste en sustituir las categorías por valores ordenados y tratarlas después como variables cuantitativas.

Ejemplo:

Categoría	Valor ordenado
Bajo	1
Medio	2
Alto	3

Lo importante es conservar el **orden** entre categorías.

Las variables **categóricas** o nominales tienen valores diferentes, pero sin un orden natural.

Ejemplos:

- rojo, verde, azul;
- Madrid, Sevilla, Valencia;
- tarjeta, efectivo, transferencia.

La medida más sencilla consiste en asignar:

- disimilitud 0 si los valores coinciden;
- disimilitud 1 si los valores son distintos.

Valor del objeto 1	Valor del objeto 2	Disimilitud
Rojo	Rojo	0
Rojo	Azul	1

En algunos problemas puede tener sentido definir diferencias distintas entre categorías. Por ejemplo, en medios de transporte, bicicleta y patinete podrían considerarse más próximos que bicicleta y avión.

Idea para recordar:

No existe una única distancia válida para todos los datos: las variables numéricas, ordinales y categóricas requieren tratamientos distintos.

EXAM=(2021J2.19)

En el **clustering de variables cuantitativas continuas**, los objetos que se agrupan son las **variables** o columnas, no las observaciones o filas.

Para comparar dos variables pueden utilizarse:

- la distancia euclídea entre sus valores;
- una disimilitud basada en la correlación entre ambas variables.

Estas dos formas son equivalentes cuando las **variables están estandarizadas**. En ese caso, dos variables muy correlacionadas quedan próximas, y dos variables poco correlacionadas quedan más alejadas.

Idea de examen:

En el clustering de variables cuantitativas continuas, usar distancia euclídea o una transformación de la correlación como disimilitud es equivalente si las variables están estandarizadas.

No debe confundirse con estandarizar observaciones: aquí se comparan variables, por lo que la estandarización relevante es la de las variables.

4.3.3. Disimilitud global entre objetos y ponderación de atributos

Bibliografía:

- [ESL] 14.3.3. “Objects Dissimilarity”. Págs. 505-507

Cuando una observación tiene varios atributos, la disimilitud total entre dos objetos debe combinar las diferencias calculadas en cada variable.

Sea $d_j(x_{ij}, x_{i'j})$ la disimilitud entre dos observaciones en el atributo j . La disimilitud global puede calcularse mediante una combinación ponderada:

$$D(x_i, x_{i'}) = \sum_{j=1}^p w_j \cdot d_j(x_{ij}, x_{i'j})$$

donde:

- p es el número de atributos;
- w_j es el peso asignado al atributo j ;
- un peso mayor hace que ese atributo influya más en la formación de clusters.

Los pesos suelen normalizarse para que sumen 1:

$$\sum_{j=1}^p w_j = 1$$

La elección de pesos no debe hacerse automáticamente: debe reflejar qué diferencias son realmente importantes en el contexto del problema.

Supongamos que agrupamos clientes mediante:

- gasto anual;
- distancia a una tienda.

Si el objetivo es diseñar ofertas según valor económico, puede interesar que el gasto tenga más peso que la distancia.

Variable	Peso posible
Gasto anual	0.8
Distancia a tienda	0.2

En cambio, si el objetivo es organizar rutas de reparto, la distancia podría ser más importante.

Por tanto:

La influencia adecuada de cada atributo depende del objetivo del análisis, no solo de los números disponibles.

Aunque se asignen pesos iguales, las variables no tienen necesariamente la misma influencia.

Ejemplo:

Variable	Rango aproximado
Edad	18 a 80
Ingresos anuales	10000 a 200000

Si se utiliza distancia euclídea sin transformar los datos, las diferencias de ingresos pueden dominar casi totalmente la distancia, simplemente porque sus valores numéricos son mayores.

En variables cuantitativas y utilizando distancia cuadrática, la influencia de una variable está relacionada con su varianza:

- variables con mayor varianza tienden a influir más;
- variables con menor varianza tienden a influir menos.

La **estandarización** transforma normalmente cada variable para que tenga media 0 y varianza 1.

Su finalidad habitual es evitar que una variable domine la disimilitud únicamente por tener una escala numérica mayor.

Ejemplo:

Situación	Posible utilidad de estandarizar
Ingresos medidos en euros y edad medida en años	Evitar que ingresos domine solo por su escala
Variables expresadas en unidades arbitrariamente diferentes	Hacer sus contribuciones más comparables

Sin embargo, en clustering estandarizar no siempre mejora el resultado.

Puede ocurrir que una variable tenga mucha variación porque es precisamente la que separa claramente los grupos naturales.

Ejemplo conceptual:

Variable	Papel en los grupos
X_1	Separa claramente dos grupos
X_2	Varía, pero no distingue grupos

Si se estandarizan ambas variables para que influyan por igual, puede reducirse artificialmente el peso de X_1 y aumentarse el de X_2 . Como consecuencia, los grupos pueden volverse más difíciles de detectar.

[ESL] ilustra precisamente este problema: en los datos originales se distinguen dos grupos bien separados, pero tras estandarizar las variables esa separación queda oscurecida.

Idea de examen:

Estandarizar las variables para darles la misma importancia al calcular la disimilitud puede empeorar la capacidad del algoritmo para distinguir grupos naturales presentes en los datos.

AAII.EX.2023J2.8

Si alguna observación tiene valores ausentes, el cálculo de la disimilitud debe adaptarse.

Opciones habituales:

- calcular la disimilitud utilizando solo los atributos observados en ambos objetos;
- imputar valores ausentes mediante la media o la mediana de la variable;
- en variables categóricas, tratar “ausente” como una categoría adicional cuando tenga sentido.

Eliminar los valores ausentes o imputar la mediana puede aumentar el sesgo, ya que de forma artificial se está reduciendo la varianza de esa variable.

Los valores ausentes no constituyen un algoritmo de agrupamiento diferente, pero afectan a cómo se calcula la disimilitud entre observaciones.

4.4. Familias de métodos de agrupamiento

Bibliografía:

- Básica
 - [ESL] 14.3.4 “Clustering Algorithms”. Págs. 507.
 - Apartado 4 “Métodos de clustering” de la presentación “ULAs” de la práctica de la asignatura.
 - Vídeos 8.2 y 8.3 “Algoritmos clustering” de la práctica de la asignatura.

No todos los métodos conciben un clúster de la misma manera:

- algunos buscan particiones que minimicen distancias internas;
- algunos suponen que los datos proceden de varias distribuciones probabilísticas;
- algunos construyen una jerarquía de agrupaciones;
- algunos identifican regiones con alta densidad de observaciones.

Por tanto, diferentes familias de clustering pueden encontrar soluciones distintas porque utilizan ideas diferentes sobre qué constituye un grupo.

Los métodos de agrupamiento intentan dividir las observaciones en grupos de forma que las disimilitudes dentro de cada grupo sean pequeñas y las disimilitudes entre grupos sean grandes. Existen distintas taxonomías de familias de métodos de agrupamiento.

Los métodos que se ponen como ejemplo para cada una de las familias serán individualmente estudiados con más detalle en el apartado “Métodos de clasificación no supervisada”, sin aplicarles ninguna taxonomía.

4.4.1. Taxonomía de Hastie et al

Bibliografía:

- Básica
 - [ESL] 14.3.4 “Clustering Algorithms”. Págs. 507.

EXAM=(2024J2.7)

[ESL] presenta tres grandes tipos de algoritmos de clustering, siendo la única taxonomía que se ha preguntado en algún examen de la asignatura:

Familia	Idea de clúster	Métodos representativos
Algoritmos combinatorios (<i>combinatorial algorithms</i>)	Agrupar las observaciones de forma directa al margen de cualquier distribución, asignando cada dato a un grupo sin suponer un modelo probabilístico (no paramétrico).	k -medias, k -medoides
Modelos de mezclas (<i>mixture modeling</i>)	Definen la densidad de probabilidad en el espacio de datos como una suma (mezcla) de distribuciones paramétricas, asumiendo que los datos provienen de una distribución distinta por cada cluster.	Mezclas gaussianas
Búscadores de modos (<i>mode seekers</i>)	Buscan máximos o regiones de alta densidad en la distribución de los datos. Están basados en la estimación no paramétrica de densidades de probabilidad en el espacio de datos.	DBSCAN, Mean Shift

4.4.2. Taxonomía de Google Developers

Bibliografía:

- Básica
 - Apartado 4. “Métodos de clustering de la presentación”ULAs” de la práctica de la asignatura.
 - Vídeos 8.2 y 8.3 “Algoritmos clustering” de la práctica de la asignatura.
- Complementaria
 - *Clustering Algorithms*. Google Developers. <https://developers.google.com/machine-learning/clustering/clustering-algorithms>
 - Dongkuan Xu, Yingjie Tian. *A Comprehensive Survey of Clustering Algorithms*. Springer Nature, 2015. <https://link.springer.com/article/10.1007/s40745-015-0040-1>

La presentación de la parte práctica de la asignatura emplea una taxonomía alternativa que coincide con la planteada en Google Developers.

Familia	Idea de clúster	Métodos representativos
Basados en centroides	Conjunto de observaciones asignadas a grupos minimizando disimilitud interna	k -medias
Jerárquicos	Grupo situado dentro de una jerarquía de fusiones o divisiones	Aglomerativo, divisivo, BIRCH, Diana, Agnes, ROCK
Basados en densidad	Región del espacio con alta concentración de observaciones	DBSCAN, Mean Shift, OPTICS, DenClue
Basados en distribución	Componente de una distribución mezcla que genera parte de los datos	Mezclas gaussianas, COBWEB

Familia	¿Requiere fijar K inicialmente?	Forma de los grupos	Elemento característico
Basados en centroides	Sí	Preferentemente grupos compactos y aproximadamente globulares	Centroides
Jerárquicos	No necesariamente al construir la jerarquía	Depende de la disimilitud y del enlace	Dendrograma
Basados en densidad	No necesariamente como número directo de clusters	Puede detectar formas arbitrarias	Regiones densas y, en DBSCAN, ruido
Basados en distribución	Habitualmente sí, número de componentes	Grupos modelados mediante distribuciones	Probabilidades de pertenencia

No existe una familia universalmente mejor dentro de esta taxonomía.

Situación aproximada	Familia que puede resultar natural
Se buscan K grupos compactos alrededor de centros	Basados en centroides
Interesa observar grupos a distintos niveles	Jerárquicos
Hay ruido o clusters con formas irregulares	Basados en densidad
Se desea una interpretación probabilística de pertenencia	Basados en distribución

La elección final también depende de:

- la medida de disimilitud;
- la escala y tipo de las variables;
- el número de clusters esperado;
- la presencia de ruido;
- la utilidad práctica de los grupos obtenidos.

4.4.2.1. Métodos basados en centroides Los métodos basados en centroides asignan cada observación a uno y solo un clúster, buscando una partición que haga que las observaciones del mismo grupo sean próximas entre sí.

Su criterio típico consiste en minimizar la disimilitud dentro de los clusters.

Características:

- trabajan directamente con las observaciones o con sus disimilitudes;
- no suponen que los datos procedan de una distribución probabilística concreta;
- normalmente requieren indicar de antemano el número de clusters K ;
- encontrar la mejor partición examinando todas las posibilidades es impracticable en conjuntos de datos normales.

Por ello, los métodos prácticos utilizan algoritmos iterativos que buscan una buena solución, aunque no garanticen el óptimo global.

Un ejemplo sería k -medias, donde el representante de cada clúster es el centroide o media de las observaciones del grupo.

k -medoides no pertenece a esta categoría, ya que el representante de cada cluster no es un centroide, sino un prototipo, donde el representante de cada cluster es una observación real elegida como centro del grupo.

Una posible categoría que englobe los métodos basados en centroides y en prototipos sería métodos de partición.

Los métodos de partición forman directamente K grupos intentando reducir la disimilitud interna.

4.4.2.2. Métodos basados en modelos probabilísticos

Los **métodos basados en modelos probabilísticos** suponen que las observaciones proceden de una población formada por varios componentes, y que cada componente representa un clúster.

El ejemplo principal del temario es la **mezcla de gaussianas**.

4.4.2.3. Métodos jerárquicos Los **métodos jerárquicos** producen una organización de los datos en distintos niveles de agrupamiento. En lugar de devolver únicamente una partición final con K clústeres, construyen una jerarquía.

El resultado se representa mediante un **dendrograma**, que es un árbol en el que:

- las hojas representan observaciones individuales;
- las uniones representan agrupaciones de clusters;
- la altura de una unión refleja la disimilitud entre los grupos fusionados.

Características:

- no requieren fijar inicialmente un único número de clústeres;
- permiten inspeccionar soluciones con distinto nivel de detalle;
- el número final de grupos puede obtenerse cortando el dendrograma a una determinada altura;
- el resultado depende de cómo se mida la disimilitud entre grupos.

El agrupamiento jerárquico representa grupos anidados: puede estudiarse desde soluciones muy detalladas hasta soluciones más generales.

Una ventaja frente a k -medias es que no obliga a elegir inicialmente un único valor de k . El usuario puede cortar el dendrograma a distintas alturas para obtener diferentes números de clusters.

Opcionalmente se puede establecer un criterio de parada automático como puede ser:

- Un **número de clústeres**, mínimo o máximo.
- Un **umbral de distancia**, de manera que se detiene cuando la distancia entre clústeres lo supera.

Existen dos enfoques principales:

Enfoque jerárquico	Procedimiento
Aglomerativo	Comienza con una observación por clúster y va fusionando los grupos más próximos
Divisivo	Comienza con todos los datos en un único clúster y lo va dividiendo

Ejemplos de métodos de agrupamiento jerárquico:

Método jerárquico	Nombre completo	Enfoque
AGNES	<i>Agglomerative Nesting</i>	Aglomerativo
DIANA	<i>Divisive Analysis</i>	Divisivo
BIRCH	<i>Balanced Iterative Reducing and Clustering using Hierarchies</i>	Aglomerativo (híbrido)
ROCK	<i>Robust Clustering using Links</i>	Aglomerativo

En la asignatura se estudian los dos enfoques aglomerativo y divisivo de manera general, referenciándose el método BIRCH tan solo en una de las bibliografías.

4.4.2.4. Métodos basados en densidad Bibliografía:

- Básica
 - Sección “Métodos basados en densidad” de la presentación “ULAs” de la parte práctica de la asignatura.
 - Vídeo 8.8 “Métodos basados en densidad” de la práctica de la asignatura

Los **métodos basados en densidad** interpretan un clúster como una región del espacio con alta concentración de observaciones, separada de otras regiones por zonas con poca densidad.

A diferencia los métodos basados en centroides, como k -medias, no necesitan representar cada clúster mediante un centroide ni asumir que los grupos sean aproximadamente esféricos.

Características:

- pueden detectar clústers con formas arbitrarias, no necesariamente globulares;
- algunos pueden identificar observaciones aisladas como ruido o valores atípicos;
- dependen de parámetros relacionados con la densidad;
- resultan adecuados cuando los clústers no forman “bolas” alrededor de centroides.

Ejemplos de algoritmos de agrupamiento basados en densidad:

Método	Idea básica
DBSCAN	Expande clusters desde regiones con suficientes vecinos cercanos y puede marcar puntos como ruido

Método	Idea básica
Mean Shift	Desplaza puntos o centros hacia máximos locales de densidad
OPTICS	
DENCLUE	
CLIQUE	

El material de la asignatura se centra en DBSCAN, que es hasta el curso 2024/2025 el único por el que se ha preguntado en exámenes. No obstante, el temario de la asignatura cubre algo de Mean Shift y en aún menor medida OPTICS.

Idea para recordar:

Los métodos basados en densidad buscan regiones pobladas del espacio y pueden detectar clusters con formas que k -medias no modela bien.

4.5. Métodos de clasificación no supervisada

Bibliografía:

- [ESL] 14.3.5-14.3.12, Págs. 507-527.

Se contemplan los siguientes métodos simples y clásicos de clasificación no supervisada:

- Agrupamiento combinatorio
- K-medias
- Mezcla de Gaussianas
- Cuantización de vectores
- K-mediods
- Agrupamiento jerárquico aglomerativo
 - BIRCH
- Agrupamiento jerárquico divisivo
- DBSCAN
- Mean Shift

Se mencionan también los siguientes métodos pero se consideran avanzados:

- Agrupamiento espectral
- Agrupamiento en subespacios

Método	Idea principal
Agrupamiento combinatorio	Buscar una partición que minimice la disimilitud interna de los grupos

Método	Idea principal
k -medias	Representar cada grupo mediante su media o centroide
Mezclas gaussianas	Modelar cada grupo mediante una distribución gaussiana y obtener pertenencias probabilísticas
Cuantización de vectores	Aplicar ideas de k -medias a compresión de señales o imágenes
k -medoides	Representar cada grupo mediante una observación real
Agrupamiento jerárquico	Construir una jerarquía de fusiones o divisiones de grupos
DBSCAN	Detectar regiones densas y marcar puntos aislados como ruido
Mean Shift	Buscar máximos locales de densidad desplazando centros hacia zonas densas

4.5.1. Agrupamiento combinatorio

Bibliografía:

- [ESL] 14.3.5 “Combinatorial Algorithms”

Los **algoritmos de agrupamiento combinatorio** asignan cada observación a uno de K clústeres sin suponer que los datos procedan de una distribución de probabilidad concreta.

Su objetivo es encontrar una partición en la que las observaciones del mismo grupo estén próximas entre sí y, de forma equivalente, los grupos distintos queden lo más separados posible.

Si $C(i)$ indica el clúster asignado a la observación i , una función objetivo natural es la dispersión interna de los grupos:

$$W(C) = \frac{1}{2} \sum_{k=1}^K \sum_{C(i)=k} \sum_{C(i')=k} d(x_i, x_{i'})$$

donde $d(x_i, x_{i'})$ es la disimilitud entre dos observaciones.

EXAM=(2021J2.8)

Interpretación:

- $W(C)$ es pequeña si los objetos del mismo clúster son parecidos;
- minimizar $W(C)$ equivale a buscar grupos internamente compactos;

- también puede verse como maximizar la separación entre grupos.

La razón es que la dispersión total de los datos puede descomponerse como:

$$T = W(C) + B(C)$$

donde:

- T es la dispersión total;
- $W(C)$ es la dispersión dentro de los clústeres;
- $B(C)$ es la dispersión entre clústeres.

Como T permanece fija para los datos dados:

Minimizar la dispersión dentro de los clústeres es equivalente a maximizar la dispersión entre clústeres.

El problema es que el número de particiones posibles crece enormemente con el número de observaciones. Examinar todas las asignaciones posibles solo es viable para conjuntos de datos muy pequeños.

Por ello, los algoritmos combinatorios prácticos utilizan búsquedas heurísticas o iterativas que exploran solo una pequeña parte de todas las particiones posibles.

4.5.2. K-medias

Bibliografía:

- [ESL] 14.3.6 “K-means” Págs. 509-510
- Apartado “Algoritmo k -means” de la presentación “ULA” de la práctica de la asignatura.
- Vídeo de la asignatura: 8.6. “k-Means”
- Vídeo 8.13 “Implementación de k-means” de la práctica de la asignatura

El algoritmo de **k -medias** (*k-means*) es un método combinatorio que representa cada clúster mediante su **centroide**, es decir, la media de las observaciones asignadas a ese grupo.

Se utiliza habitualmente con variables cuantitativas y distancia euclídea cuadrática.

El método necesita fijar previamente el número de clusters K .

Para cada cluster k , sea m_k su centroide. El algoritmo intenta minimizar la suma de distancias cuadráticas de cada observación al centroide de su grupo:

$$\sum_{k=1}^K \sum_{C(i)=k} \|x_i - m_k\|^2$$

Interpretación:

k -medias intenta construir K grupos compactos alrededor de K centroides.

EXAM=(2023J2.7)

El **algoritmo** alterna dos pasos:

1. **Asignación de observaciones:** cada observación se asigna al centroide más cercano.
2. **Actualización de centroides:** cada centroide se recalcula como la media de las observaciones que tiene asignadas.

Paso	Qué se modifica	Qué permanece fijo
Asignación	El codificador $C(i)$, es decir, el grupo de cada observación	Los centroides
Actualización	Las medias o centroides de cada grupo	Las asignaciones actuales

Ambos pasos disminuyen o mantienen la función objetivo. El proceso termina cuando las asignaciones dejan de cambiar.

Importante:

k -medias garantiza convergencia, pero no garantiza alcanzar el óptimo global; puede terminar en un óptimo local.

El resultado depende de los centroides iniciales.

- Una buena inicialización puede conducir a una partición adecuada.
- Una mala inicialización puede conducir a clústeres peores.
- Una práctica habitual es ejecutar el algoritmo varias veces con inicializaciones diferentes y conservar la solución con menor coste.

k -medias funciona mejor cuando los clústeres son aproximadamente compactos y globulares.

Puede funcionar mal cuando:

- existe mucho ruido o valores atípicos;
- los clústeres tienen formas no globulares;
- los clústeres tienen tamaños muy diferentes;
- los clústeres tienen densidades muy diferentes;
- la distancia euclídea no representa adecuadamente la similitud relevante.

La distancia cuadrática da mucha influencia a observaciones muy alejadas, por lo que k -medias puede ser sensible a valores atípicos (*outliers*).

EXAM=(2023J2.7)

La idea de k -medias puede generalizarse utilizando otras medidas de disimilitud y modificando la forma de obtener el representante o prototipo de cada clúster.

Por ejemplo:

Método	Representante del clúster	Robustez frente a valores atípicos
k -medias	Media	Menor
k -medianas	Mediana	Mayor
k -medoides	Observación real representativa	Mayor flexibilidad en disimilitudes

Por tanto, puede obtenerse una versión de k -means más robusta frente a valores atípicos sustituyendo la definición de los representantes o prototipos de cada clúster por otra adecuada a una métrica más robusta.

EXAM=AAII.EX.2024S0.8

k -medias está estrechamente relacionado con el algoritmo EM aplicado a mezclas gaussianas.

- En mezclas gaussianas, una observación puede pertenecer parcialmente a distintos componentes mediante probabilidades.
- En k -medias, cada observación se asigna de forma dura al centroide más cercano.
- Cuando las gaussianas tienen covarianzas esféricas muy pequeñas, la asignación probabilística se vuelve prácticamente determinista y coincide con k -medias.

Por ello, para el test:

k -medias puede verse como una versión límite o simplificada de EM para mezclas gaussianas, basada en una búsqueda heurística local y no en la exploración exhaustiva de todas las particiones.

k -medias necesita que se especifique el número k .

4.5.3. Mezclas gaussianas

Bibliografía:

- Básico
 - [ESL] 14.3.7 “Gaussian Mixtures as Soft K-Means Clustering”. Págs. 510-514.
- Complementario
 - 8.2.10 “Gaussian Mixture Model” del capítulo 8 “Aprendizaje No Supervisado” del libro desconocido de la práctica de la asignatura.

EXAM=(2026J2.10)

La **mezcla de gaussianas** es la generalización probabilística del algoritmo de k -medias. En ella, una observación puede tener distinta probabilidad de pertenencia a cada clúster en lugar de pertenecer rígidamente a un solo clúster.

El agrupamiento mediante mezclas gaussianas supone que los datos proceden de una mezcla de varias distribuciones gaussianas, cada una asociada a un clúster.

- cada clúster se representa mediante una distribución gaussiana;
- cada observación puede tener cierta probabilidad de pertenecer a cada clúster;
- la asignación puede ser blanda o probabilística, no necesariamente una decisión inmediata de pertenencia única.

A diferencia de k -medias, una observación no se asigna inicialmente de forma absoluta a un único grupo. En su lugar, recibe una probabilidad de pertenencia a cada componente.

Método	Asignación de una observación
k -medias	Dura: pertenece al clúster con centroide más próximo
Mezcla gaussiana	Blanda: tiene una probabilidad de pertenecer a cada clúster

Ejemplo:

Clúster	Probabilidad de pertenencia de una observación
Grupo 1	0.75
Grupo 2	0.20
Grupo 3	0.05

La observación se asociaría principalmente al grupo 1, pero se conserva información sobre la incertidumbre.

Por ello, una mezcla de gaussianas es una generalización probabilística o blanda de k -medias.

EXAM=(2022SO.8)

Si las gaussianas tienen matrices de covarianza esféricas e iguales, proporcionales a la identidad, y su dispersión tiende a cero, las probabilidades de pertenencia se convierten en asignaciones prácticamente duras al centro más próximo.

Siguiendo la notación utilizada en el examen:

$$\Sigma = \sigma I, \quad \sigma \rightarrow 0$$

En ese caso, la mezcla de gaussianas coincide con k -medias.

4.5.4. Cuantización de vectores

Bibliografía:

- [ESL] 14.3.9 de la práctica de la asignatura. Págs. 514-515.

La **cuantización de vectores** (en inglés, *vector quantization*, VQ) aplica la idea de k -medias a problemas de compresión, especialmente de imágenes o señales.

Procedimiento conceptual:

1. Se dividen los datos en pequeños bloques representados como vectores.
2. Se agrupan esos vectores mediante k -medias.
3. Cada centroide representa un patrón prototipo o *codeword*.
4. Cada bloque original se sustituye por la referencia al prototipo más cercano.

Concepto	Significado
<i>Codebook</i>	Conjunto de centroides o prototipos
<i>Codeword</i>	Uno de los prototipos
Compresión	Sustituir muchos bloques similares por referencias al mismo prototipo

Cuanto menos prototipos se utilicen, mayor será la compresión, pero también puede aumentar la pérdida de calidad.

La cuantización de vectores utiliza centroides obtenidos mediante k -medias para representar de forma compacta muchos patrones similares.

4.5.5. K-medoides

Bibliografía:

- Básica
 - [ESL] 14.3.10 “K-medoids”. Págs. 515-518

El algoritmo de ***k-medoides*** (***k-medoids***) es una variante de *k-medias* en la que el representante de cada clúster no es la media, sino una observación real del propio grupo.

Método	Representante del clúster
<i>k-medias</i>	Centroide calculado como media
<i>k-medoides</i>	Observación real que minimiza la disimilitud con las demás del grupo

Ventajas de *k-medoides*:

- puede utilizar disimilitudes más generales que la distancia euclídea cuadrática;
- puede aplicarse cuando solo disponemos de una matriz de disimilitudes;
- suele ser menos sensible a valores atípicos que *k-medias*.

Inconveniente:

- tiene mayor coste computacional, porque elegir el medoide exige comparar observaciones dentro del clúster.

Procedimiento básico:

1. Seleccionar un medoide para cada clúster.
2. Asignar cada observación al medoide más próximo.
3. Recalcular qué observación debe ser el medoide de cada grupo.
4. Repetir hasta que las asignaciones no cambien.

4.5.6 Agrupamiento jerárquico aglomerativo Bibliografía:

- Básica
 - [ESL] 14.3.12 “Hierarchical Clustering”. Págs. 520-528.
 - Apartado “Clustering jerárquico” de la presentación “ULAs” de la práctica de la asignatura.
 - Vídeo 8.7 “Clustering jerárquico” de la práctica de la asignatura.
 - Vídeo 8.12 “Agglomerative” de la práctica de la asignatura.

El **agrupamiento jerárquico aglomerativo** forma los clústeres partiendo de cada dato como clúster único y fusionándolos sucesivamente.

Este método trabaja de abajo hacia arriba:

1. Comienza con un clúster por cada observación.
2. Calcula qué dos clústeres son más próximos.

3. Los fusiona en un único clúster.
4. Repite el proceso hasta que todos los datos forman un solo grupo.

En un dendrograma aglomerativo, los grupos muy parecidos se fusionan a baja altura. Los grupos más diferentes se fusionan más arriba.

La altura de la unión refleja la disimilitud entre los clusters fusionados y, en la representación jerárquica habitual, crece a medida que avanzan las fusiones.

Ejemplo conceptual:

Altura de fusión	Interpretación
Baja	Grupos muy similares
Alta	Grupos más diferentes

Para fusionar clústeres hay que definir cómo medir la disimilitud entre dos grupos completos. Los **criterios de enlace en agrupamiento aglomerativo** que se estudian en [ESL] y la asignatura son:

- *Single linkage*
- *Complete linkage*
- *Average linkage*

Single linkage considera que dos clústeres son próximos si existe al menos una pareja de puntos, uno de cada clúster, que esté muy próxima.

Esto puede provocar el fenómeno de **encadenamiento** (*chaining*), que se produce cuando los puntos o grupos se unen mediante una cadena de observaciones próximas y el clúster resultante puede ser largo y poco compacto, de manera que algunos puntos del mismo clúster pueden estar muy alejados entre sí.

EXAM=2022J2.10

El problema del encadenamiento solo aparece en el agrupamiento jerárquico aglomerativo con criterio *single linkage*.

Complete linkage exige que los elementos más alejados de dos grupos no estén demasiado separados. Por ello, tiende a producir clústeres más compactos.

Average linkage utiliza la distancia media entre los elementos de ambos grupos y representa una solución intermedia entre los extremos de *single* y *complete linkage*.

Criterio	Cómo mide la distancia entre dos clusters	Tendencia principal
<i>Single linkage</i>	Distancia entre la pareja de observaciones más próxima	Puede producir encadenamiento
<i>Complete linkage</i>	Distancia entre la pareja de observaciones más alejada	Favorece clusters compactos
<i>Average linkage</i>	Media de las distancias entre observaciones de ambos grupos	Compromiso entre ambos

Entre los métodos de agrupamiento jerárquico divisivo se encuentran:

- AGNES
- BIRCH (principalmente aglomerativo, pero híbrido)
- ROCK

En la asignatura no se entra en detalle de ninguno de los métodos ni se ha preguntado sobre ellos en los exámenes hasta el curso 2024/2025, si bien BIRCH es desarrollada en una de las bibliografías complementarias.

4.5.6.1. BIRCH

Bibliografía:

- Básica
 - Apartado 8.2.3. “Birch” del capítulo 8 “Aprendizaje No Supervisado” del libro desconocido incluido en la práctica de la asignatura.

4.5.7. Agrupamiento jerárquico divisivo

Bibliografía:

- Básica
 - [ESL] 14.3.12 “Hierarchical Clustering”. Págs. 520-528.
 - Apartado “Clustering jerárquico” de la presentación “ULAs” de la práctica de la asignatura.
 - Vídeo 8.7 “Clustering jerárquico” de la práctica de la asignatura.

El método **divisivo** trabaja de arriba hacia abajo:

1. Comienza con todos los datos en un solo clúster.
2. Divide uno de los clústeres existentes en dos grupos.
3. Repite la división recursivamente.

Puede ser útil si interesa especialmente obtener un número pequeño de grupos generales, pero se estudia y utiliza menos que el enfoque aglomerativo.

4.5.8. DBSCAN

Bibliografía:

- Básica
 - Apartado 3 “DBSCAN” de la sección “Métodos basados en densidad” de la presentación “ULAs” de la práctica de la asignatura.
 - Apartado 8.2.4 “DBSCAN” del capítulo 8 “Aprendizaje No Supervisado” de un libro incluido en la parte práctica de la asignatura. Págs. 338-340.
 - Vídeo 8.8 “Métodos basados en densidad” de la práctica de la asignatura

=EXAM(2025J2.1)

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) es un método basado en densidad que forma clústers conectando observaciones situadas en regiones suficientemente pobladas.

Sus parámetros fundamentales son:

Parámetro	Variable Scikit-learn
ε	eps
Mínimo observaciones	min_samples

Tipos de punto en DBSCAN:

Tipo de punto	Idea
Punto núcleo	Tiene suficientes vecinos dentro de su radio ε
Punto frontera	Está próximo a un núcleo, pero no tiene suficientes vecinos por sí mismo
Ruido	No queda conectado a ninguna región densa

Ventajas principales de DBSCAN frente a k -medias:

DBSCAN	k -medias
No obliga a fijar previamente K	Requiere indicar K
Puede detectar clústeres con formas arbitrarias	Funciona mejor con grupos compactos o globulares
Puede identificar ruido	Todos los puntos suelen asignarse a algún clúster

4.5.9. Mean Shift

Bibliografía:

- Básica
 - Apartado 8.2.7 “Mean Shift” del capítulo 8 “Aprendizaje No Supervisado” de un libro incluido en la parte práctica de la asignatura. Págs. 338-340.
 - Vídeo 8.8 “Métodos basados en densidad” de la práctica de la asignatura
 - Vídeo 8.14 “Mean Shift”

Mean Shift es un método basado en densidad que busca los máximos locales o **modos** de la densidad de los datos.

La idea básica es:

1. Situar puntos o centros en el espacio de características.
2. Calcular hacia qué dirección se concentra una mayor densidad de observaciones.
3. Desplazar iterativamente cada centro hacia esa región más densa.
4. Considerar que los centros que llegan al mismo máximo representan un mismo clúster.

Su parámetro principal es el ancho de banda (**bandwidth**), que controla el tamaño de la región utilizada para estimar la densidad.

bandwidth	Efecto aproximado
Pequeño	Puede detectar muchos máximos y producir más clústeres
Grande	Suaviza la densidad y puede fusionar clústeres

La diferencia entre Mean Shift y DBSCAN es que Mean Shift agrupa buscando máximos de densidad y DBSCAN agrupa conectando regiones densas y puede etiquetar puntos como ruido.

4.5.10. OPTICS

Bibliografía

- Básica
 - Apartado 8.2.7 “OPTICS” del capítulo 8 “Aprendizaje No Supervisado” de un libro incluido en la parte práctica de la asignatura. Págs. 338-340.

4.5.11. Agrupamiento espectral

Bibliografía:

- Básica

– [TSpC]

El **agrupamiento espectral** (en inglés, *spectral clustering*) transforma los datos en un grafo de similitud, donde los puntos son nodos y las aristas representan parecidos entre puntos. Después usa los autovectores del laplaciano del grafo para obtener una representación donde los grupos son más fáciles de separar, normalmente aplicando luego k -medias.

Es útil cuando los clústeres no tienen formas simples como las que espera k -medias.

4.5.12. Agrupamiento en subespacios

Bibliografía:

- Básica
 - [TSSC]

El **agrupamiento en subespacios** (en inglés, *subspace clustering*) intenta encontrar simultáneamente qué subespacios existen y qué puntos pertenecen a cada uno en lugar de buscar clústeres alrededor de centros.

Se usa cuando los datos viven en un espacio de muchas dimensiones, pero los grupos reales se explican mejor en subespacios de menor dimensión. Es útil en datos de alta dimensión, por ejemplo visión artificial, imágenes o movimiento.

4.6. Cuestiones prácticas en agrupamiento

4.6.1. Inicialización y óptimos locales

- Básica
 - [ESL] 14.3.11 “Practical Issues”. Págs. 518-520.

Métodos iterativos como k -medias y k -medoides necesitan una configuración inicial, normalmente K centros iniciales.

En k -medias, cada iteración reduce o mantiene la dispersión interna de los clusters, por lo que el algoritmo termina convergiendo. Sin embargo, solo explora una parte de las particiones posibles:

k -medias converge, pero puede hacerlo a un óptimo local y no al óptimo global.

Como el resultado puede depender de los centros iniciales, una práctica habitual es:

1. Ejecutar el algoritmo varias veces con inicializaciones diferentes.
2. Comparar la función objetivo obtenida en cada ejecución.
3. Conservar la solución con menor dispersión interna.

Una inicialización sencilla consiste en elegir aleatoriamente K observaciones como centros iniciales.

Idea para recordar:

Una mala inicialización puede producir clusters peores; varias inicializaciones reducen ese riesgo, pero no garantizan encontrar el óptimo global.

4.6.2. Selección del número de clústeres

Bibliografía:

- Básica
 - [ESL] 14.3.11 “Practical Issues”. Págs. 518-520.
 - Apartado 8.3. “Determinar número óptimo de clústers” del capítulo 8 “Aprendizaje No Supervisado” del libro desconocido de los apuntes prácticos.
 - Vídeo 8.9 “Determinar clusters”
 - Vídeo 8.11 “Tecnicas para determinar clusters”

Métodos como k -**medias** y k -**medoides** necesitan indicar previamente el número de clústeres K .

Si se aumenta k , la disimilitud interna de los grupos tiende a disminuir:

- con más clústeres, cada grupo contiene menos observaciones;
- las observaciones pueden quedar más próximas a su centro o representante;
- por tanto, elegir el k que simplemente minimiza la disimilitud llevaría a usar demasiados grupos.

Criterios empleados para seleccionar el número de clústeres:

- Criterio del codo
- Dendograma
- GAP
- Silhouette

No se entra en detalle de Silhouette, ya que este criterio se ve más en detalle en el apartado de evaluación de métricas.

4.6.2.1. Criterio del codo)

Bibliografía:

- Básica
 - [ESL] 14.3.11 “Practical Issues”. Págs. 518-520.
 - [ANS] Apartado 8.3.1. “Método del codo”.

El **criterio del codo** (*kink*, *knee* o *elbow*) consiste en ejecutar el método para distintos valores de K y observar la disimilitud intra-grupo W_K :

- mientras se estén separando grupos naturales, aumentar K produce descensos importantes de W_K ;
- cuando los grupos principales ya se han separado, añadir más clústeres produce mejoras pequeñas;
- se selecciona el valor de K a partir del cual la reducción deja de ser significativa.

El número de grupos puede estimarse como el valor a partir del cual aumentar k ya no produce descensos significativos en la disimilitud intra-grupo.

4.6.2.2. Dendograma) Bibliografía:

- Básica
 - [ANS] Apartado 8.3. “Determinar número óptimo de clústers”.

4.6.2.3. GAP) Bibliografía:

- Básica
 - [ESL] 14.3.11 “Practical Issues”. Págs. 519-520.
 - [ANS] Apartado 8.3.2. “GAP”.

El **estadístico Gap** (en inglés, *Gap Statistic*) es una técnica para estimar el número de clusters k .

La idea es comparar la dispersión intra-grupo observada en los datos reales con la dispersión intra-grupo que se esperaría si los datos no tuvieran una estructura clara de grupos.

EXAM=(2021J2.26)

Para ello se compara:

- la dispersión intra-grupo obtenida por un codificador $C(i)$ en los datos reales;
- la dispersión intra-grupo obtenida en datos de referencia generados bajo una distribución aproximadamente uniforme.

Es decir:

Gap compara el agrupamiento real con lo que ocurriría si los datos estuvieran distribuidos de forma uniforme, sin clusters claros.

Si para cierto valor de K la dispersión interna real es mucho menor que la esperada bajo datos uniformes, eso sugiere que ese número de clusters captura una estructura relevante.

No debe confundirse con:

- asumir una mezcla de gaussianas como proceso generador;
- comparar con el resultado de otro algoritmo;
- elegir simplemente el k que minimiza la dispersión intra-grupo.

La elección sigue siendo parcialmente heurística: puede no existir un valor de k claramente mejor y conviene contrastar el resultado con otras métricas y con la interpretación del problema.

4.7. Evaluación de agrupamientos

Bibliografía:

- Básica
 - [EMUL]

Puesto que para la parte de evaluación de agrupamientos la única bibliografía es [EMUL], se estructura el contenido de manera similar a como hace el artículo.

Evaluar un agrupamiento es más difícil que evaluar una clasificación supervisada, porque normalmente no se dispone de etiquetas verdaderas que indiquen cuál es la partición correcta.

Una solución de agrupamiento suele considerarse buena cuando presenta:

- **alta cohesión:** los elementos del mismo cluster están próximos entre sí;
- **alta separación:** los elementos de clústeres diferentes están alejados entre sí.

Sin embargo, no existe una única métrica universalmente adecuada para todos los algoritmos y todos los tipos de clústeres.

La evaluación de agrupamiento debe realizarse comparando varias métricas y, cuando sea posible, buscando soluciones estables entre distintos algoritmos y configuraciones.

Las medidas de evaluación pueden clasificarse en:

Tipo de evaluación	Qué utiliza	Cuándo puede aplicarse
Interna	Solo los datos y los clústeres obtenidos	Cuando no existen etiquetas externas

Tipo de evaluación	Qué utiliza	Cuándo puede aplicarse
Externa	Una partición o etiquetas de referencia	Cuando existe información externa disponible
Relativa	Compara soluciones obtenidas con distintos parámetros o algoritmos	Para elegir configuraciones o número de clústeres

Además, pueden utilizarse pruebas estadísticas para comprobar si los datos muestran realmente una tendencia de agrupamiento o si la estructura observada podría ser compatible con datos aleatorios.

La **evaluación interna** valora la calidad de los clústeres utilizando únicamente la información disponible en los propios datos.

Sus dos conceptos fundamentales son:

Concepto	Significado	En una buena agrupación
Cohesión	Proximidad entre observaciones del mismo clúster	Debe ser alta
Separación	Distancia entre observaciones o centros de clústeres diferentes	Debe ser alta

En términos de disimilitud:

- una buena cohesión implica distancias pequeñas dentro de cada clúster;
- una buena separación implica distancias grandes entre clústeres.

Dos cantidades básicas son:

Medida	Significado	Valor deseable
SSE o SSW	Suma de errores cuadrados dentro de los clústeres	Pequeño
SSB	Suma de cuadrados entre clústeres	Grande

La **suma de errores cuadrados intragrupo** (SSE) mide cuánto se alejan las observaciones del representante de su propio cluster.

La **suma de cuadrados entre grupos** (SSB) mide cuánto se separan los clústeres entre sí.

Por tanto:

Una buena agrupación tiende a presentar SSE pequeña y SSB grande.

Advertencia:

Las métricas basadas en SSE favorecen naturalmente a métodos como k -medias, porque ese algoritmo se construye precisamente minimizando la suma de errores cuadrados. Pueden ser menos adecuadas para evaluar métodos basados en densidad como DBSCAN.

La **evaluación externa** compara los clústeres encontrados con una partición de referencia externa, por ejemplo:

- etiquetas conocidas que no se utilizaron durante el agrupamiento;
- la clasificación proporcionada por un experto;
- el resultado de otro método que se toma como referencia.

Algunas medidas externas son:

Familia	Ejemplos
Correspondencia entre clústeres y clases	Pureza, precisión, recall, medida F
Comparación de pares de observaciones	Índice de Rand, Jaccard, Fowlkes-Mallows
Teoría de la información	Entropía, información mutua

La evaluación externa no siempre está disponible, porque el objetivo habitual del aprendizaje no supervisado es precisamente trabajar sin etiquetas conocidas.

La **evaluación relativa** compara varios agrupamientos obtenidos:

- con distintos algoritmos;
- con diferentes valores de sus parámetros;
- con distintos números de clústeres.

Por ejemplo, puede utilizarse para comparar soluciones de k -medias obtenidas con diferentes valores de K .

Esta idea conecta con el criterio del codo:

Se buscan configuraciones a partir de las cuales aumentar la complejidad ya no produce mejoras significativas en la calidad del agrupamiento.

4.7.1. Índices internos combinados de evaluación

Bibliografía:

- Básica
 - [EMUL] Subapartado A “Partitional methods” del apartado IV “Internal Validation”.

Existen medidas que intentan combinar en un único valor la cohesión y la separación de los clústeres.

Índice	Idea principal	Valor deseable
Calinski-Harabasz	Comparar separación entre clústeres con dispersión interna, corregidas por grados de libertad	Alto
Hartigan	Relación logarítmica entre separación y dispersión interna	Alto
Dunn	Comparar la mínima separación entre clústeres con el máximo diámetro interno	Alto
Silhouette	Comparar, para cada observación, su proximidad al propio clúster con su proximidad al clúster alternativo más cercano	Alto

4.7.1.1. Índice de Calinski-Harabasz

Bibliografía:

- Básica
 - [EMUL] IV. Internal Validation

El índice de **Calinski-Harabasz** relaciona la dispersión entre clústeres con la dispersión dentro de los clústeres, ajustando ambas cantidades por grados de libertad.

En la notación utilizada en [EMUL]:

$$CH = \frac{SSB_M/(M-1)}{SSE_M/M}$$

donde:

- M es el número de clústeres;
- SSB_M mide la dispersión o separación entre clústeres;
- SSE_M mide la dispersión interna de los clústeres.

Interpretación:

Un valor alto de Calinski-Harabasz indica clústeres bien separados y con poca dispersión interna.

No confundir:

La fórmula basada en el cociente de SSB y SSE corregido por grados de libertad corresponde a **Calinski-Harabasz**, no a Hartigan.

4.7.1.2. Índice de Hartigan

Bibliografía:

- Básica
 - [EMUL] IV. Internal Validation

EXAM=(2023J2.6)

Según [EMUL], el índice de **Hartigan** se define como el logaritmo del cociente entre la suma de cuadrados entre clústeres y la suma de errores cuadrados dentro de los clústeres:

$$H = \log \left(\frac{SSB_M}{SSE_M} \right)$$

Interpretación:

- SSB_M grande indica clústeres alejados entre sí;
- SSE_M pequeña indica clústeres internamente compactos;
- un valor alto de H indica una mejor separación relativa respecto a la dispersión interna.

Dicho en otras palabras, el índice de Hartigan mide, en escala logarítmica, la relación entre la dispersión entre grupos y la dispersión dentro de los grupos.

Al basarse en SSB_M/SSE_M , Hartigan funciona mejor cuando los clusters son compactos alrededor de un centro, parecidos a los que favorece k -medias. Puede ser menos adecuado para clusters alargados, no convexos o de formas irregulares.

4.7.1.3. Índice de Dunn

Bibliografía:

- Básica
 - [EMUL] IV. Internal Validation

EXAM=(2023S0.8)

El índice de **Dunn** compara la menor separación entre clústeres distintos con el mayor diámetro interno de los clústeres:

$$D = \frac{\text{distancia mínima entre clústeres distintos}}{\text{distancia máxima dentro de un mismo clúster}}$$

Interpretación:

- el numerador debe ser grande: interesa que los clústeres estén separados;
- el denominador debe ser pequeño: interesa que cada clúster sea compacto;
- por tanto, un valor alto de Dunn indica una buena agrupación.

Dunn se centra en los casos extremos: puesto que usa la mínima distancia entre clústeres y el máximo diámetro intraclúster, depende mucho del peor caso. Un solo punto atípico, un clúster muy disperso o dos puntos de grupos distintos muy cercanos pueden deteriorar mucho el índice.

4.7.1.4. Coeficiente silhouette

Bibliografía:

- Básica
 - Apartado 8.3.4 “Silhouette” de capítulo 8 “Aprendizaje No Supervisado” de libro de apuntes práctico.
 - [EMUL] IV. Internal Validation

EXAM=(2024J2.8)

El coeficiente **Silhouette** evalúa cada observación comparando su proximidad al clúster al que ha sido asignada con su proximidad al clúster alternativo más cercano.

Para una observación i :

- $a(i)$ es la distancia media desde i a las demás observaciones de su propio clúster;
- $b(i)$ es la menor distancia media desde i a las observaciones de cualquier otro clúster.

Su valor es:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

Interpretación:

Valor de $s(i)$	Interpretación
Cercano a 1	Observación bien asignada a su clúster
Cercano a 0	Observación situada cerca de la frontera entre clústeres
Negativo	Observación posiblemente mejor asignable a otro clúster

El coeficiente global es la media de los valores individuales:

$$S = \frac{1}{n} \sum_{i=1}^n s(i)$$

4.7.2. Evaluación de agrupamientos jerárquicos

Bibliografía:

- Básica
 - [EMUL] Subapartado “B. Hierarchical Methods” del apartado IV “Internal Validation”. Págs. 5-6.

EXAM=(2021J1.10,2025S0.2)

Para agrupamientos jerárquicos puede utilizarse el **coeficiente de correlación cofenética** (CPCC).

En un dendrograma, la distancia cofenética entre dos observaciones es la altura a la que ambas quedan unidas por primera vez en el mismo cluster.

El coeficiente cofenético compara:

- las disimilitudes originales entre observaciones;
- las disimilitudes representadas por el dendrograma.

Interpretación:

Un coeficiente cofenético alto indica que el dendrograma conserva razonablemente bien la estructura de disimilitudes original.

No existe una métrica perfecta para todos los problemas.

Situación	Métrica o enfoque útil
No hay etiquetas externas y se estudian particiones compactas	Silhouette, Dunn, Calinski-Harabasz, Hartigan
Se evalúa un dendrograma	Coeficiente cofenético

Situación	Métrica o enfoque útil
Existen etiquetas externas de referencia	Pureza, Rand, Jaccard, medida F , información mutua
Se comparan configuraciones o números de clusters	Métricas internas y evaluación relativa

Hay que tener precaución:

- una métrica basada en centroides o SSE puede favorecer a k -medias;
- una métrica de compactación puede valorar mal clusters no globulares detectados por DBSCAN;
- diferentes métricas pueden elegir soluciones diferentes.

Por tanto:

Conviene comparar varios algoritmos y varias métricas, buscando soluciones estables e interpretables.

4.8. Reglas de asociación

Introducción a las reglas de asociación

Bibliografía:

- Básica
 - Vídeo 8.15 “Reglas de asociación” de la práctica de la asignatura
- Complementaria
 - [ESL] 14.2 “Association rules” Págs. 487-503

Las **reglas de asociación** son técnicas de aprendizaje no supervisado que buscan relaciones frecuentes entre elementos o valores que aparecen conjuntamente en los datos.

Ejemplo típico:

Si una compra contiene pan y queso, también suele contener vino.

Una regla suele expresarse como:

antecedente -> consecuente

Por ejemplo:

pan, queso -> vino

Las medidas básicas son:

Medida	Significado
Soporte	Frecuencia con la que aparece conjuntamente la regla en los datos
Confianza	Frecuencia con la que aparece el consecuente cuando aparece el antecedente
<i>Lift</i>	Cuánto más frecuente es la asociación respecto a lo esperable si ambos eventos fueran independientes

No confundir con clustering:

Técnica	Qué descubre
Clustering	Grupos de observaciones similares
Reglas de asociación	Relaciones frecuentes entre elementos o variables

Algoritmo apriori

Bibliografía:

- Básica
 - Vídeo 8.16 “Algoritmo Apriori” de la práctica de la asignatura

Apriori es un algoritmo clásico para descubrir reglas de asociación.

Su idea principal es:

Si un conjunto de elementos no es frecuente, ningún conjunto mayor que lo contenga podrá ser frecuente.

A partir de esta propiedad, Apriori:

1. Busca conjuntos de elementos frecuentes, es decir, con soporte suficiente.
2. Descarta combinaciones que no alcanzan el soporte mínimo.
3. Genera reglas de asociación a partir de los conjuntos frecuentes encontrados.

Ejemplo:

Si {pan, queso} no aparece con suficiente frecuencia, no merece la pena explorar reglas basadas en {pan, queso, vino}.

Idea para recordar:

Apriori encuentra conjuntos frecuentes y, a partir de ellos, genera reglas de asociación; no forma clusters de observaciones.

Bibliografía

Bibliografía:

- Básica
 - [ESL] HASTIE, Trevor, TIBSHIRANI, Robert, FRIEDMAN, Jerome. Secciones 14.1 y 14.3 de The Elements of Statistical Learning. 2.^a ed. Springer, 2017.
 - [EMUL] Informe técnico Evaluation Metrics for Unsupervised Learning Algorithms
- Complementaria
 - [ANS] Capítulo 8 “Aprendizaje No Supervisado”, extraído de un libro sin identificar <https://agora.uned.es/mod/resource/view.php?id=704477>
 - [TSpC] LUXBURG, Ulrike von. A Tutorial on Spectral Clustering. Statistics and Computing, 17 (4), 2007.
 - [TSsC] VIDAL, René. A Tutorial on Subspace Clustering. Johns Hopkins University.
- FAQ

Licencia y atribución

License CC BY 4.0

Este trabajo está licenciado bajo la licencia **Creative Commons Atribución 4.0 Internacional**.

© 2026, Colaboradores de apuntes-muicd-uned.