

AAII - Tema 4: Aprendizaje no supervisado

En este tema se revisan técnicas de aprendizaje no supervisado.

4.1. Introducción al aprendizaje no supervisado

Bibliografía:

- Básica
 - [ESL] 14.1 “Introduction” Págs. 485-487
 - Presentación “ULAs” de la práctica de la asignatura
 - [ANS]

En el **aprendizaje no supervisado** (*unsupervised learning*) se dispone de observaciones descritas por variables de entrada, pero no existe una variable objetivo conocida ni etiquetas correctas que indiquen qué debe aprender el modelo.

Tipo de aprendizaje	Datos disponibles	Objetivo habitual
Supervisado	Variables de entrada X y respuesta conocida Y	Predecir Y a partir de X
No supervisado	Solo variables X	Descubrir estructura o patrones presentes en los datos

En aprendizaje supervisado puede pensarse que existe un “profesor”:

- el modelo produce una predicción;
- se conoce la respuesta correcta;
- puede medirse el error cometido mediante una función de pérdida.

En aprendizaje no supervisado se aprende **sin profesor**:

- no hay respuestas correctas para cada observación;
- no hay un error de predicción directamente observable;
- el objetivo es describir la estructura interna de los datos.

En términos generales, el aprendizaje no supervisado intenta inferir propiedades de la distribución de las variables observadas.

Dicho de forma práctica, busca responder preguntas como:

- ¿Existen grupos naturales de observaciones?
- ¿Hay variables que suelen comportarse conjuntamente?
- ¿Puede resumirse la información mediante menos dimensiones?
- ¿Existen patrones especialmente frecuentes en los datos?

ESL menciona, entre otras, las siguientes tareas no supervisadas:

Tarea	Idea
Componentes principales	Representar los datos mediante menos dimensiones
Reglas de asociación	Detectar valores o productos que aparecen conjuntamente con frecuencia
Análisis de grupos (cluster analysis)	Identificar regiones o grupos de observaciones similares
Modelos de mezclas	Representar los datos como mezcla de varios tipos de observaciones

En esta unidad, el interés principal estará en el **análisis de grupos o clustering**.

El **agrupamiento (clustering)** intenta dividir las observaciones en grupos de forma que:

- las observaciones del mismo grupo sean parecidas entre sí;
- las observaciones de grupos distintos sean suficientemente diferentes.

Ejemplo:

Disponemos de información sobre clientes, como gasto medio, frecuencia de compra y tipos de producto adquiridos, pero no tenemos etiquetas de cliente. Un algoritmo de agrupamiento puede intentar descubrir perfiles diferenciados a partir de esas variables.

Vocabulario:

En los apuntes de la asignatura, el agrupamiento se presenta como una forma de **clasificación no supervisada**: el algoritmo asigna cada observación a un grupo o clase, pero esas clases no son conocidas durante el entrenamiento.

En aprendizaje supervisado existe una forma clara de medir el éxito:

- se comparan las predicciones con las respuestas reales;
- se calcula una pérdida o tasa de error;
- pueden compararse modelos mediante validación cruzada.

En aprendizaje no supervisado esto es más difícil:

- normalmente no existe una agrupación correcta conocida;
- no puede calcularse directamente un error de predicción respecto a una verdad observada;

- distintos algoritmos pueden descubrir estructuras distintas y razonables.

ESL destaca que la validez de las conclusiones obtenidas mediante algoritmos no supervisados es difícil de comprobar directamente. Por ello, la calidad de los resultados suele valorarse mediante criterios indirectos o heurísticos.

Un mismo conjunto de datos puede mostrar estructuras distintas según cómo se analice.

Por ejemplo, unos clientes podrían agruparse:

- por nivel de gasto;
- por frecuencia de compra;
- por preferencias de producto;
- por una combinación de esos criterios.

El resultado puede depender de:

- las variables utilizadas;
- la escala de esas variables;
- la medida de similitud o distancia;
- el algoritmo de agrupamiento;
- sus parámetros, como el número de grupos;
- la métrica utilizada para evaluar el resultado.

Por eso, en aprendizaje no supervisado no siempre existe una única solución “correcta”.

Dado que no suele existir una etiqueta real con la que comparar directamente las soluciones, no es recomendable seleccionar un modelo utilizando una única técnica o una única medida de evaluación.

La práctica recomendable es:

Comparar los resultados obtenidos mediante diferentes algoritmos y diferentes métricas de evaluación, comprobando además si la estructura encontrada resulta interpretable y útil para el problema.

Al analizar una solución de agrupamiento conviene comprobar:

- si distintos algoritmos encuentran grupos parecidos;
- si el resultado es estable al cambiar parámetros;
- si distintas métricas favorecen la misma solución;
- si los grupos tienen sentido desde el punto de vista del problema estudiado.

No debe seleccionarse automáticamente el modelo:

- más rápido;
- que produzca el número de grupos esperado intuitivamente;
- que obtenga buen resultado en una única métrica;
- que se haya probado en primer lugar.

4.2. Análisis de grupos

Bibliografía:

- Básica
 - [ESL 14.3 “Cluster Analysis”] Págs. 501-527
- Definición de clustering.
- Objetivo: alta similitud intra-cluster y baja similitud inter-cluster.
- Idea de grupos naturales frente a segmentación.
- Importancia central de definir qué significa similitud o diferencia.

El objetivo del agrupamiento es dividir los datos de forma que exista:

- **alta similitud intra-cluster**: las observaciones del mismo grupo se parecen entre sí;
- **baja similitud inter-cluster**: las observaciones pertenecientes a grupos distintos son diferentes entre sí.

Por tanto:

La clasificación no supervisada o clustering busca agrupar datos similares en las mismas clases y separar datos diferentes en clases distintas.

Ejemplo:

Si disponemos de datos sobre clientes, como frecuencia de compra, gasto medio y productos adquiridos, un método de clustering puede intentar descubrir perfiles de clientes sin que previamente exista una etiqueta que indique a qué perfil pertenece cada uno.

Idea de examen:

El objetivo principal de la clasificación no supervisada es agrupar datos similares en las mismas clases y separar datos diferentes en clases distintas.

Aunque la pregunta utilice la expresión **clasificación no supervisada**, en este contexto se refiere a **agrupamiento**: las clases o grupos no están definidos antes de aplicar el algoritmo.

Todo método de clustering necesita alguna forma de decidir cuándo dos observaciones son parecidas o diferentes.

- Una **similitud** toma valores altos cuando dos observaciones se parecen mucho.
- Una **disimilitud** o distancia toma valores altos cuando dos observaciones son muy diferentes.

Un algoritmo de clustering no sabe por sí mismo qué significa que dos objetos sean parecidos: esa decisión depende de las variables elegidas, de la medida utilizada y del significado del problema.

Por ejemplo, para agrupar clientes podría ser importante:

- que tengan un gasto parecido;
- que compren productos similares;
- que visiten con frecuencia parecida;
- o alguna combinación de estos criterios.

Idea clave:

En clustering, definir adecuadamente la similitud o disimilitud puede ser tan importante o más que elegir el algoritmo de agrupamiento.

A veces los datos contienen grupos claramente separados; en ese caso puede hablarse de **grupos naturales**.

Otras veces los grupos se solapan o no están claramente separados. En ese caso, el algoritmo sigue produciendo una partición, pero puede ser más correcto interpretarla como una **segmentación** útil de los datos que como el descubrimiento de clases naturales indiscutibles.

Por tanto:

- que un algoritmo produzca grupos no garantiza que esos grupos existan de forma clara en los datos;
- diferentes métodos o medidas de disimilitud pueden producir particiones diferentes;
- la interpretación del resultado sigue dependiendo del contexto del problema.

En muchos problemas se recomienda **estandarizar** las variables antes de calcular distancias, especialmente si unas variables tienen escalas mucho mayores que otras.

Estandarizar suele significar transformar cada variable para que tenga media 0 y varianza 1.

La motivación es sencilla:

- si una variable toma valores entre 0 y 100000;
- y otra toma valores entre 0 y 1;
- la primera puede dominar casi por completo una distancia numérica.

Sin embargo, en clustering estandarizar **no siempre es lo correcto**.

Si una variable presenta una gran variabilidad precisamente porque separa claramente los grupos naturales, reducir su influencia mediante estandarización puede ocultar la estructura que queremos descubrir.

Ejemplo conceptual:

Variable	Situación
X_1	Separa claramente dos grupos naturales
X_2	Tiene variación, pero no ayuda a distinguir grupos

Si se fuerza a ambas variables a influir igual en la distancia, X_2 puede ganar demasiada importancia y dificultar que el algoritmo detecte la separación real producida por X_1 .

Idea de examen:

Estandarizar las variables para darles la misma importancia en el cálculo de la disimilitud puede empeorar la capacidad del algoritmo para distinguir grupos naturales.

Afirmación	Correcta o incorrecta	Motivo
Clustering agrupa observaciones similares	Correcta	Es su objetivo principal
Clustering utiliza categorías predefinidas como respuesta correcta	Incorrecta	Eso corresponde a clasificación supervisada
La disimilitud elegida influye en los grupos obtenidos	Correcta	El algoritmo agrupa según esa definición
Siempre es obligatorio estandarizar todas las variables	Incorrecta	Puede ocultar variables que separan grupos naturales
Todos los algoritmos encontrarán los mismos clusters	Incorrecta	Depende del método, distancia y parámetros

4.3. Medidas de similitud y disimilitud

Los algoritmos de clustering agrupan observaciones según una definición de qué significa que dos objetos sean **parecidos** o **diferentes**.

- Una **similitud** es mayor cuanto más parecidos son dos objetos.
- Una **disimilitud** es mayor cuanto más diferentes son dos objetos.
- Una **distancia** es un tipo particular de disimilitud que cumple propiedades matemáticas adicionales.

La idea fundamental es:

El algoritmo agrupa según la medida que se le proporcione; cambiar la disimilitud puede cambiar completamente los clusters obtenidos.

Por ello, la elección de la medida de disimilitud debe depender del tipo de variables y del significado real del problema.

4.3.1. Matrices de proximidad

- Datos representados mediante similitudes o disimilitudes entre pares de objetos.
- Matriz de proximidades.
- Diferencia básica entre similitud y disimilitud.

Bibliografía:

- [ESL] 14.3.1 “Proximity Matrixes” Págs. 503

En algunos problemas no se dispone directamente de variables descriptivas para cada objeto, sino de una medida de proximidad entre cada par de objetos.

Estas relaciones pueden organizarse en una **matriz de proximidad**.

Si tenemos N objetos, la matriz de disimilitudes es una matriz $N \times N$:

\$\$

$$D = (d_{ii'})$$

\$\$

donde $d_{ii'}$ representa la disimilitud entre los objetos i e i' .

Ejemplo:

Objeto	A	B	C
A	0	2	8
B	2	0	6
C	8	6	0

En este ejemplo:

- A y B son relativamente parecidos, porque su disimilitud es pequeña;
- A y C son más diferentes, porque su disimilitud es mayor.

En una matriz de disimilitudes se espera habitualmente que:

- la disimilitud sea no negativa;
- la disimilitud de un objeto consigo mismo sea cero;
- la matriz sea simétrica, es decir, $d_{ii'} = d_{i'i}$.

Concepto	Interpretación
Similitud alta	Los objetos se parecen mucho
Disimilitud alta	Los objetos son muy diferentes

Concepto	Interpretación
Diagonal de una matriz de disimilitud	Vale 0, porque un objeto no difiere de sí mismo

Si inicialmente se dispone de similitudes, pueden transformarse en disimilitudes mediante una función que disminuya cuando aumenta la similitud.

Idea para recordar:

Una matriz de proximidad contiene la relación entre pares de objetos y puede utilizarse directamente como entrada de algunos algoritmos de clustering.

4.3.2. Disimilitudes según el tipo de atributo

Bibliografía:

- [ESL] 14.3.2 “Dissimilarities Based on Attributes” Pág. 503-504

Lo más habitual es que cada observación esté descrita por varios atributos o variables.

Para calcular la disimilitud entre dos observaciones, primero debe decidirse cómo medir su diferencia en cada atributo.

La medida adecuada depende del tipo de variable:

Tipo de variable	Ejemplo	Forma habitual de medir diferencia
Cuantitativa	Edad, peso, ingresos	Diferencia absoluta o diferencia cuadrática
Ordinal	Malo, regular, bueno, excelente	Convertir el orden a una escala numérica ordenada
Categórica	Color, país, tipo de producto	Igual o distinto, o costes específicos entre categorías

Las variables **cuantitativas** toman valores numéricos para los que tiene sentido medir diferencias.

Dos medidas habituales son:

Medida	Expresión para una variable	Característica
Diferencia absoluta	$\ x_i - x_{i'}\ $	Trata las diferencias de forma proporcional
Diferencia cuadrática	$(x_i - x_{i'})^2$	Penaliza especialmente las diferencias grandes

Ejemplo, si comparamos los valores 2 y 5:

- diferencia absoluta: 3;
- diferencia cuadrática: 9.

La diferencia cuadrática da más importancia a valores muy alejados y, por ello, puede ser más sensible a valores atípicos.

Las variables **ordinales** tienen categorías con un orden natural, pero las distancias entre categorías no están necesariamente definidas.

Ejemplos:

- bajo, medio, alto;
- suspenso, aprobado, notable, sobresaliente;
- muy insatisfecho, insatisfecho, neutral, satisfecho, muy satisfecho.

Una estrategia habitual consiste en sustituir las categorías por valores ordenados y tratarlas después como variables cuantitativas.

Ejemplo:

Categoría	Valor ordenado
Bajo	1
Medio	2
Alto	3

Lo importante es conservar el **orden** entre categorías.

Las variables **categóricas** o nominales tienen valores diferentes, pero sin un orden natural.

Ejemplos:

- rojo, verde, azul;
- Madrid, Sevilla, Valencia;
- tarjeta, efectivo, transferencia.

La medida más sencilla consiste en asignar:

- disimilitud 0 si los valores coinciden;
- disimilitud 1 si los valores son distintos.

Valor del objeto 1	Valor del objeto 2	Disimilitud
Rojo	Rojo	0
Rojo	Azul	1

En algunos problemas puede tener sentido definir diferencias distintas entre categorías. Por ejemplo, en medios de transporte, bicicleta y patinete podrían considerarse más próximos que bicicleta y avión.

Idea para recordar:

No existe una única distancia válida para todos los datos: las variables numéricas, ordinales y categóricas requieren tratamientos distintos.

4.3.3. Disimilitud global entre objetos y ponderación de atributos

Bibliografía:

- [ESL] 14.3.3. Págs. 505-507

Cuando una observación tiene varios atributos, la disimilitud total entre dos objetos debe combinar las diferencias calculadas en cada variable.

Sea $d_j(x_{ij}, x_{i'j})$ la disimilitud entre dos observaciones en el atributo j . La disimilitud global puede calcularse mediante una combinación ponderada:

\$\$

$$D(x_i, x_{i'}) = \sum_{j=1}^p w_j d_j(x_{ij}, x_{i'j})$$

\$\$

donde:

- p es el número de atributos;
- w_j es el peso asignado al atributo j ;
- un peso mayor hace que ese atributo influya más en la formación de clusters.

Los pesos suelen normalizarse para que sumen 1:

\$\$

$$\sum_{j=1}^p w_j = 1$$

\$\$

La elección de pesos no debe hacerse automáticamente: debe reflejar qué diferencias son realmente importantes en el contexto del problema.

Supongamos que agrupamos clientes mediante:

- gasto anual;
- distancia a una tienda.

Si el objetivo es diseñar ofertas según valor económico, puede interesar que el gasto tenga más peso que la distancia.

Variable	Peso posible
Gasto anual	0.8
Distancia a tienda	0.2

En cambio, si el objetivo es organizar rutas de reparto, la distancia podría ser más importante.

Por tanto:

La influencia adecuada de cada atributo depende del objetivo del análisis, no solo de los números disponibles.

Aunque se asignen pesos iguales, las variables no tienen necesariamente la misma influencia.

Ejemplo:

Variable	Rango aproximado
Edad	18 a 80
Ingresos anuales	10000 a 200000

Si se utiliza distancia euclídea sin transformar los datos, las diferencias de ingresos pueden dominar casi totalmente la distancia, simplemente porque sus valores numéricos son mayores.

En variables cuantitativas y utilizando distancia cuadrática, la influencia de una variable está relacionada con su varianza:

- variables con mayor varianza tienden a influir más;
- variables con menor varianza tienden a influir menos.

La **estandarización** transforma normalmente cada variable para que tenga media 0 y varianza 1.

Su finalidad habitual es evitar que una variable domine la disimilitud únicamente por tener una escala numérica mayor.

Ejemplo:

Situación	Posible utilidad de estandarizar
Ingresos medidos en euros y edad medida en años	Evitar que ingresos domine solo por su escala
Variables expresadas en unidades arbitrariamente diferentes	Hacer sus contribuciones más comparables

Sin embargo, en clustering estandarizar no siempre mejora el resultado.

Puede ocurrir que una variable tenga mucha variación porque es precisamente la que separa claramente los grupos naturales.

Ejemplo conceptual:

Variable	Papel en los grupos
X_1	Separa claramente dos grupos
X_2	Varía, pero no distingue grupos

Si se estandarizan ambas variables para que influyan por igual, puede reducirse artificialmente el peso de X_1 y aumentarse el de X_2 . Como consecuencia, los grupos pueden volverse más difíciles de detectar.

ESL ilustra precisamente este problema: en los datos originales se distinguen dos grupos bien separados, pero tras estandarizar las variables esa separación queda oscurecida.

Idea de examen:

Estandarizar las variables para darles la misma importancia al calcular la disimilitud puede empeorar la capacidad del algoritmo para distinguir grupos naturales presentes en los datos.

Si alguna observación tiene valores ausentes, el cálculo de la disimilitud debe adaptarse.

Opciones habituales:

- calcular la disimilitud utilizando solo los atributos observados en ambos objetos;
- imputar valores ausentes mediante la media o la mediana de la variable;
- en variables categóricas, tratar “ausente” como una categoría adicional cuando tenga sentido.

Los valores ausentes no constituyen un algoritmo de clustering diferente:

Afectan a cómo se calcula la disimilitud entre observaciones.

4.4. Familias de métodos de agrupamiento

Bibliografía:

- Básica
 - [ESL] 14.3.4 “Clustering Algorithms”. Págs. 507.
 - Apartado 4. “Métodos de clustering de la presentación”ULAs” de la práctica de la asignatura.
 - Vídeos 8.2 y 8.3 “Algoritmos clustering” de la práctica de la asignatura.

No todos los métodos entienden un clúster de la misma manera:

- algunos buscan particiones que minimicen distancias internas;
- algunos suponen que los datos proceden de varias distribuciones probabilísticas;
- algunos construyen una jerarquía de agrupaciones;
- algunos identifican regiones con alta densidad de observaciones.

Por tanto:

Diferentes familias de clustering pueden encontrar soluciones distintas porque utilizan ideas diferentes sobre qué constituye un grupo.

Los métodos de agrupamiento intentan dividir las observaciones en grupos de forma que las disimilitudes dentro de cada grupo sean pequeñas y las disimilitudes entre grupos sean grandes. Existen distintas taxonomías de familias de métodos de agrupamiento.

4.4.1. Taxonomía de Hastie et al

Bibliografía:

- Básica
 - [ESL] 14.3.4 “Clustering Algorithms”. Págs. 507.

=EXAM(2024J2.7)

[ESL] presenta tres grandes tipos de algoritmos de clustering, siendo la única que se ha empleado en algún examen de la asignatura:

Familia	Idea de clúster	Métodos representativos
Algoritmos combinatorios (<i>combinatorial algorithms</i>)	Agrupar las observaciones de forma directa al margen de cualquier distribución, asignando cada dato a un grupo sin suponer un modelo probabilístico (no paramétrico).	k -medias, k -medoides
Modelos de mezclas (<i>mixture modeling</i>)	Definen la densidad de probabilidad en el espacio de datos como una suma (mezcla) de distribuciones paramétricas, asumiendo que los datos provienen de una distribución distinta por cada cluster.	Mezclas gaussianas
Búscadores de modos (<i>mode seekers</i>)	Buscan máximos o regiones de alta densidad en la distribución de los datos. Están basados en la estimación no paramétrica de densidades de probabilidad en el espacio de datos.	MeanShift, DBSCAN

4.4.2. Taxonomía de Google Developers

Bibliografía:

- Básica
 - Apartado 4. “Métodos de clustering de la presentación”ULAs” de la práctica de la asignatura.
 - Vídeos 8.2 y 8.3 “Algoritmos clustering” de la práctica de la asignatura.
- Complementaria
 - * Clustering Algorithms. Google Developers. <https://developers.google.com/machine-learning/clustering/clustering-algorithms>
 - * Dongkuan Xu, Yingjie Tian. A Comprehensive Survey of Clustering Algorithms. Springer Nature, 2015. <https://link.springer.com/article/10.1007/s40745-015-0040-1>

Los apuntes prácticos de la asignatura emplean una taxonomía alternativa que coincide con la planteada en Google Developers.

Familia	Idea de clúster	Métodos representativos
Basados en centroides	Conjunto de observaciones asignadas a grupos minimizando disimilitud interna	k -medias
Jerárquicos	Grupo situado dentro de una jerarquía de fusiones o divisiones	Aglomerativo, divisivo, Diana, Agnes, BIRCH, ROCK
Basados en densidad	Región del espacio con alta concentración de observaciones	DBSCAN, Mean Shift, OPTICS, DenClue
Basados en distribución	Componente de una distribución mezcla que genera parte de los datos	Mezclas gaussianas, COBWEB

Familia	¿Requiere fijar K inicialmente?	Forma de los grupos	Elemento característico
Basados en centroides	Sí	Preferentemente grupos compactos y aproximadamente globulares	Centroides
Jerárquicos	No necesariamente al construir la jerarquía	Depende de la disimilitud y del enlace	Dendrograma
Basados en densidad	No necesariamente como número directo de clusters	Puede detectar formas arbitrarias	Regiones densas y, en DBSCAN, ruido
Basados en distribución	Habitualmente sí, número de componentes	Grupos modelados mediante distribuciones	Probabilidades de pertenencia

No existe una familia universalmente mejor.

Situación aproximada	Familia que puede resultar natural
Se buscan K grupos compactos alrededor de centros	Basados en centroides
Interesa observar grupos a distintos niveles	Jerárquicos
Hay ruido o clusters con formas irregulares	Basados en densidad
Se desea una interpretación probabilística de pertenencia	Basados en distribución

La elección final también depende de:

- la medida de disimilitud;
- la escala y tipo de las variables;
- el número de clusters esperado;
- la presencia de ruido;
- la utilidad práctica de los grupos obtenidos.

4.4.2.1. Métodos basados en centroides Los métodos basados en centroides asignan cada observación a uno y solo un clúster, buscando una partición que haga que las observaciones del mismo grupo sean próximas entre sí.

Su criterio típico consiste en minimizar la disimilitud dentro de los clusters.

Características:

- trabajan directamente con las observaciones o con sus disimilitudes;
- no suponen que los datos procedan de una distribución probabilística concreta;
- normalmente requieren indicar de antemano el número de clusters K ;
- encontrar la mejor partición examinando todas las posibilidades es impracticable en conjuntos de datos normales.

Por ello, los métodos prácticos utilizan algoritmos iterativos que buscan una buena solución, aunque no garanticen el óptimo global.

Un ejemplo sería k -medias, donde el representante de cada clúster es el centroide o media de las observaciones del grupo.

k -medoides no pertenece a esta categoría, ya que el representante de cada cluster no es un centroide, sino un prototipo, donde el representante de cada cluster es una observación real elegida como centro del grupo.

Una posible categoría que englobe los métodos basados en centroides y en prototipos sería métodos de partición.

Los métodos de partición forman directamente K grupos intentando reducir la disimilitud interna.

4.4.2.2. Métodos basados en modelos probabilísticos

Los **métodos basados en modelos probabilísticos** suponen que las observaciones proceden de una población formada por varios componentes, y que cada componente representa un cluster.

El ejemplo principal del temario es la **mezcla de gaussianas**:

- cada cluster se representa mediante una distribución gaussiana;
- cada observación puede tener cierta probabilidad de pertenecer a cada cluster;
- la asignación puede ser blanda o probabilística, no necesariamente una decisión inmediata de pertenencia única.

Relación con k -medias:

Método	Tipo de asignación
k -medias	Dura: cada observación se asigna al centroide más cercano
Mezcla de gaussianas	Blanda: cada observación recibe probabilidades de pertenencia

Por ello:

Una mezcla de gaussianas puede entenderse como una generalización probabilística o versión blanda de k -medias.

4.4.2.3. Métodos jerárquicos Los **métodos jerárquicos** producen una organización de los datos en distintos niveles de agrupamiento.

En lugar de devolver únicamente una partición con K clusters, construyen una jerarquía que puede representarse mediante un **dendrograma**.

Existen dos enfoques principales:

Método jerárquico	Procedimiento
Aglomerativo	Comienza con una observación por cluster y va fusionando los grupos más próximos
Divisivo	Comienza con todos los datos en un único cluster y lo va dividiendo

Características:

- no requieren fijar inicialmente un único número de clusters;
- permiten inspeccionar soluciones con distinto nivel de detalle;

- el número final de grupos puede obtenerse cortando el dendrograma a una determinada altura;
- el resultado depende de cómo se mida la disimilitud entre grupos.

Idea para recordar:

El clustering jerárquico representa grupos anidados: puede estudiarse desde soluciones muy detalladas hasta soluciones más generales.

4.4.2.4. Métodos basados en densidad Los **métodos basados en densidad** interpretan un cluster como una región del espacio donde se acumulan muchas observaciones, separada de otras regiones por zonas con poca densidad.

Características:

- pueden detectar grupos con formas no globulares;
- no dependen necesariamente de representar cada cluster mediante un centroide;
- algunos pueden identificar observaciones aisladas como ruido o valores atípicos.

Ejemplos:

Método	Idea básica
DBSCAN	Expande clusters desde regiones con suficientes vecinos cercanos y puede marcar puntos como ruido
Mean Shift	Desplaza puntos o centros hacia máximos locales de densidad

DBSCAN es especialmente importante en la asignatura porque aparece en los materiales prácticos y ha sido objeto de pregunta de examen.

Idea para recordar:

Los métodos basados en densidad buscan regiones pobladas del espacio y pueden detectar clusters con formas que k -medias no modela bien.

4.5. Métodos de clasificación no supervisada

Bibliografía:

- [ESL] 14.3.5-14.3.12, Págs. 507-527

Se contemplan los siguientes métodos simples y clásicos de clasificación no supervisada:

- Agrupamiento combinatorio

- K-medias
- Mezcla de Gaussianas
- Cuantización de vectores
- K-mediods
- Agrupamiento jerárquico
 - Aglomerativo
 - Divisivo
- Agrupamiento basado en densidad
 - DBSCAN
 - Mean Shift

Quedan fuera del temario otros métodos más complejos, entre ellos:

- Clustering espectral
- Clustering en subespacios

Método	Idea principal
Agrupamiento combinatorio	Buscar una partición que minimice la disimilitud interna de los grupos
k -medias	Representar cada grupo mediante su media o centroide
Mezclas gaussianas	Modelar cada grupo mediante una distribución gaussiana y obtener pertenencias probabilísticas
Cuantización de vectores	Aplicar ideas de k -medias a compresión de señales o imágenes
k -medoides	Representar cada grupo mediante una observación real
Agrupamiento jerárquico	Construir una jerarquía de fusiones o divisiones de grupos
DBSCAN	Detectar regiones densas y marcar puntos aislados como ruido
Mean Shift	Buscar máximos locales de densidad desplazando centros hacia zonas densas

4.5.1. Agrupamiento combinatorio

Bibliografía:

- [ESL] 14.3.5 “Combinatorial Algorithms”
- Idea general de asignar observaciones a clusters minimizando disimilitud interna.
- Problema: explorar todas las particiones posibles es rápidamente impracticable.

Los **algoritmos de agrupamiento combinatorio** asignan cada observación a uno de K clusters sin suponer que los datos procedan de una distribución de probabilidad concreta.

Su objetivo es encontrar una partición en la que las observaciones del mismo grupo estén próximas entre sí.

Si $C(i)$ indica el cluster asignado a la observación i , una función objetivo natural es la dispersión interna de los grupos:

$$W(C) = \frac{1}{2} \sum_{k=1}^K \sum_{C(i)=k} \sum_{C(i')=k} d(x_i, x_{i'})$$

donde $d(x_i, x_{i'})$ es la disimilitud entre dos observaciones.

Interpretación:

- $W(C)$ es pequeña si los objetos del mismo cluster son parecidos;
- minimizar $W(C)$ equivale a buscar grupos internamente compactos;
- no se está minimizando la separación entre grupos, sino la dispersión **dentro** de cada grupo.

También puede pensarse en maximizar la separación entre grupos, porque la dispersión total de los datos permanece fija:

\$\$

$$T = W(C) + B(C)$$

\$\$

donde $B(C)$ representa la dispersión entre clusters.

El problema es que el número de particiones posibles crece enormemente con el número de observaciones. Examinar todas las asignaciones posibles solo es viable para conjuntos de datos muy pequeños.

Por eso:

Los algoritmos combinatorios prácticos utilizan búsquedas heurísticas o iterativas que exploran solo una pequeña parte de todas las particiones posibles.

Lo imprescindible para el test:

- Trabajan directamente con observaciones y disimilitudes.
- No necesitan definir una distribución probabilística de los datos.
- Buscan minimizar la dispersión interna de los clusters.
- La búsqueda exhaustiva de la mejor partición suele ser impracticable.

4.5.2. K-medias

Bibliografía:

- [ESL] 14.3.6 “K-means” Págs. 509-510
- Vídeo de la asignatura: 8.6. “k-Means”
- Vídeo 8.13 “Implementación de k-means” de la práctica de la asignatura

El algoritmo de ***k*-medias** (**k-means**) es un método combinatorio que representa cada cluster mediante su **centroide**, es decir, la media de las observaciones asignadas a ese grupo.

Se utiliza habitualmente con variables cuantitativas y distancia euclídea cuadrática.

El método necesita fijar previamente el número de clusters K .

Para cada cluster k , sea m_k su centroide. El algoritmo intenta minimizar la suma de distancias cuadráticas de cada observación al centroide de su grupo:

$$\sum_{k=1}^K \sum_{C(i)=k} \|x_i - m_k\|^2$$

Interpretación:

k -medias intenta construir K grupos compactos alrededor de K centroides.

El algoritmo alterna dos pasos:

1. **Asignación de observaciones:** cada observación se asigna al centroide más cercano.
2. **Actualización de centroides:** cada centroide se recalcula como la media de las observaciones que tiene asignadas.

Paso	Qué se modifica	Qué permanece fijo
Asignación	El codificador $C(i)$, es decir, el grupo de cada observación	Los centroides
Actualización	Las medias o centroides de cada grupo	Las asignaciones actuales

Ambos pasos disminuyen o mantienen la función objetivo. El proceso termina cuando las asignaciones dejan de cambiar.

Importante:

k -medias garantiza convergencia, pero no garantiza alcanzar el óptimo global; puede terminar en un óptimo local.

El resultado depende de los centroides iniciales.

- Una buena inicialización puede conducir a una partición adecuada.
- Una mala inicialización puede conducir a clusters peores.
- Una práctica habitual es ejecutar el algoritmo varias veces con inicializaciones diferentes y conservar la solución con menor coste.

k -medias funciona mejor cuando los clusters son aproximadamente compactos y globulares.

Puede funcionar mal cuando:

- existe mucho ruido o valores atípicos;
- los clusters tienen formas no globulares;
- los clusters tienen tamaños muy diferentes;
- los clusters tienen densidades muy diferentes;
- la distancia euclídea no representa adecuadamente la similitud relevante.

La distancia cuadrática da mucha influencia a observaciones muy alejadas, por lo que k -medias puede ser sensible a **outliers**.

La idea de k -medias puede generalizarse utilizando otras medidas de disimilitud y modificando la forma de obtener el representante o prototipo de cada cluster.

Por ejemplo:

Método	Representante del cluster	Robustez frente a valores atípicos
k -medias	Media	Menor
k -medianas	Mediana	Mayor
k -medoides	Observación real representativa	Mayor flexibilidad en disimilitudes

Por tanto:

Puede obtenerse una versión más robusta frente a valores atípicos sustituyendo la definición de los prototipos por otra adecuada a una métrica más robusta.

k -medias está estrechamente relacionado con el algoritmo EM aplicado a mezclas gaussianas.

- En mezclas gaussianas, una observación puede pertenecer parcialmente a distintos componentes mediante probabilidades.
- En k -medias, cada observación se asigna de forma dura al centroide más cercano.
- Cuando las gaussianas tienen covarianzas esféricas muy pequeñas, la asignación probabilística se vuelve prácticamente determinista y coincide con k -medias.

Por ello, para el test:

k -medias puede verse como una versión límite o simplificada de EM para mezclas gaussianas, basada en una búsqueda heurística local y no en la exploración exhaustiva de todas las particiones.

k -medias necesita que se especifique el número k .

4.5.3. Mezclas gaussianas

Bibliografía:

- [ESL] 14.3.7 de la práctica de la asignatura. Págs. 510-514.

Mezcla de gaussianas es la generalización probabilística del algoritmo de k -medias. En ella, una observación puede tener distinta probabilidad de pertenencia a cada cluster.

El clustering mediante **mezclas gaussianas** supone que los datos proceden de una mezcla de varias distribuciones gaussianas, cada una asociada a un cluster.

A diferencia de k -medias, una observación no se asigna inicialmente de forma absoluta a un único grupo. En su lugar, recibe una probabilidad de pertenencia a cada componente.

Método	Asignación de una observación
k -medias	Dura: pertenece al cluster con centroide más próximo
Mezcla gaussiana	Blanda: tiene una probabilidad de pertenecer a cada cluster

Ejemplo:

Cluster	Probabilidad de pertenencia de una observación
Grupo 1	0.75
Grupo 2	0.20
Grupo 3	0.05

La observación se asociaría principalmente al grupo 1, pero se conserva información sobre la incertidumbre.

Por eso:

Una mezcla de gaussianas es una generalización probabilística o blanda de k -medias.

Si las gaussianas tienen matrices de covarianza esféricas e iguales, proporcionales a la identidad, y su dispersión tiende a cero, las probabilidades de pertenencia se convierten en asignaciones prácticamente duras al centro más próximo.

Siguiendo la notación utilizada en el examen:

\$\$

$$= \mathbf{I}, \quad 0$$

\$\$

En ese caso, la mezcla de gaussianas coincide con k -medias.

4.5.4. Cuantización de vectores

Bibliografía:

- [ESL] 14.3.9 de la práctica de la asignatura. Págs. 514-515.

La **cuantización de vectores** (en inglés, *vector quantization*, VQ) aplica la idea de k -medias a problemas de compresión, especialmente de imágenes o señales.

Procedimiento conceptual:

1. Se dividen los datos en pequeños bloques representados como vectores.
2. Se agrupan esos vectores mediante k -medias.
3. Cada centroide representa un patrón prototipo o *codeword*.
4. Cada bloque original se sustituye por la referencia al prototipo más cercano.

Concepto	Significado
<i>Codebook</i>	Conjunto de centroides o prototipos
<i>Codeword</i>	Uno de los prototipos
Compresión	Sustituir muchos bloques similares por referencias al mismo prototipo

Cuantos menos prototipos se utilicen, mayor será la compresión, pero también puede aumentar la pérdida de calidad.

La cuantización de vectores utiliza centroides obtenidos mediante k -medias para representar de forma compacta muchos patrones similares.

4.5.5. K-medoides

Bibliografía:

- Básica
 - [ESL] 14.3.10 “K-medoids”. Págs. 515-518

El algoritmo de **k -medoides** (**k-medoids**) es una variante de k -medias en la que el representante de cada cluster no es la media, sino una observación real del propio grupo.

Método	Representante del cluster
k -medias	Centroide calculado como media
k -medoides	Observación real que minimiza la disimilitud con las demás del grupo

Ventajas de k -medoides:

- puede utilizar disimilitudes más generales que la distancia euclídea cuadrática;
- puede aplicarse cuando solo disponemos de una matriz de disimilitudes;
- suele ser menos sensible a valores atípicos que k -medias.

Inconveniente:

- tiene mayor coste computacional, porque elegir el medoide exige comparar observaciones dentro del cluster.

Procedimiento básico:

1. Seleccionar un medoide para cada cluster.
2. Asignar cada observación al medoide más próximo.
3. Recalcular qué observación debe ser el medoide de cada grupo.
4. Repetir hasta que las asignaciones no cambien.

Idea para recordar:

k -medoides generaliza la idea de k -medias utilizando observaciones reales como representantes y admitiendo disimilitudes más flexibles.

4.5.6. Agrupamiento jerárquico

Bibliografía:

- Básica

- [ESL] 14.3.12 “Hierarchical Clustering”. Págs. 520-528.
- Apartado “Clustering jerárquico” de la presentación “ULAs” de la práctica de la asignatura.
- Vídeo 8.7 “Clustering jerárquico” de la práctica de la asignatura.
- Vídeo 8.12 “Agglomerative” de la práctica de la asignatura.

El **agrupamiento jerárquico** construye una jerarquía de clusters en lugar de producir únicamente una partición final.

El resultado se representa mediante un **dendrograma**, un árbol en el que:

- las hojas representan observaciones individuales;
- las uniones representan agrupaciones de clusters;
- la altura de una unión refleja la disimilitud entre los grupos fusionados.

Una ventaja frente a k -medias es que no obliga a elegir inicialmente un único valor de K . El usuario puede cortar el dendrograma a distintas alturas para obtener diferentes números de clusters.

Existen dos enfoques principales:

Método	Inicio	Procedimiento
Aglomerativo	Cada observación es un cluster individual	Fusiona sucesivamente los clusters más próximos
Divisivo	Todos los datos forman un único cluster	Divide sucesivamente grupos en subgrupos

4.5.6.1. Agrupamiento jerárquico aglomerativo

El método **aglomerativo** trabaja de abajo hacia arriba:

1. Comienza con un cluster por cada observación.
2. Calcula qué dos clusters son más próximos.
3. Los fusiona en un único cluster.
4. Repite el proceso hasta que todos los datos forman un solo grupo.

Idea de examen:

El clustering jerárquico aglomerativo forma los clusters partiendo de cada dato como cluster único y fusionándolos sucesivamente.

En un dendrograma aglomerativo, los grupos muy parecidos se fusionan a baja altura. Los grupos más diferentes se fusionan más arriba.

Por tanto:

La altura de la unión refleja la disimilitud entre los clusters fusionados y, en la representación jerárquica habitual, crece a medida que avanzan las fusiones.

Ejemplo conceptual:

Altura de fusión	Interpretación
Baja	Grupos muy similares
Alta	Grupos más diferentes

Para fusionar clusters hay que definir cómo medir la disimilitud entre dos grupos completos.

Criterio	Cómo mide la distancia entre dos clusters
Single linkage	Distancia entre la pareja de observaciones más próxima
Complete linkage	Distancia entre la pareja de observaciones más alejada
Average linkage	Media de las distancias entre observaciones de ambos grupos

Single linkage considera que dos clusters son próximos si existe al menos una pareja de puntos, uno de cada cluster, que esté muy próxima.

Esto puede provocar el fenómeno de **encadenamiento (chaining)**:

- puntos o grupos se unen mediante una cadena de observaciones próximas;
- el cluster resultante puede ser largo y poco compacto;
- algunos puntos del mismo cluster pueden estar muy alejados entre sí.

Idea de examen:

El problema de **chaining** aparece en el agrupamiento jerárquico aglomerativo con criterio **single linkage**.

Complete linkage exige que los elementos más alejados de dos grupos no estén demasiado separados. Por ello, tiende a producir clusters más compactos.

Average linkage utiliza la distancia media entre los elementos de ambos grupos y representa una solución intermedia entre los extremos de **single** y **complete linkage**.

Criterio	Tendencia principal
Single linkage	Puede producir encadenamiento
Complete linkage	Favorece clusters compactos
Average linkage	Compromiso entre ambos

4.5.6.2. Agrupamiento jerárquico divisivo

El método **divisivo** trabaja de arriba hacia abajo:

1. Comienza con todos los datos en un solo cluster.
2. Divide uno de los clusters existentes en dos grupos.
3. Repite la división recursivamente.

Puede ser útil si interesa especialmente obtener un número pequeño de grupos generales, pero se estudia y utiliza menos que el enfoque aglomerativo.

4.5.7. Agrupamiento basado en densidad

Bibliografía:

- Básica
 - Vídeo 8.8 “Métodos basados en densidad” de la práctica de la asignatura

Los métodos de **agrupamiento basado en densidad** interpretan un cluster como una región del espacio con alta concentración de observaciones, separada de otros grupos por regiones poco pobladas.

A diferencia de k -medias, no necesitan representar cada cluster mediante un centroide ni asumir que los grupos sean aproximadamente esféricos.

Características:

- pueden detectar clusters con formas arbitrarias;
- pueden manejar ruido o valores atípicos;
- dependen de parámetros relacionados con la densidad;
- resultan adecuados cuando los clusters no forman “bolas” alrededor de centroides.

4.5.7.1. DBSCAN Bibliografía:

- Básica
 - Apartado 3 “DBSCAN” de la sección “Métodos basados en densidad” de la presentación “ULAs” de la práctica de la asignatura.

=EXAM(AAII.EX.2025J2)

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) es un método basado en densidad que forma clusters conectando observaciones situadas en regiones suficientemente pobladas.

Sus parámetros fundamentales son:

Parámetro	Significado
ε o <code>eps</code>	Radio utilizado para definir el vecindario de un punto
<code>min_samples</code>	Número mínimo de observaciones requerido para considerar una región suficientemente densa

Conceptos básicos:

Tipo de punto	Idea
Punto núcleo	Tiene suficientes vecinos dentro de su radio ε
Punto frontera	Está próximo a un núcleo, pero no tiene suficientes vecinos por sí mismo
Ruido	No queda conectado a ninguna región densa

Ventajas principales frente a k -medias:

DBSCAN	k -medias
No obliga a fijar previamente K	Requiere indicar K
Puede detectar clusters con formas arbitrarias	Funciona mejor con grupos compactos o globulares
Puede identificar ruido	Todos los puntos suelen asignarse a algún cluster

Idea de examen:

Una ventaja de DBSCAN es que no asume clusters esféricos ni obliga a definir previamente el número K de clusters.

4.5.7.2. Mean Shift Bibliografía

- Básica
 - Vídeo 8.14 Mean Shift

Mean Shift es un método basado en densidad que busca los máximos locales o **modos** de la densidad de los datos.

La idea básica es:

1. Situar puntos o centros en el espacio de características.
2. Calcular hacia qué dirección se concentra una mayor densidad de observaciones.
3. Desplazar iterativamente cada centro hacia esa región más densa.
4. Considerar que los centros que llegan al mismo máximo representan un mismo cluster.

Su parámetro principal es el ancho de banda (**bandwidth**), que controla el tamaño de la región utilizada para estimar la densidad.

bandwidth	Efecto aproximado
Pequeño	Puede detectar muchos máximos y producir más clusters
Grande	Suaviza la densidad y puede fusionar clusters

Mean Shift agrupa buscando máximos de densidad; DBSCAN agrupa conectando regiones densas y puede etiquetar puntos como ruido.

4.6. Cuestiones prácticas en agrupamiento

4.6.1. Inicialización y óptimos locales

- Básica
 - [ESL] 14.3.11 “Practical Issues”. Págs. 518-520.

Métodos iterativos como ***k*-medias** y ***k*-medoides** necesitan una configuración inicial, normalmente K centros iniciales.

En *k*-medias, cada iteración reduce o mantiene la dispersión interna de los clusters, por lo que el algoritmo termina convergiendo. Sin embargo, solo explora una parte de las particiones posibles:

k-medias converge, pero puede hacerlo a un óptimo local y no al óptimo global.

Como el resultado puede depender de los centros iniciales, una práctica habitual es:

1. Ejecutar el algoritmo varias veces con inicializaciones diferentes.
2. Comparar la función objetivo obtenida en cada ejecución.
3. Conservar la solución con menor dispersión interna.

Una inicialización sencilla consiste en elegir aleatoriamente K observaciones como centros iniciales.

Idea para recordar:

Una mala inicialización puede producir clusters peores; varias inicializaciones reducen ese riesgo, pero no garantizan encontrar el óptimo global.

4.6.2. Selección del número de clusters

Bibliografía:

- Básica
 - [ESL] 14.3.11 “Practical Issues”. Págs. 518-520.
 - Vídeo 8.9 “Determinar clusters”
 - Vídeo 8.11 “Técnicas para determinar clusters”

Métodos como ***k*-medias** y ***k*-medoides** necesitan indicar previamente el número de clústeres K .

Si se aumenta K , la disimilitud interna de los grupos tiende a disminuir:

- con más clústeres, cada grupo contiene menos observaciones;
- las observaciones pueden quedar más próximas a su centro o representante;
- por tanto, elegir el K que simplemente minimiza la disimilitud llevaría a usar demasiados grupos.

El **criterio del codo** consiste en ejecutar el método para distintos valores de K y observar la disimilitud intra-grupo W_K :

- mientras se estén separando grupos naturales, aumentar K produce descensos importantes de W_K ;
- cuando los grupos principales ya se han separado, añadir más clústeres produce mejoras pequeñas;
- se selecciona el valor de K a partir del cual la reducción deja de ser significativa.

El número de grupos puede estimarse como el valor a partir del cual aumentar K ya no produce descensos significativos en la disimilitud intra-grupo.

También puede utilizarse el **estadístico Gap**, que compara la reducción observada de la disimilitud interna con la esperable en datos sin una estructura clara de grupos.

La elección sigue siendo heurística: puede no existir un codo claro y conviene contrastar la solución con otras métricas e interpretación del problema.

4.7. Evaluación de agrupamientos

Bibliografía:

- Básica

– [EMUL]

Evaluar un agrupamiento es más difícil que evaluar una clasificación supervisada, porque normalmente no se dispone de etiquetas verdaderas que indiquen cuál es la partición correcta.

Una solución de agrupamiento suele considerarse buena cuando presenta:

- **alta cohesión:** los elementos del mismo cluster están próximos entre sí;
- **alta separación:** los elementos de clusters diferentes están alejados entre sí.

Sin embargo, no existe una única métrica universalmente adecuada para todos los algoritmos y todos los tipos de clusters.

La evaluación de clustering debe realizarse comparando varias métricas y, cuando sea posible, buscando soluciones estables entre distintos algoritmos y configuraciones.

Las medidas de evaluación pueden clasificarse en:

Tipo de evaluación	Qué utiliza	Cuándo puede aplicarse
Interna	Solo los datos y los clusters obtenidos	Cuando no existen etiquetas externas
Externa	Una partición o etiquetas de referencia	Cuando existe información externa disponible
Relativa	Compara soluciones obtenidas con distintos parámetros o algoritmos	Para elegir configuraciones o número de clusters

Además, pueden utilizarse pruebas estadísticas para comprobar si los datos muestran realmente una tendencia de agrupamiento o si la estructura observada podría ser compatible con datos aleatorios.

La **evaluación interna** valora la calidad de los clusters utilizando únicamente la información disponible en los propios datos.

Sus dos conceptos fundamentales son:

Concepto	Significado	En una buena agrupación
Cohesión	Proximidad entre observaciones del mismo cluster	Debe ser alta
Separación	Distancia entre observaciones o centros de clusters diferentes	Debe ser alta

En términos de disimilitud:

- una buena cohesión implica distancias pequeñas dentro de cada cluster;
- una buena separación implica distancias grandes entre clusters.

Dos cantidades básicas son:

Medida	Significado	Valor deseable
SSE o SSW	Suma de errores cuadrados dentro de los clusters	Pequeño
SSB	Suma de cuadrados entre clusters	Grande

La **suma de errores cuadrados intragrupo** (SSE) mide cuánto se alejan las observaciones del representante de su propio cluster.

La **suma de cuadrados entre grupos** (SSB) mide cuánto se separan los clusters entre sí.

Por tanto:

Una buena agrupación tiende a presentar SSE pequeña y SSB grande.

Advertencia:

Las métricas basadas en SSE favorecen naturalmente a métodos como k -medias, porque ese algoritmo se construye precisamente minimizando la suma de errores cuadrados. Pueden ser menos adecuadas para evaluar métodos basados en densidad como DBSCAN.

La **evaluación externa** compara los clusters encontrados con una partición de referencia externa, por ejemplo:

- etiquetas conocidas que no se utilizaron durante el agrupamiento;

- la clasificación proporcionada por un experto;
- el resultado de otro método que se toma como referencia.

Algunas medidas externas son:

Familia	Ejemplos
Correspondencia entre clusters y clases	Pureza, precisión, recall, medida F
Comparación de pares de observaciones	Índice de Rand, Jaccard, Fowlkes-Mallows
Teoría de la información	Entropía, información mutua

La evaluación externa no siempre está disponible, porque el objetivo habitual del aprendizaje no supervisado es precisamente trabajar sin etiquetas conocidas.

La **evaluación relativa** compara varios agrupamientos obtenidos:

- con distintos algoritmos;
- con diferentes valores de sus parámetros;
- con distintos números de clusters.

Por ejemplo, puede utilizarse para comparar soluciones de k -medias obtenidas con diferentes valores de K .

Esta idea conecta con el criterio del codo:

Se buscan configuraciones a partir de las cuales aumentar la complejidad ya no produce mejoras significativas en la calidad del agrupamiento.

4.7.1. Índices internos combinados de evaluación

Existen medidas que intentan combinar en un único valor la cohesión y la separación de los clusters.

Índice	Idea principal	Valor deseable
Calinski-Harabasz	Comparar separación entre clusters con dispersión interna, corregidas por grados de libertad	Alto
Hartigan	Relación logarítmica entre separación y dispersión interna	Alto

Índice	Idea principal	Valor deseable
Dunn	Comparar la mínima separación entre clusters con el máximo diámetro interno	Alto
Silhouette	Comparar, para cada observación, su proximidad al propio cluster con su proximidad al cluster alternativo más cercano	Alto

4.7.1.1. Índice de Calinski-Harabasz

El índice de **Calinski-Harabasz** relaciona la dispersión entre clusters con la dispersión dentro de los clusters, ajustando ambas cantidades por grados de libertad.

En la notación utilizada en EMUL:

$$CH = \frac{SSB_M/(M-1)}{SSE_M/M}$$

donde:

- M es el número de clusters;
- SSB_M mide la dispersión o separación entre clusters;
- SSE_M mide la dispersión interna de los clusters.

Interpretación:

Un valor alto de Calinski-Harabasz indica clusters bien separados y con poca dispersión interna.

No confundir:

La fórmula basada en el cociente de SSB y SSE corregido por grados de libertad corresponde a **Calinski-Harabasz**, no a Hartigan.

4.7.1.2. Índice de Hartigan

Según EMUL, el índice de **Hartigan** se define como el logaritmo del cociente entre la suma de cuadrados entre clusters y la suma de errores cuadrados dentro de los clusters:

$$H = \log \left(\frac{SSB_M}{SSE_M} \right)$$

Interpretación:

- SSB_M grande indica clusters alejados entre sí;
- SSE_M pequeña indica clusters internamente compactos;
- un valor alto de H indica una mejor separación relativa respecto a la dispersión interna.

4.7.1.3. Índice de Dunn

El índice de **Dunn** compara la menor separación entre clusters distintos con el mayor diámetro interno de los clusters:

$$D = \frac{\text{distancia mínima entre clusters distintos}}{\text{distancia máxima dentro de un mismo cluster}}$$

Interpretación:

- el numerador debe ser grande: interesa que los clusters estén separados;
- el denominador debe ser pequeño: interesa que cada cluster sea compacto;
- por tanto, un valor alto de Dunn indica una buena agrupación.

4.7.1.4. Coeficiente silhouette El coeficiente **Silhouette** evalúa cada observación comparando su proximidad al cluster al que ha sido asignada con su proximidad al cluster alternativo más cercano.

Para una observación i :

- $a(i)$ es la distancia media desde i a las demás observaciones de su propio cluster;
- $b(i)$ es la menor distancia media desde i a las observaciones de cualquier otro cluster.

Su valor es:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

Interpretación:

Valor de $s(i)$	Interpretación
Cercano a 1	Observación bien asignada a su cluster
Cercano a 0	Observación situada cerca de la frontera entre clusters
Negativo	Observación posiblemente mejor asignable a otro cluster

El coeficiente global es la media de los valores individuales:

$$S = \frac{1}{n} \sum_{i=1}^n s(i)$$

4.7.2. Evaluación de agrupamientos jerárquicos

Para agrupamientos jerárquicos puede utilizarse el **coeficiente de correlación cofenética** (CPCC).

En un dendrograma, la distancia cofenética entre dos observaciones es la altura a la que ambas quedan unidas por primera vez en el mismo cluster.

El coeficiente cofenético compara:

- las disimilitudes originales entre observaciones;
- las disimilitudes representadas por el dendrograma.

Interpretación:

Un coeficiente cofenético alto indica que el dendrograma conserva razonablemente bien la estructura de disimilitudes original.

No existe una métrica perfecta para todos los problemas.

Situación	Métrica o enfoque útil
No hay etiquetas externas y se estudian particiones compactas	Silhouette, Dunn, Calinski-Harabasz, Hartigan
Se evalúa un dendrograma	Coeficiente cofenético
Existen etiquetas externas de referencia	Pureza, Rand, Jaccard, medida F , información mutua
Se comparan configuraciones o números de clusters	Métricas internas y evaluación relativa

Hay que tener precaución:

- una métrica basada en centroides o SSE puede favorecer a k -medias;
- una métrica de compactación puede valorar mal clusters no globulares detectados por DBSCAN;
- diferentes métricas pueden elegir soluciones diferentes.

Por tanto:

Conviene comparar varios algoritmos y varias métricas, buscando soluciones estables e interpretables.

4.8. Reglas de asociación

Introducción a las reglas de asociación

Bibliografía:

- Básica
 - Vídeo 8.15 “Reglas de asociación” de la práctica de la asignatura
- Complementaria
 - [ESL] 14.2 “Association rules” Págs. 487-503

Las **reglas de asociación** son técnicas de aprendizaje no supervisado que buscan relaciones frecuentes entre elementos o valores que aparecen conjuntamente en los datos.

Ejemplo típico:

Si una compra contiene pan y queso, también suele contener vino.

Una regla suele expresarse como:

antecedente -> consecuente

Por ejemplo:

pan, queso -> vino

Las medidas básicas son:

Medida	Significado
Soporte	Frecuencia con la que aparece conjuntamente la regla en los datos
Confianza	Frecuencia con la que aparece el consecuente cuando aparece el antecedente
Lift	Cuánto más frecuente es la asociación respecto a lo esperable si ambos eventos fueran independientes

No confundir con clustering:

Técnica	Qué descubre
Clustering	Grupos de observaciones similares
Reglas de asociación	Relaciones frecuentes entre elementos o variables

Algoritmo apriori

Bibliografía:

- Básica
 - Vídeo 8.16 “Algoritmo Apriori” de la práctica de la asignatura

Apriori es un algoritmo clásico para descubrir reglas de asociación.

Su idea principal es:

Si un conjunto de elementos no es frecuente, ningún conjunto mayor que lo contenga podrá ser frecuente.

A partir de esta propiedad, Apriori:

1. Busca conjuntos de elementos frecuentes, es decir, con soporte suficiente.
2. Descarta combinaciones que no alcanzan el soporte mínimo.
3. Genera reglas de asociación a partir de los conjuntos frecuentes encontrados.

Ejemplo:

Si {pan, queso} no aparece con suficiente frecuencia, no merece la pena explorar reglas basadas en {pan, queso, vino}.

Idea para recordar:

Apriori encuentra conjuntos frecuentes y, a partir de ellos, genera reglas de asociación; no forma clusters de observaciones.

Bibliografía

Bibliografía:

- Básica
 - [ESL] HASTIE, Trevor, TIBSHIRANI, Robert, FRIEDMAN, Jerome. Secciones 14.1 y 14.3 de The Elements of Statistical Learning. 2.^a ed. Springer, 2017.
 - [EMUL] Informe técnico Evaluation Metrics for Unsupervised Learning Algorithms
- Complementaria
 - [ANS] Capítulo 8 “Aprendizaje No Supervisado”, extraído de un libro sin identificar <https://agora.uned.es/mod/resource/view.php?id=704477>
- FAQ

Licencia y atribución

License CC BY 4.0

Este trabajo está licenciado bajo la licencia **Creative Commons Atribución 4.0 Internacional**.

© 2026, Colaboradores de apuntes-muicd-uned.