

AAII.EX.2025J2

Ejercicios elaborados con fines educativos, inspirados en los contenidos evaluados en el examen de la sesión de la 2.^a semana de junio 2025 de Aprendizaje Automático II del MUICD de la UNED.

Este documento no es una copia ni una transcripción del examen oficial, sino una redacción propia de ejercicios conceptualmente equivalentes.

Asignatura: Aprendizaje Automático II

Duración máxima: 60 minutos

Material permitido: todo tipo de material de consulta.

N.º preguntas: 10 N.º por pregunta: 4 Pregunta correcta: +1 punto Pregunta incorrecta: -0,3 puntos

Indicaciones

La prueba consta de 10 preguntas teórico-prácticas sobre los contenidos de la asignatura. Cada cuestión presenta hasta cuatro opciones, siendo válida únicamente una. Cada respuesta correcta suma un punto y cada respuesta incorrecta resta 0.3 puntos.

AAII.EX.2025J2.1

Enunciado AAII.EX.2025J2.1

Una propiedad destacada de métodos de clustering basados en densidad como DBSCAN es que...

- A. no requieren ponderar explícitamente la importancia de cada variable.
- B. producen siempre el mismo número de grupos que K-medias.
- C. permiten formas arbitrarias de clúster y no exigen fijar previamente K.
- D. garantizan convergencia global en cada iteración.

Solución AAII.EX.2025J2.1

La respuesta correcta es **C**.

DBSCAN no obliga a fijar K y puede detectar clústeres de forma no esférica (además de identificar ruido/outliers).

AAII.EX.2025J2.2

Enunciado AAII.EX.2025J2.2

El objetivo principal del método Bagging es...

- A. disminuir el sesgo del modelo base.
- B. incrementar la complejidad de los modelos individuales.
- C. reducir la varianza de la predicción combinada.
- D. optimizar directamente la función de pérdida cuadrática.

Solución AAII.EX.2025J2.2

La respuesta correcta es **C**.

El objetivo principal de bagging es **reducir la varianza** del predictor promedio al combinar muchos modelos entrenados sobre remuestreos.

AAII.EX.2025J2.3

Enunciado AAII.EX.2025J2.3

Según la formulación clásica del boosting con pérdida cuadrática, cada nuevo árbol ajusta...

- A. el gradiente de los errores de clasificación.
- B. los residuos de la predicción previa, equivalentes a la derivada del error cuadrático.
- C. el promedio de las observaciones fuera de bolsa.
- D. la entropía asociada a la distribución de pesos.

Solución AAII.EX.2025J2.3

La respuesta correcta es **B**.

Con pérdida cuadrática, boosting ajusta en cada iteración los **residuos** de la predicción anterior, equivalentes al **gradiente negativo** de la pérdida:

$$r_i^{(m)} = y_i - \hat{f}^{(m-1)}(x_i)$$

AAII.EX.2025J2.4

Enunciado AAII.EX.2025J2.4

En un bosque aleatorio, la importancia de las variables suele estimarse mediante...

- A. el análisis de la matriz de confusión.
- B. criterios de pureza como Gini junto con permutaciones aleatorias.
- C. contrastes estadísticos chi-cuadrado.
- D. coeficientes de regularización específicos por variable.

Solución AAII.EX.2025J2.4

La respuesta correcta es **B**.

En Random Forest, la importancia de variables se obtiene típicamente por:

- disminución media de impureza (p. ej., Gini)
- importancia por permutación (deterioro al permutar una feature)

AAII.EX.2025J2.5

Enunciado AAII.EX.2025J2.5

Un metamodelo lineal puede resultar insuficiente al combinar clasificadores altamente no lineales porque...

- A. ignora la presencia de variables categóricas.
- B. puede no capturar interacciones complejas entre modelos base.
- C. incrementa sistemáticamente el sesgo del stacking.
- D. no presenta limitaciones en este contexto.

Solución AAII.EX.2025J2.5

La respuesta correcta es **B**.

Un meta-modelo lineal puede no capturar **interacciones no lineales** entre predicciones de modelos base altamente no lineales.

AAII.EX.2025J2.6

Enunciado AAII.EX.2025J2.6

Cambiar el criterio de división en un Random Forest por uno menos habitual (por ejemplo, entropía en lugar de Gini) podría...

- A. reducir el número necesario de árboles.
- B. mejorar automáticamente la interpretabilidad.
- C. alterar las particiones, generando árboles potencialmente más diversos.
- D. exigir validación cruzada en cada árbol.

Solución AAII.EX.2025J2.6

La respuesta correcta es **C**.

Cambiar el criterio de división (Gini vs entropía u otro) puede cambiar qué *splits* se eligen, produciendo árboles con particiones algo distintas y, por tanto, potencialmente más diversidad.

AAII.EX.2025J2.7

Enunciado AAII.EX.2025J2.7

El clustering jerárquico aglomerativo construye grupos...

- A. partiendo de un único grupo global que se subdivide.
- B. comenzando con cada observación como clúster independiente y fusionándolos.
- C. aplicando validación cruzada en cada fusión.
- D. fijando previamente el número de grupos.

Solución AII.EX.2025J2.7

La respuesta correcta es **B**.

El jerárquico aglomerativo comienza con cada observación como clúster propio y va **fusionando** sucesivamente según un criterio de enlace.

AII.EX.2025J2.8

Enunciado AII.EX.2025J2.8

El boosting puede ser más propenso al sobreajuste que el bagging porque...

- A. entrena modelos de forma independiente.
- B. enfatiza progresivamente ejemplos difíciles, pudiendo ajustar ruido.
- C. requiere validación cruzada iterativa.
- D. utiliza menos datos de entrenamiento.

Solución AII.EX.2025J2.8

La respuesta correcta es **B**.

Boosting es secuencial y se va enfocando en los ejemplos difíciles; si hay ruido, puede terminar **ajustándolo** (sobreajuste) si no se regulariza.

AII.EX.2025J2.9

Enunciado AII.EX.2025J2.9

En AdaBoost, tras cada iteración las muestras mal clasificadas...

- A. se eliminan del entrenamiento.
- B. reducen su peso relativo.
- C. incrementan su peso para recibir mayor atención.
- D. no influyen en la siguiente iteración.

Solución AII.EX.2025J2.9

La respuesta correcta es **C**.

En AdaBoost, las observaciones mal clasificadas aumentan su peso para que el siguiente clasificador se centre más en ellas.

AII.EX.2025J2.10

Enunciado AII.EX.2025J2.10

El stacking puede comportarse de forma similar al bagging cuando...

- A. el metamodelo ignora las variables originales.
- B. los modelos base son árboles podados.

- C. el metamodelo se limita a promediar directamente las predicciones.
- D. se emplean subconjuntos aleatorios de variables en cada división.

Solución AAIL.EX.2025J2.10

La respuesta correcta es **C**.

Stacking se comporta como bagging si el meta-modelo se reduce a una **media directa** (o promedio) de las predicciones de los modelos base.