

MDMS - Tema 1: Herramientas y métodos de extracción de información en redes sociales

Introducción a la minería de medios sociales

Bibliografía:

- Básica
 - [TSMS] Apartado 1 “Introducción”.
- Complementaria
 - [SMMI] 1.1 “What is Social Media Mining?”

Los **medios sociales** generan cantidades masivas de datos sobre usuarios, contenidos y relaciones. Estos datos se diferencian de los empleados habitualmente en minería de datos porque proceden en gran medida de los propios usuarios y suelen presentarse de forma no estructurada, con ruido y conectados mediante relaciones sociales, como amistades, seguimientos, respuestas o menciones. Por ello, no basta con aplicar directamente técnicas tradicionales: es necesario combinarlas con métodos de análisis de redes y con teorías sociales que ayuden a interpretar el comportamiento de los usuarios.

La **minería de los medios sociales** es el proceso de representar, analizar y extraer patrones útiles de los datos generados en estos entornos. Permite estudiar cómo actúan los individuos, cómo interactúan entre sí y con distintos contenidos o plataformas, y cómo de esas relaciones surgen grupos, es decir, comunidades.

Elementos de los medios sociales:

- **Átomos sociales:** los individuos o usuarios.
- **Moléculas sociales:** las comunidades formadas por individuos o usuarios.
- **Entidades:** contenidos, sitios, grupos, publicaciones, vídeos u otros objetos de la red.
- **Interacciones:** relaciones entre usuarios o entre usuarios y entidades, como seguir, responder, comentar o compartir.

De manera general, una minería eficiente de medios sociales requiere:

1. **Recopilación.** Recopilar información sobre los usuarios y las entidades.
2. **Análisis:** Medir las interacciones que se producen entre ellos.
3. **Extracción.** Descubrir patrones que ayuden a comprender el comportamiento humano en la red.

Retos de la minería de los medios sociales

Bibliografía:

- Básica

- [TSMS] Apartado 2 “Retos de la minería de los medios sociales”.
- [SMMI] 1.2 “New Challenges for Mining”. Págs. 2-3.

Retos de la minería de los medios sociales, de acuerdo a [SMMI]:

- Paradoja del Big Data
- Muestreo suficiente
- Engaño de la eliminación del ruido
- Dilema de la evaluación

Paradoja del Big Data

La **paradoja del Big Data** se refiere a que aunque el volumen global de datos es masivo, la información disponible sobre un individuo específico suele ser mínima.

Para mitigar esta carencia, la minería de datos debe aprovechar la naturaleza multidimensional y multifuente de las plataformas, integrando diversos flujos de información para construir un perfil de usuario más completo.

Muestreo suficiente

El **muestreo suficiente** se refiere a la limitación encontrada por la restricción por las plataformas de redes sociales en los volúmenes y criterios predefinidos de los datos extraídos, lo que genera dudas sobre la representatividad de la muestra respecto al átomo social. Por tanto, se debe asumir que ninguna fuente de datos externa posee una veracidad absoluta.

Engaño de la eliminación del ruido

El **engaño de la eliminación del ruido** se refiere a las complejidades de la eliminación del ruido en redes sociales, pues:

- Una limpieza agresiva agrava la paradoja del Big Data al reducir aún más los pocos datos individuales existentes.
- La definición de “ruido” es relativa; lo que es irrelevante para un análisis puede ser esencial para otro, dificultando un preprocesado estándar.

Dilema de la evaluación

EXAM=(2023S0.C.1)

En la minería de datos convencional, lo estándar es fragmentar la información en conjuntos de entrenamiento y prueba para validar patrones.

El **dilema de la evaluación** se refiere a que la naturaleza dinámica y estructural de los medios sociales suele impedir la división estos conjuntos para MDMS.

Pese a esta dificultad, es necesario diseñar mecanismos de evaluación alternativos que permitan certificar la fiabilidad y calidad de los patrones extraídos en este contexto.

Características de los datos en medios sociales

Bibliografía:

- Básica
 - [TSMS] Apartado 3 “Hacer minería en los medios sociales”.
 - [MSMST] Apartado 2 “Social media data is social”

Los datos de los medios sociales presentan características propias que los diferencian de los datos tratados habitualmente en minería de datos. Las características son, de acuerdo a [MSMST]:

- Grandes
- Enlazados
- Ruidosos
- Desestructurados
- Incompletos

Además, al reflejar relaciones e interacciones entre usuarios, permiten aplicar teorías sociales para analizar y descubrir patrones de comportamiento.

- **Grandes:** aunque la información disponible sobre un usuario concreto pueda ser limitada, los medios sociales reúnen datos de una enorme cantidad de usuarios y de sus interacciones. Así, puede haber pocos datos sobre cada átomo social, pero muchísimos átomos sociales relacionados entre sí.
- **Enlazados o relacionados:** los usuarios no aparecen aislados, sino conectados mediante amistades, seguimientos, respuestas, menciones u otras relaciones. Estos enlaces pueden reflejar afinidad, influencia, estatus o rechazo, por lo que son especialmente relevantes para aplicar teorías sociales.
- **Ruidosos:** parte de los datos puede ser errónea, irrelevante, ambigua o artificial para el objetivo del análisis. Por ejemplo, pueden considerarse ruido los mensajes *spam*, las publicaciones duplicadas, los comentarios que no guardan relación con el tema estudiado o la actividad generada por cuentas automatizadas. No obstante, qué datos son ruido depende de la tarea concreta, y un filtrado excesivo podría eliminar información útil.
- **Poco estructurados:** gran parte del contenido es generado libremente por los usuarios, como textos, imágenes, vídeos o comentarios. Además, distintas plataformas o API pueden proporcionar información parcial y en formatos diferentes, dificultando su integración y análisis.
- **Incompletos:** no siempre se dispone de toda la información necesaria sobre los usuarios o sus relaciones. Las restricciones de privacidad, los

perfiles parcialmente cumplimentados o la imposibilidad de observar toda la actividad hacen que los datos accesibles sean habitualmente parciales.

Teorías sociales en los medios sociales

Bibliografía:

- Básica
 - [TSMS] Apartado 4 “Teorías sociales en los medios sociales”.

Teorías sociales estudiadas en la asignatura:

- Teoría de correlación social
- Teoría del balance
- Teoría del estatus

Teoría de correlación social

Bibliografía:

- Básica
 - [TSMS] Apartado 4.1 “Teorías de correlación social”.
- Complementario
 - [RDDSIH]
 - [RDN]
 - [MSMST] 3.1 “Social Correlation Theory”

EXAM=(2023J2.P.1,2024S0.C.2,2025S0.C.2)

La **teoría de correlación social** trata de explicar cómo se propagan comportamientos y rasgos en un entorno conectado. Este fenómeno se fundamenta en los siguientes mecanismos, principalmente en los dos primeros:

- Homofilia social
- Influencia
- k -exposición

Homofilia social (introducción)

Bibliografía:

- Básica
 - [TSMS] Apartado 4.1 “Teoría de correlación social”.
 - [MSMST] 3.1 “Social Correlation Theory”

La **homofilia social** (en inglés, *social homophily*), descrita a menudo como la “afinidad por lo semejante”, la homofilia es la inclinación natural de las personas a establecer vínculos con quienes comparten atributos similares. Esta

convergencia en valores, educación o creencias actúa como un lubricante social, facilitando la comunicación y el fortalecimiento de la relación. En el análisis de redes, este concepto se mide técnicamente bajo el término de asortatividad.

El concepto de homofilia se amplía en el tema 3.

Influencia

Bibliografía:

- Básica
 - [TSMS] Apartado 4.1 “Teoría de correlación social”.
- Complementaria
 - [SMMI] 8.2 “Influence”
 - [MSMST] 3.1 “Social Correlation Theory”

La **influencia** ocurre cuando el vínculo social preexistente moldea el comportamiento del individuo. Es el proceso por el cual las personas adoptan rasgos, gustos o acciones de sus allegados. En esencia, la cercanía social fomenta la mimetización de conductas entre los nodos de la red.

Confusión

Bibliografía:

- Básica
 - [TSMS] Apartado 4.1 “Teoría de correlación social”. Pág. 4.
 - [SMMI] 8. “Influence and Homophily”. Pág. 217.
 - [MSMST] 3.1 “Social Correlation Theory”
- Complementaria

La **confusión** (en inglés, *confounding*) se produce cuando dos usuarios presentan semejanzas debido a un factor externo común, y no porque uno haya influido en el otro ni porque su relación se haya formado por homofilia. Por ejemplo, dos personas pueden hablar el mismo idioma porque viven en el mismo país, o presentar hábitos semejantes porque comparten un mismo entorno.

La confusión es, por tanto, una explicación alternativa de la similitud observada entre usuarios: dos individuos pueden parecerse aunque esa semejanza no proceda de sus relaciones sociales.

Según [MSMST], una consecuencia de la confusión es establecer relaciones comunes con individuos expuestos a los mismos factores externos. Esto se puede explicar por homofilia: si dos individuos están en un mismo entorno, adquieren características similares y por tanto es probable que establezcan una relación por homofilia.

Bibliografía:

- Básica

- [TSMS] Apartado 4.1 “Teoría de correlación social”. Pág. 4.
- [GMIA] 2.1. Social correlation

La ***k*-exposición** expresa que la probabilidad de que un usuario adopte un contenido, conducta o elemento es directamente proporcional al número (*k*) de contactos en su círculo que ya lo han hecho. A diferencia de la confusión, aquí interviene la exposición a la actividad de otros usuarios de la red.

Según [TSMS], *k*-exposición y confusión están relacionados; no obstante, dadas las definiciones anteriores se comprueba que tienen matices distintos: en confusión la relación es una consecuencia, y en *k*-exposición una causa.

La teoría de correlación social según [MSMST] no incluye la *k*-exposición entre los mecanismos que la desarrollan, pero se incluye aquí para aclarar las diferencias.

Teoría del balance

Bibliografía:

- Básica
 - [TSMS] Apartado 4.2 “Teorías del balance”.
- Complementario
 - [MSMST] Apartado 3.2. “Balance Theory”

La **teoría del balance** estudia la coherencia de las relaciones positivas y negativas dentro de una tríada formada por tres usuarios. Una relación positiva puede representar amistad, confianza o afinidad; una relación negativa, enemistad, desconfianza o aversión.

Para aplicar esta teoría, cada relación entre dos usuarios debería poder marcarse como positiva (amistad, afinidad, confianza) o negativa (enemistad, rechazo, desconfianza).

Una tríada está **equilibrada** cuando sus relaciones no producen una situación social contradictoria o inestable y que de manera intuitiva se cumple que:

- *los amigos de mis amigos son mis amigos*
- *los enemigos de mis enemigos son mis amigos*

Para aplicar esta teoría es necesario disponer de relaciones etiquetadas como positivas o negativas. En muchos medios sociales estas etiquetas no aparecen directamente y deben inferirse a partir de acciones como confiar o desconfiar, apoyar o rechazar, etc. La teoría del balance se formula originalmente para redes no dirigidas; si se aplica a relaciones dirigidas, normalmente se ignora la dirección del enlace.

EXAM=(2025S0.C.3)

Cuando se comprueba en una red que los miembros del mismo grupo tienen afinidad y los de grupos distintos sienten aversión, es aplicable la teoría del balance.

Teoría del estatus

Bibliografía:

- Básica
 - [TSMS] Apartado 4.3 “Teorías del estatus”.
 - [MSMST] Apartado 3.3. “Status theory”
- Complementaria
 - [SMMI] Apartado 3.3 “Balance and status”

EXAM=(2022J2.C.1,2023J2.P.1,2025J2.C.1)

La **teoría del estatus** sostiene que el estatus define el nivel de prestigio, rango u honor que un individuo posee dentro de un colectivo. Aplicado al análisis de redes, los átomos sociales ocupan posiciones jerárquicas que se manifiestan a través de sus interacciones.

Un enlace positivo dirigido desde un usuario u_1 hacia un usuario u_2 significa que u_2 tiene mayor estatus que u_1 . Es decir, el signo positivo no expresa amistad, como en la teoría del balance, sino una relación de reconocimiento de mayor rango o prestigio del nodo destino respecto al nodo origen.

Cuando se forman nuevos enlaces, la teoría del estatus predice que es más probable que aparezcan desde usuarios de menor estatus hacia usuarios de mayor estatus. Por ejemplo, en una red social dirigida, un alumno principiante podría seguir, consultar o responder a un alumno con más experiencia, porque lo reconoce como alguien de mayor prestigio o conocimiento.

Para poder aplicar la teoría del estatus es necesario que:

- las relaciones sean **direccionales** (con origen y destino claros)
- permitan el **etiquetado de estatus**, facilitando así la identificación de las asimetrías de rango entre los nodos de la red

Teorías sociales en las tareas de minería

Bibliografía:

- Básica
 - [TSMS] Apartado 5 “Teorías sociales en las tareas de minería”.
 - [MSMT]

En los medios sociales pueden identificarse tres tipos de objetos, de acuerdo a [MSMT]: los **usuarios**, que crean y consumen información; las **relaciones sociales**, que conectan a unos usuarios con otros, como amistades, seguimientos

o respuestas; y los **contenidos**, como publicaciones, comentarios, imágenes o vídeos.

Las tareas de minería de datos de los medios sociales se centra, por tanto, en los objetos mencionados:

- Usuarios
- Relaciones sociales
- Contenidos

Tareas de MDMS basadas en usuarios

Bibliografía:

- Básica
 - [TSMS] Apartado 5.1. “Sobre los usuarios.
 - [MSMT] 4.1. “Social Theories in User-Related Tasks”

Tareas de minería basados en usuarios:

- Detección de comunidades (básico)
- Clasificación de usuarios
- Detección de spammers sociales

Detección de comunidades (básico)

Bibliografía:

- Básica
 - [TSMS] Subpartado “Detección de comunidades” del apartado 5.1. “Sobre los usuarios.
- Complementaria
 - [SMMI] 6.1 “Community Detection” Págs. 144-161
 - [MSMT] 4.1.1 “Community Detection”

Nota: esta sección se refiere a la detección de comunidades “básica” porque el concepto se amplía en apartados con el mismo nombre en el tema 2, con las etiquetas “importante” y “avanzada”, de acuerdo con el mapa conceptual de la asignatura para el tema 2.

EXAM=(2023S0.C.1)

La **detección de comunidades** es importante en minería de datos de los medios sociales por los siguientes motivos:

1. Permite **inferir los intereses de individuos**, puesto que los individuos pertenecen a comunidades de acuerdo a intereses.
2. Permite obtener una **perspectiva integral de las dinámicas entre usuarios**. Mientras que el comportamiento de los individuos de la red suele ser errático, ruidoso o demasiado específico, las comunidades tienden

a manifestar patrones comunes y más estables frente a variaciones externas. Esta cohesión permite deducir información valiosa sobre un sujeto analizando no solo sus acciones particulares, sino también su alineación con las tendencias globales del grupo al que pertenece.

EXAM=(2023J2.C.1)

Tipos de comunidades:

- Explícita
- Implícita

Una **comunidad explícita** es aquella en la que los individuos son conscientes de que forman parte de ella, los no-miembros son conscientes de que no son parte de ella, y los miembros de la comunidad interaccionan más entre ellos que con los no-miembros.

Una **comunidad implícita** es aquella en la que los individuos interactúan entre sí sin que tengan consciencia de comunidad.

Clasificación de usuarios

Bibliografía:

- Básica
 - [TSMS] Subapartado “Clasificación de usuarios” del apartado 5.1 “Sobre los usuarios”.
- Complementaria
 - [MSMST] 4.1. “User Classification”

La **clasificación de usuarios** implica que a partir de la estructura de una red y ciertos datos personales, se categoricen a los individuos o colectivos enriqueciendo sus perfiles con la información grupal. Por ejemplo, al delimitar una comunidad, sus integrantes pueden ser clasificados mediante el análisis agregado de los datos individuales de todos sus miembros, permitiendo que el conocimiento del conjunto complete las lagunas de información de cada usuario.

Detección de spammers sociales

Bibliografía:

- Básica
 - [TSMS] Subapartado “Detección de spammers sociales” del apartado 5.1 “Sobre los usuarios”
- Complementaria
 - [MSMST] 4.1.3 “Social Spammer Detection”

La **detección de spammers sociales** trata de identificar usuarios, denominados *spammers*, que realizan actividades no deseadas o artificiales en una red

social. De acuerdo con la teoría de correlación social, los usuarios normales suelen presentar comportamientos similares a los de sus vecinos y, por ello, tienden a agruparse en zonas más densamente conectadas. En cambio, un *spammer* suele relacionarse principalmente con usuarios normales, pero su actividad difiere de la de estos. Por tanto, un usuario cuyo comportamiento resulte anómalo respecto al de sus vecinos puede considerarse sospechoso de ser *spammer*.

Tareas de MDMS basadas en relaciones

Bibliografía:

- Básica
 - [TSMS] Apartado 5.2. “Sobre las relaciones sociales”.
 - [MSMST] 4.2 “Social Theories in Relation-Related Tasks”

Tareas de minería social basadas en relaciones:

- Predicción de enlaces

[MSMST] identifica otras dos tareas, pero estas no se listan en los apuntes de la asignatura [TSMS].

Predicción de enlaces

Bibliografía:

- Básica
 - [TSMS] Subpartado “Predicción de enlaces” del apartado 5.2. “Sobre las relaciones sociales”.
- Complementaria
 - [MSMST] 4.2.1 “Link Prediction”

EXAM=(2024S0.C.2)

La **predicción de enlaces** consiste en estimar qué pares de usuarios que todavía no están conectados tienen mayor probabilidad de establecer una relación en el futuro. Esta tarea puede apoyarse en distintas teorías sociales.

Teorías sociales que apoyan la predicción de enlaces:

- **Teoría de la correlación**
 - La **homofilia** plantea que la similitud entre individuos facilita la creación de vínculos. El **coeficiente de homofilia social** expresa la fuerza de esa semejanza entre dos usuarios. En un modelo de espacio latente o implícito, cada usuario se representa mediante una posición obtenida a partir de sus características o relaciones; cuanto menor sea la distancia entre dos usuarios en ese espacio, mayor será su homofilia y más probable será la formación de un enlace entre ellos.

- El efecto de **confusión** indica que dos usuarios expuestos a condiciones externas semejantes pueden tener mayor probabilidad de conectarse. Por ejemplo, usuarios cuyos desplazamientos o lugares frecuentados presentan un alto solapamiento pueden encontrarse físicamente próximos y ser más propensos a establecer una relación.
- **Teoría del estatus**
 - Permite predecir enlaces dirigidos: es más probable que se forme una relación desde un usuario de menor estatus hacia otro de mayor estatus, como cuando un usuario sigue o reconoce a otro más prestigioso.

La **predicción de enlaces** consiste en estimar qué usuarios actualmente no conectados tienen mayor probabilidad de establecer una relación en el futuro.

Según la **homofilia**, dos usuarios similares tienen mayor probabilidad de relacionarse. El **coeficiente de homofilia social** expresa la fuerza de esa semejanza: en un espacio implícito que representa a los usuarios mediante sus características o relaciones, una menor distancia entre ellos indica una homofilia más fuerte y, por tanto, una mayor probabilidad de conexión.

El efecto de **confusión** también puede utilizarse para predecir enlaces: dos usuarios expuestos a un mismo entorno, por ejemplo porque residen cerca o sus trayectorias de movilidad se solapan, pueden tener más probabilidad de establecer una relación, aunque todavía no exista un enlace directo entre ellos.

Finalmente, según la **teoría del estatus**, en redes dirigidas es más probable que aparezcan enlaces desde usuarios de menor estatus hacia usuarios de mayor estatus. Qué conviene conservar para el examen

Contenidos

Bibliografía:

- Básica
 - [TSMS] Subapartado “Recomendación social” del apartado 5.3 “Sobre los contenidos”.
 - [MSMST] Apartado 5.3. “Sobre los contenidos”.

Tareas de minería social para el tipo de objeto contenido:

- Recomendación social

Recomendación social

Bibliografía:

- Básica
 - [TSMS] Subapartado “Recomendación social” del apartado 5.3 “Sobre los contenidos”.
- Complementaria
 - [MSMST]. Apartado 4.3.1. “Social Recommendation”. Pág. 7.

Las plataformas digitales ofrecen una capa de datos adicional: el tejido de conexiones entre usuarios. Esta red permite optimizar los sistemas de **recomendación social** (en inglés, *social recommendation*) al integrar el impacto que el entorno cercano ejerce sobre el individuo, ya sea por homofilia, influencia directa o el efecto de la k-exposición. Se ha demostrado que este enfoque es altamente eficaz para resolver la saturación informativa y perfeccionar la sugerencia de contenidos, personalizando la experiencia según la dinámica social de cada nodo.

Bibliografía

Bibliografía:

- Básica
 - [TSMS] RODRÍGUEZ ANAYA, Antonio. Teorías sociales en la minería social.
 - [TRS] LOZARES, Carlos. La teoría de las redes sociales. Universitat Autònoma de Barcelona, 1996.
- Complementaria
 - [SMMI] ZAFARANI, Reza, ABBASI, Mohammad Ali, LIU, Huan Liu. Social media mining: An introduction. Cambridge University Press, 2014.
 - [MSMST] TANG, Jiliang, CHANG, Yi, LIU Huan. Mining social media with social theories: a survey. Explorations Newsletter, 15(2):20–29, 2014.
 - [GMIA] CHUA, Freddy Chong Tat, LAUW, Hady W, LIM, Ee-Peng. Generative models for item adoptions using social correlation. IEEE Transactions on Knowledge and Data Engineering, 25(9):2036–2048, 2013.
 - [RDDSIIH] LA FOND, Timothy, NEVILLE, Jennifer. Randomization tests for distinguishing social influence and homophily effects. In Proceedings of the 19th international conference on World wide web, pages 601–610. ACM, 2010.
 - [RDN] NEVILLE, Jennifer, JENSEN, David. Relational dependency networks. Journal of Machine Learning Research, 8:653–692, 2007.

Licencia y atribución

License CC BY 4.0

Este trabajo está licenciado bajo la licencia **Creative Commons Atribución 4.0 Internacional**.

© 2026, Colaboradores de apuntes-muicd-uned.