

MDMS - Tema 3: Técnicas de minería de datos en redes sociales

La estructura de este tema trata de seguir la organización propuesta en el mapa conceptual del tema 3 de la asignatura junto con los apartados del material lectivo elaborado por el personal docente.

Fases de minería de los datos

Bibliografía:

- Básica
 - [IMDRS] Apartado 1 “Introducción”.

Hay cuatro fases.

1. **Descubrimiento de conocimiento.** A partir de un conjunto de datos en crudo, se extrae una selección de los mismos.
2. **Preprocesamiento.** Sobre la selección de datos, se aplica un tratamiento para poder aplicar herramientas sobre ellos.
3. **Aplicación de herramientas.** Se aplican, por ejemplo, algoritmos, con el objetivo de obtener patrones de los datos.
4. **Evaluación.** Los patrones de datos se validan y verifican, analizándose también su relevancia.

“DPAE”

Calidad de los datos

Bibliografía:

- Básica
 - [IMDRS] Apartado 2.1 “Calidad de los datos”.

Incluye cuatro definiciones:

- Ruido
- Valor errático
- Valor perdido
- Valor duplicado

Ruido

Bibliografía:

- Básica
 - [IMDRS] Apartado 2.1 “Calidad de los datos”.

EXAM=(2023J2.C.3,2024J2.C.2)

El **ruido** es la presencia de datos, contenidos o relaciones que dificultan extraer patrones fiables en una tarea de minería de datos. En los medios sociales aparece con frecuencia porque los usuarios generan libremente contenidos de calidad muy variable y porque las relaciones establecidas en la red no siempre representan vínculos sociales significativos.

El ruido puede afectar a todos los elementos de las redes sociales (usuarios, contenidos y relaciones sociales). Son ejemplos de datos ruidosos los mensajes de *spam*, publicaciones duplicadas o irrelevantes, errores y expresiones difíciles de interpretar, cuentas automatizadas o enlaces creados indiscriminadamente que mezclan relaciones superficiales con vínculos reales de amistad, afinidad o confianza.

Para tratar el ruido suele realizarse un preprocesado de los datos. Sin embargo, debe tenerse en cuenta el objetivo del análisis, porque un dato considerado ruido en una tarea puede ser relevante en otra: por ejemplo, una cuenta con actividad anómala podría eliminarse al estudiar el comportamiento habitual de los usuarios, pero sería fundamental en una tarea de detección de *spammers*.

Valor errático

Bibliografía:

- Básica
 - [IMDRS] Apartado 2.1 “Calidad de los datos”.

Los **valores erráticos** o **valores atípicos** (en inglés, *outliers*) son instancias que presentan valores muy alejados o diferentes de los habituales en el conjunto de datos. Por ejemplo, en una red educativa, un estudiante que publique cientos de mensajes en pocas horas podría ser un caso atípico frente al comportamiento general.

Estos valores pueden eliminarse si proceden de errores o distorsionan el análisis, pero no deben descartarse automáticamente: según la tarea, pueden representar información relevante, como un usuario extremadamente activo, un *spammer* o un comportamiento anómalo que se desea detectar.

Valor perdido

Bibliografía:

- Básica
 - [IMDRS] Apartado 2.1 “Calidad de los datos”.

Los **valores perdidos** aparecen cuando una instancia no tiene información disponible para alguno de sus atributos. Este problema es habitual en medios sociales, ya que los usuarios pueden no proporcionar determinados datos o restringir su acceso mediante opciones de privacidad.

Ante valores perdidos pueden adoptarse distintas estrategias: eliminar las instancias incompletas, estimar los valores ausentes o utilizar algoritmos capaces de trabajar sin ellos. La elección depende de la cantidad de información que falta, de su importancia para la tarea y del algoritmo que vaya a aplicarse.

Dato duplicado

Bibliografía:

- Básica
 - [IMDRS] Apartado 2.1 “Calidad de los datos”.

Los **datos duplicados** aparecen cuando distintas instancias tienen los mismos valores en todos sus atributos o cuando un mismo registro se incorpora varias veces al conjunto de datos. Por ejemplo, una publicación podría recogerse repetida al combinar información obtenida de varias fuentes.

Los duplicados pueden eliminarse cuando son errores de recopilación que alterarían los resultados. Sin embargo, en algunas tareas la repetición puede tener significado propio, como cuando varios usuarios comparten el mismo contenido o cuando interesa medir la difusión de un mensaje.

Proceso de minería de datos

Bibliografía:

- Básica
 - [IMDRS]
 - [SMMI]

El apartado de proceso de minería de datos engloba prácticamente todo el tema 3, si quitamos la introducción.

Preprocesado de los datos

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”

La sección de procesado de datos está marcada como “concepto básico” en el mapa conceptual del tema 3.

El **preprocesado de datos** se divide en procesos:

- Agregación
- Discretización
- Normalización estadística
- Selección de atributos

- Extracción de atributos
- Muestreo
- Eliminación de instancias con valores atípicos o erráticos

Una regla nemotécnica para recordar los procesos es el acrónimo ADNSEME(n).

Agregación)

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 2.

La **agregación** consiste en combinar varios atributos en uno nuevo o en resumir datos a una escala diferente.

Por ejemplo, el número de mensajes enviados por un estudiante cada día puede agregarse para obtener su actividad total semanal.

Discretización)

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.
 - Discretización. Wikipedia.

La **discretización** transforma un atributo continuo en un conjunto limitado de categorías. Por ejemplo, una variable numérica como el número de mensajes publicados puede convertirse en los valores **actividad baja**, **actividad media** y **actividad alta**.

Normalización estadística)

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.
 - Normalization. Wikipedia.

La **normalización** adapta los valores de distintos atributos a una escala comparable, evitando que los atributos con valores numéricos mayores tengan más influencia únicamente por su rango.

Por ejemplo, el número de mensajes y el número de respuestas recibidas pueden transformarse para que ambos tomen valores entre 0 y 1.

Selección de atributos)

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.

La **selección de atributos** consiste en conservar únicamente los atributos que resulten útiles para la tarea de análisis, descartando los irrelevantes, redundantes o demasiado costosos de procesar.

Por ejemplo, para estudiar la participación en un foro podrían seleccionarse el número de mensajes, las respuestas recibidas y la centralidad del estudiante.

Extracción de atributos)

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.

EXAM=(2023S0.C.3)

La **extracción de atributos** significa transformar los atributos originales para crear un nuevo conjunto de atributos. Es decir, no se reducen necesariamente las instancias, sino que se cambia la forma de representar la información.

Un ejemplo sería a partir de textos de publicaciones en redes sociales, extraer atributos como número de palabras, frecuencia de términos, presencia de hash-tags, sentimiento, número de menciones o vectores TF-IDF.

Muestreo)

EXAM=(2023S0.C.3)

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.

El **muestreo** consiste en seleccionar un subconjunto de instancias del conjunto total cuando el conjunto de datos es muy grande o el proceso es costoso en tiempo o computación. La idea es trabajar con una muestra que se asume representativa del total.

Un ejemplo sería seleccionar al azar un conjunto de publicaciones entre todas las existentes en una red social.

Eliminación de instancias con valores atípicos o erráticos)

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.
 - Distribución normal. Wikipedia.

Como se vió al inicio del tema, los valores errantes o atípicos son instancias que presentan valores muy diferentes de los habituales en el conjunto de datos.

Pueden eliminarse cuando distorsionan el análisis, pero no deben descartarse automáticamente, ya que en algunos problemas constituyen precisamente la información de interés. Por ejemplo, una cuenta con una actividad extraordinariamente alta podría ser ruido en un estudio del comportamiento medio, pero resultar relevante en una investigación sobre spammers o usuarios anómalos.

Algoritmos de aprendizaje automático

Bibliografía:

- Básica
 - [IMDRS]
 - [SMMI]

Esta sección está etiquetada en el mapa conceptual del tema 3 tanto como “concepto básico” como “avanzado”, lo que se puede interpretar como que introduce conceptos de ambas categorías.

EXAM=(2024J2.P.1.3,2025J2.P.1.3)

Una pregunta habitual en problemas de exámenes es indicar técnicas de aprendizaje automático que se consideran convenientes en el caso expuesto.

Se muestra un resumen de los algoritmos vistos en la asignatura y algunas de sus características:

Algoritmo	Aprendizaje	Atributo de clase
Árbol de decisión	Supervisado	Discreto
Naive Bayes	Supervisado	Discreto
Redes neuronales	Supervisado	Discreto
El vecino más cercano	Supervisado	Discreto
Regresión	Supervisado	Continuo

Algoritmos de aprendizaje supervisado

Bibliografía:

- Básica
 - [IMDRS]
 - [SMMI] 5.4 “Supervised Learning”. Págs. 113-127.

EXAM=(2022J2.C.2,2022J2.P.1.4,2023J2.P.1,2025S0.P.1.4)

En aprendizaje supervisado, se cuenta con:

- Unos **atributos** o **características** (*features*) conocidos y asociados a cada una de las instancias. Se corresponden con las variables explicativas o independientes de estadística.
- Un **atributo de clase** o **clase** que se pretende predecir en las nuevas instancias. Se corresponden con las variables de respuesta o dependientes de estadística.

Los **algoritmos de aprendizaje supervisado** utilizan un conjunto de entrenamiento en el que cada instancia tiene asociado un valor conocido del atributo de clase. A partir de estos ejemplos, el algoritmo aprende un modelo capaz de predecir la clase de nuevas instancias.

Se distinguen las dos clases de algoritmo de aprendizaje supervisado:

- De valor discreto
- De valor continuo

Cuando el atributo de clase toma valores discretos se utilizan algoritmos de clasificación; cuando la clase toma valores continuos, el tipo de algoritmo adecuado es la regresión.

Algoritmos de aprendizaje supervisado de valor discreto

Los algoritmos de aprendizaje supervisado son aquellos que permiten resolver el problema de clasificación.

Algoritmos de aprendizaje no supervisado de valor discreto vistos en [IMDRS]:

- Árbol de decisión
- Naive Bayes
- Redes neuronales
- El vecino más cercano

[SMMI] también desarrolla la clasificación con información de red y dedica un apartado a la evaluación del aprendizaje supervisado.

Árbol de decisión

Bibliografía:

- Básica
 - [IMDRS]
 - [SMMI] 5.4.1. Decision Tree Learning. Págs. 115-117.

Un **árbol de decisión** construye una estructura de reglas a partir de los datos de entrenamiento. Cada nodo interno representa una decisión sobre un atributo, cada rama corresponde a un posible valor o intervalo de valores y cada hoja asigna una clase. Una de sus principales ventajas es que permiten interpretar fácilmente por qué una instancia ha sido clasificada de una determinada manera. El modelo debe evaluarse con datos diferentes de los utilizados para entrenarlo.

Naive Bayes

Bibliografía:

- Básica
 - [IMDRS]
 - Teorema de Bayes. Wikipedia.
 - [SMMI] 5.4.2. Naive Bayes Classifier. Págs. 117-119.

Naive Bayes es un clasificador probabilístico basado en el teorema de Bayes:

$$P(Y | X) = \frac{P(X | Y)P(Y)}{P(X)}$$

donde Y representa la clase y X los atributos observados. Para clasificar una instancia, calcula la probabilidad de cada clase dados sus atributos y selecciona la más probable. Su simplificación principal consiste en asumir que los atributos son condicionalmente independientes entre sí una vez conocida la clase.

Redes neuronales

Bibliografía:

- Básica
 - [IMDRS]

Las **redes neuronales** están formadas por nodos computacionales conectados mediante pesos. A partir de los atributos de entrada, la red aprende durante el entrenamiento una función que permite predecir el atributo de clase. El aprendizaje consiste en ajustar los pesos de sus conexiones para reducir los errores de predicción. Pueden obtener buenos resultados en problemas complejos, aunque normalmente resulta difícil interpretar de forma directa cómo han llegado a una decisión concreta.

El vecino más cercano

Bibliografía:

- Básica
 - [IMDRS]
 - [SMMI] 5.4.3. Nearest Neighbor Classifier. Pág. 119.

El vecino más cercano (en inglés, *k-nearest neighbor*, **kNN**) clasifica una nueva instancia a partir de las k instancias etiquetadas más próximas a ella. Para determinar la proximidad se utiliza una medida de distancia, como la

distancia euclídea. La clase predicha suele ser la clase mayoritaria entre los vecinos seleccionados. La elección de k es importante, ya que puede modificar el resultado y afectar al rendimiento del algoritmo.

Algoritmos de aprendizaje supervisado de valor continuo

Bibliografía:

- Básica
 - [IMDRS] 4.1. “Algoritmos de aprendizaje supervisado”

EXAM=(2022J2.C.2, 2025J2.C.1)

En aprendizaje supervisado, cuando el atributo de clase toma valores continuos, el tipo de algoritmo adecuado es la regresión.

La regresión busca aprender una función que relacione los atributos de entrada con un valor numérico real de salida:

$$f(x) = y$$

donde x representa los atributos de la instancia e y es el atributo de clase continuo que se quiere predecir. Por ejemplo, a partir de datos de participación de un estudiante en un foro —número de mensajes, respuestas recibidas o centralidad— se podría predecir una nota numérica, el tiempo de permanencia en el curso o la probabilidad estimada de abandono.

En la asignatura se describe un único algoritmo de aprendizaje supervisado de valor continuo:

- Regresión

Regresión

Bibliografía:

- Básica
 - [IMDRS] 4.1. “Algoritmos de aprendizaje supervisado”
- Complementaria
 - Regresión lineal. Wikipedia
 - Logistic regression. Wikipedia
 - [SMMI] Apartado 5.4.5 “Regression”. Págs.122-124

La **regresión** es un método de predicción en el que a partir de unas variables explicatorias (x_i) se busca una función $F(x_i) = y$, donde y es una variable independiente representada con un número real.

La función de regresión puede ser:

- **Linear:** predice el resultado de una variable continua.
- **Logística:** predice el resultado de una variable categórica, es decir, que puede adoptar un número limitado de categorías, mediante un valor continuo de probabilidad.

La regresión logística se emplea habitualmente para resolver problemas de clasificación, puesto que el resultado final se transforma en una clase discreta. No obstante, internamente calcula un valor continuo, que suele ser una probabilidad entre 0 y 1.

Algoritmos de aprendizaje no supervisado

Bibliografía:

- Básica
 - [IMDRS] 4.2 “Algoritmos de aprendizaje no supervisado”
- Complementaria
 - [SMMI] 5.5 “Unsupervised Learning”. Págs. 127-133.
 - Algoritmo de agrupamiento. Wikipedia

EXAM=(2022J2.P.1.5, 2023J2.P.1, 2024S0.C.3, 2025S0.P.1.4)

Los **algoritmos de aprendizaje no supervisado** permiten dividir un conjunto de datos en grupos de instancias similares sin disponer de un atributo de clase conocido previamente. Esta característica resulta especialmente útil en medios sociales, donde los datos suelen carecer de etiquetas y no hay una clase que dé pistas sobre la agrupación de los datos.

Su principal dificultad es la evaluación: al no conocerse de antemano cuál sería la agrupación correcta, resulta más difícil comprobar la validez de los resultados.

Pasos para estudiar problemas de agrupamiento)

Bibliografía:

- Básica
 - [IMDRS] 4.2 “Algoritmos de aprendizaje no supervisado”
- Complementaria
 - [PR]

El principal tipo de aprendizaje no supervisado es el **agrupamiento** (*clustering*). Su objetivo es formar grupos o clústeres de modo que las instancias del mismo grupo sean semejantes entre sí y diferentes de las pertenecientes a otros grupos.

Los pasos para estudiar problemas de clustering según [PR]:

- **Selección de atributos:** deben escogerse los atributos que aporten información útil para la agrupación, evitando atributos irrelevantes o redundantes.

- **Medida de proximidad:** es necesario definir cómo se calculará la similitud o distancia entre instancias, por ejemplo mediante distancia euclídea, distancia de Manhattan o similitud del coseno. Según la medida elegida, puede ser conveniente normalizar previamente los atributos.
- **Criterio de agrupación:** una instancia puede asignarse a un único grupo, pertenecer a varios con distintas probabilidades o presentar distintos grados de pertenencia.
- **Algoritmo de agrupamiento:** se selecciona el método más adecuado en función de los datos y del tipo de agrupación buscado, por ejemplo, *k-means* para una partición en un número prefijado de grupos.
- **Validación de resultados:** como no existen etiquetas conocidas, la agrupación puede evaluarse comprobando que los grupos sean internamente **cohesivos** y estén bien **separados** entre sí. El **índice de silueta** combina ambas ideas.
- **Interpretación de resultados:** finalmente, los grupos obtenidos deben analizarse en relación con el problema estudiado, en muchos casos con apoyo de un experto del ámbito.

Métodos de verificación de aprendizaje no supervisado)

Bibliografía:

- Básica
 - [IMDRS] 4.2 “Algoritmos de aprendizaje no supervisado”
 - [MDMS] 5.5.2. Unsupervised Learning Evaluation. Pág. 130

EXAM(2024S0.C.3)

El aprendizaje no supervisado tiene la dificultad de que no existen muestras etiquetadas de test contra las que verificar los resultados del entrenamiento. No obstante se han desarrollado métodos de verificación empleados en aprendizaje no supervisado.

Métodos de verificación de agrupamiento vistos en [IMDRS]:

- Cohesión
- Separación
- Índice de silueta

Cohesión)

Bibliografía:

- Básica
 - [IMDRS] 4.2 “Algoritmos de aprendizaje no supervisado”
 - [MDMS] 5.5.2. “Unsupervised Learning Evaluation”. Págs. 130-131.

La **cohesión** (en inglés, *cohesiveness*) mide lo próximas que están entre sí las instancias pertenecientes a un mismo clúster. Puede calcularse mediante su distancia al centroide del grupo. Cuanto menores sean estas distancias, mayor será la cohesión.

Separación)

Bibliografía:

- Básica
 - [IMDRS] 4.2 “Algoritmos de aprendizaje no supervisado”
 - [MDMS] 5.5.2. “Unsupervised Learning Evaluation”. Pág. 131.

La **separación** (en inglés, *separateness*) mide lo alejados que se encuentran unos clústers de otros. Puede evaluarse mediante la distancia entre sus centroides. Cuanto mayor sea esta distancia, mejor estarán separados los grupos.

Índice de silueta)

Bibliografía:

- Básica
 - [IMDRS] 4.2 “Algoritmos de aprendizaje no supervisado”
 - [SMMI] 5.5.2. “Unsupervised Learning Evaluation”. Págs. 162-165 (PDF), 131-132 (impreso).

Índice de silueta (en inglés, *silhouette index*) combina cohesión y separación. Compara, para cada instancia, su distancia media respecto de las instancias de su propio grupo con su distancia respecto del grupo alternativo más próximo. Un valor elevado indica que la instancia está bien asignada: cerca de su clúster y alejada de los demás.

Aplicaciones

Bibliografía:

- Básica
 - [SMMI], parte III “Applications”.

El apartado de aplicaciones figura en el mapa conceptual del tema 3 y se considera cubierto por la parte III de [SMMI], si bien el material propio de la asignatura [IMDRS] no se desarrolla.

Hasta el curso 2024/2025, no ha entrado ninguna pregunta relacionada con este tema.

- Influencia
- Homofilia social
- Recomendaciones
- Comportamientos

Influencia

Bibliografía:

- Básica
 - [SMMI] 8.1. “Measuring Assortativity”. Págs. 218-225.
 - [SMMI] 8.2. “Influence”. Págs. 225-234.

Homofilia social (avanzado)

Bibliografía:

- Básica
 - [SMMI] 8.3 “Homophily”. Págs. 234-236
 - [SMMI] 8.4-8.7. 236-244

El concepto de homofilia social fue introducido en el tema 1 como mecanismo de la teoría de correlación social y también junto con el concepto de coeficiente de homofilia para la predicción de enlaces.

Recomendaciones

Bibliografía:

- Básica
 - [SMMI], 9 “Recommendations in Social Media”. Págs. 245-270.

Comportamientos

Bibliografía:

- Básica
 - [SMMI], 10 “Behavior analytics”. Págs. 271-294.

Bibliografía

- Básica
 - [IMDRS] RODRÍGUEZ ANAYA, Antonio. Introducción a la minería de datos en redes sociales, 2021-02-02.
 - [SMMI] ZAFARANI, Reza, ABBASI, Mohammad Ali, LIU, Huan Liu. Social media mining: An introduction. Cambridge University Press, 2014.
- Complementaria
 - [PR] S. Theodoridis, K. Koutroumbas. [Pattern Recognition]. Elsevier Academic Press, 2003.

- [HOML] GÉRON, Aurelien. Hands-on Machine Learning with Scikit-learn, Keras and TensorFlow. 3.^a ed. O'Reilly Media, 2022. ISBN: 9781098125967.

Licencia y atribución

License CC BY 4.0

Este trabajo está licenciado bajo la licencia **Creative Commons Atribución 4.0 Internacional**.

© 2026, Colaboradores de apuntes-muicd-uned.