

MDMS - Tema 3: Técnicas de minería de datos para redes sociales

Bibliografía:

- Básica
 - Apuntes tema 3 originales de la asignatura
 - ZAFARANI, Reza, ABBASI, Mohammad Ali, LIU, Huan Liu. Social media mining: An introduction. Cambridge University Press, 2014.
- Complementaria
 - GÉRON, Aurelien. Hands-on Machine Learning with Scikit-learn, Keras and TensorFlow. 3.^a ed. O'Reilly Media, 2022. ISBN: 9781098125967.

Introducción a la minería de datos para redes sociales

Bibliografía:

- Básica
 - Apuntes tema 3 originales de la asignatura

Fases de minería de los datos

Hay cuatro fases.

1. **Descubrimiento de conocimiento.** A partir de un conjunto de datos en crudo, se extrae una selección de los mismos.
2. **Preprocesamiento.** Sobre la selección de datos, se aplica un tratamiento para poder aplicar herramientas sobre ellos.
3. **Aplicación de herramientas.** Se aplican, por ejemplo, algoritmos, con el objetivo de obtener patrones de los datos.
4. **Evaluación.** Los patrones de datos se validan y verifican, analizándose también su relevancia.

Calidad de los datos

Ruido es una distorsión de los datos.

EXAM=(2023J2.C.3,2024SO.C.2)

Un **valor errático** es...

Un **Valor perdido** es...

Un **datos duplicado** es...

Proceso de minería de datos

Bibliografía:

- Básica
 - Apuntes tema 3 originales de la asignatura

Preprocesado de los datos

Bibliografía:

- Básica
 - Apuntes tema 3 originales de la asignatura

El **preprocesado de datos** se divide en procesos:

- Agregación
- Discretización
- Normalización estadística
- Selección de atributos
- Extracción de atributos
- Muestreo
- Eliminación de instancias con valores atípicos o erráticos

Agregación) La **agregación** es...

Discretización) La **discretización** es...

Normalización estadística) La **normalización estadística** es...

Selección de atributos) La **selección de atributos** es...

Extracción de atributos) EXAM=(2023SO.C.3)

La **extracción de atributos** significa transformar los atributos originales para crear un nuevo conjunto de atributos. Es decir, no se reducen necesariamente las instancias, sino que se cambia la forma de representar la información.

Un ejemplo sería a partir de textos de publicaciones en redes sociales, extraer atributos como número de palabras, frecuencia de términos, presencia de hash-tags, sentimiento, número de menciones o vectores TF-IDF.

Muestreo) EXAM=(2023SO.C.3)

El **muestreo** consiste en seleccionar un subconjunto de instancias del conjunto total cuando el conjunto de datos es muy grande o el proceso es costoso en tiempo o computación. La idea es trabajar con una muestra que se asume representativa del total.

Un ejemplo sería seleccionar al azar un conjunto de publicaciones entre todas las existentes en una red social.

Eliminación de instancias con valores atípicos o erráticos) La eliminación de instancias con valores atípicos o erráticos es...

Algoritmos de aprendizaje automático

EXAM=(2024J2.P.1)

Algoritmos de aprendizaje supervisado Bibliografía:

- Básica
 - Apuntes tema 3 originales de la asignatura
 - [SMMI]

EXAM=(2022J2.C.2)

Algoritmos de aprendizaje no supervisado Bibliografía:

- Básica
 - Apuntes tema 3 originales de la asignatura
 - [SMMI]

Se distinguen las dos clases de algoritmo de aprendizaje no supervisado

- De valor discreto
- De valor continuo

Algoritmos de aprendizaje no supervisado de valor discreto A:

- Árbol de decisión
- Naive Bayes
- Redes neuronales
- El vecino más cercano

Árbol de decisión

Árbol de decisión...

Naive Bayes

Naive Bayes...

Redes neuronales

Redes neuronales...

El vecino más cercano

El vecino más cercano...

Algoritmos de aprendizaje no supervisado de valor continuo EXAM=(2025J2.C.1)

En la asignatura se describe un único algoritmo de aprendizaje no supervisado de valor continuo:

- Regresión

Regresión

La **regresión** es un método de predicción en el que a partir de unas variables explicatorias (x_i) se busca una función $F(x_i) = y$, donde y es una variable independiente representada con un número real.

La función de regresión puede ser:

- **Linear**: predice el resultado de una variable continua.
- **Logística**: predice el resultado de una variable categórica, es decir, que puede adoptar un número limitado de categorías, mediante un valor continuo de probabilidad.

Aplicaciones

Bibliografía:

- Básica
 - Apuntes tema 3 originales de la asignatura
 - [SMMI], apartado III “Applications”

Influencia Bibliografía:

- Básica
 - [SMMI], 8.1-8.2. Págs. 257-277

Homofilia Bibliografía:

- Básica
 - [SMMI], 8.3-8.7. Págs. 278-288

Recomendaciones

- Básica
 - [SMMI], 9 “Recommendations in Social Media”

Comportamientos

- Básica
 - [SMMI], 10 “Behavior analytics”