

MDMS - Tema 3: Técnicas de minería de datos en redes sociales

La estructura de este tema trata de seguir la organización propuesta en el mapa conceptual del tema 3 de la asignatura junto con los apartados del material lectivo elaborado por el personal docente.

Fases de minería de los datos

Bibliografía:

- Básica
 - [IMDRS] Apartado 1 “Introducción”.

Hay cuatro fases.

1. **Descubrimiento de conocimiento.** A partir de un conjunto de datos en crudo, se extrae una selección de los mismos.
2. **Preprocesamiento.** Sobre la selección de datos, se aplica un tratamiento para poder aplicar herramientas sobre ellos.
3. **Aplicación de herramientas.** Se aplican, por ejemplo, algoritmos, con el objetivo de obtener patrones de los datos.
4. **Evaluación.** Los patrones de datos se validan y verifican, analizándose también su relevancia.

Calidad de los datos

Bibliografía:

- Básica
 - [IMDRS] Apartado 2.1 “Calidad de los datos”.

Incluye cuatro definiciones:

- Ruido
- Valor errático
- Valor perdido
- Valor duplicado

Ruido Bibliografía:

- Básica
 - [IMDRS] Apartado 2.1 “Calidad de los datos”.

EXAM=(2023J2.C.3,2024J2.C.2)

El **ruido** es la presencia de datos, contenidos o relaciones que dificultan extraer patrones fiables en una tarea de minería de datos. En los medios sociales aparece con frecuencia porque los usuarios generan libremente contenidos de calidad muy

variable y porque las relaciones establecidas en la red no siempre representan vínculos sociales significativos.

El ruido puede afectar tanto a los **contenidos** como a las **relaciones sociales**. Son ejemplos de datos ruidosos los mensajes de *spam*, publicaciones duplicadas o irrelevantes, errores y expresiones difíciles de interpretar, cuentas automatizadas o enlaces creados indiscriminadamente que mezclan relaciones superficiales con vínculos reales de amistad, afinidad o confianza.

Para tratar el ruido suele realizarse un preprocesado de los datos. Sin embargo, debe tenerse en cuenta el objetivo del análisis, porque un dato considerado ruido en una tarea puede ser relevante en otra: por ejemplo, una cuenta con actividad anómala podría eliminarse al estudiar el comportamiento habitual de los usuarios, pero sería fundamental en una tarea de detección de *spammers*.

Valor errático Bibliografía:

- Básica
 - [IMDRS] Apartado 2.1 “Calidad de los datos”.

Los **valores erráticos o atípicos** son instancias que presentan valores muy alejados o diferentes de los habituales en el conjunto de datos. Por ejemplo, en una red educativa, un estudiante que publique cientos de mensajes en pocas horas podría ser un caso atípico frente al comportamiento general.

Estos valores pueden eliminarse si proceden de errores o distorsionan el análisis, pero no deben descartarse automáticamente: según la tarea, pueden representar información relevante, como un usuario extremadamente activo, un *spammer* o un comportamiento anómalo que se desea detectar.

Valor perdido Bibliografía:

- Básica
 - [IMDRS] Apartado 2.1 “Calidad de los datos”.

Los **valores perdidos** aparecen cuando una instancia no tiene información disponible para alguno de sus atributos. Este problema es habitual en medios sociales, ya que los usuarios pueden no proporcionar determinados datos o restringir su acceso mediante opciones de privacidad.

Ante valores perdidos pueden adoptarse distintas estrategias: eliminar las instancias incompletas, estimar los valores ausentes o utilizar algoritmos capaces de trabajar sin ellos. La elección depende de la cantidad de información que falta, de su importancia para la tarea y del algoritmo que vaya a aplicarse.

Dato duplicado Bibliografía:

- Básica

- [IMDRS] Apartado 2.1 “Calidad de los datos”.

Los **datos duplicados** aparecen cuando distintas instancias tienen los mismos valores en todos sus atributos o cuando un mismo registro se incorpora varias veces al conjunto de datos. Por ejemplo, una publicación podría recogerse repetida al combinar información obtenida de varias fuentes.

Los duplicados pueden eliminarse cuando son errores de recopilación que alterarían los resultados. Sin embargo, en algunas tareas la repetición puede tener significado propio, como cuando varios usuarios comparten el mismo contenido o cuando interesa medir la difusión de un mensaje.

Proceso de minería de datos

Bibliografía:

- Básica
 - [IMDRS]
 - [SMMI]

El apartado de proceso de minería de datos engloba prácticamente todo el tema 3, si quitamos la introducción.

Preprocesado de los datos

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preprocesado de datos”

La sección de procesado de datos está marcada como “concepto básico” en el mapa conceptual del tema 3.

El **preprocesado de datos** se divide en procesos:

- Agregación
- Discretización
- Normalización estadística
- Selección de atributos
- Extracción de atributos
- Muestreo
- Eliminación de instancias con valores atípicos o erráticos

Agregación) La **agregación** consiste en combinar varios atributos en uno nuevo o en resumir datos a una escala diferente. Por ejemplo, el número de mensajes enviados por un estudiante cada día puede agregarse para obtener su actividad total semanal.

Discretización) Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.
 - Discretización. Wikipedia.

La **discretización** transforma un atributo continuo en un conjunto limitado de categorías. Por ejemplo, una variable numérica como el número de mensajes publicados puede convertirse en los valores **actividad baja**, **actividad media** y **actividad alta**.

Normalización estadística) Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.
 - Discretización. Wikipedia.

La **normalización** adapta los valores de distintos atributos a una escala comparable, evitando que los atributos con valores numéricos mayores tengan más influencia únicamente por su rango. Por ejemplo, el número de mensajes y el número de respuestas recibidas pueden transformarse para que ambos tomen valores entre 0 y 1.

Selección de atributos) Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.

La **selección de atributos** consiste en conservar únicamente los atributos que resulten útiles para la tarea de análisis, descartando los irrelevantes, redundantes o demasiado costosos de procesar. Por ejemplo, para estudiar la participación en un foro podrían seleccionarse el número de mensajes, las respuestas recibidas y la centralidad del estudiante.

Extracción de atributos) EXAM=(2023S0.C.3)

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.

La **extracción de atributos** significa transformar los atributos originales para crear un nuevo conjunto de atributos. Es decir, no se reducen necesariamente las instancias, sino que se cambia la forma de representar la información.

Un ejemplo sería a partir de textos de publicaciones en redes sociales, extraer atributos como número de palabras, frecuencia de términos, presencia de hash-tags, sentimiento, número de menciones o vectores TF-IDF.

Muestreo) EXAM=(2023S0.C.3)

Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.

El **muestreo** consiste en seleccionar un subconjunto de instancias del conjunto total cuando el conjunto de datos es muy grande o el proceso es costoso en tiempo o computación. La idea es trabajar con una muestra que se asume representativa del total.

Un ejemplo sería seleccionar al azar un conjunto de publicaciones entre todas las existentes en una red social.

Eliminación de instancias con valores atípicos o erráticos) Bibliografía:

- Básica
 - [IMDRS] Apartado 3 “Preproceso de datos”. Pág. 3.
 - Distribución normal. Wikipedia.

Los **valores atípicos** son instancias que presentan valores muy diferentes de los habituales en el conjunto de datos. Pueden eliminarse cuando distorsionan el análisis, pero no deben descartarse automáticamente, ya que en algunos problemas constituyen precisamente la información de interés. Por ejemplo, una cuenta con una actividad extraordinariamente alta podría ser ruido en un estudio del comportamiento medio, pero resultar relevante en una investigación sobre spammers o usuarios anómalos.

Algoritmos de aprendizaje automático

Bibliografía:

- Básica
 - [IMDRS]
 - [SMMI]

La sección de procesado de datos está marcada tanto como “concepto básico” como “avanzado” en el mapa conceptual del tema 3, lo que se puede interpretar como que introduce conceptos de ambas categorías.

EXAM=(2024J2.P.1.3,2025J2.P.1.3)

Una pregunta habitual en problemas de exámenes es indicar técnicas de aprendizaje automático que fuera conveniente.

Algoritmos de aprendizaje supervisado Bibliografía:

- Básica
 - [IMDRS]
 - [SMMI]

EXAM=(2022J2.C.2, 2022J2.P.1.4, 2023J2.P.1, 2025S0.P.1.4)

Algoritmos de aprendizaje no supervisado Bibliografía:

- Básica
 - [IMDRS]
 - [SMMI]

EXAM=(2022j2.p.1.5, 2023j2.p.1, 2024so.c.3, 2025so.p.1.4)

Se distinguen las dos clases de algoritmo de aprendizaje no supervisado

- De valor discreto
- De valor continuo

Algoritmos de aprendizaje no supervisado de valor discreto Algoritmos de aprendizaje no supervisado de valor discreto:

- Árbol de decisión
- Naive Bayes
- Redes neuronales
- El vecino más cercano

Árbol de decisión

Árbol de decisión...

Naive Bayes

Naive Bayes...

Redes neuronales

Redes neuronales...

El vecino más cercano

El vecino más cercano (en inglés, *k-nearest neighbor*)...

Algoritmos de aprendizaje no supervisado de valor continuo

EXAM=(2025J2.C.1)

En la asignatura se describe un único algoritmo de aprendizaje no supervisado de valor continuo:

- Regresión

Regresión

La **regresión** es un método de predicción en el que a partir de unas variables explicatorias (x_i) se busca una función $F(x_i) = y$, donde y es una variable independiente representada con un número real.

La función de regresión puede ser:

- **Linear**: predice el resultado de una variable continua.
- **Logística**: predice el resultado de una variable categórica, es decir, que puede adoptar un número limitado de categorías, mediante un valor continuo de probabilidad.

Aplicaciones

Bibliografía:

- Básica
 - [SMMI], parte III “Applications”.

El apartado de aplicaciones figura en el mapa conceptual del tema 3 y se considera cubierto por la parte III de [SMMI], si bien el material propio de la asignatura [IMDRS] no se desarrolla.

Hasta el curso 2024/2025, no ha entrado ninguna pregunta relacionada con este tema.

Influencia Bibliografía:

- Básica
 - [SMMI] 8.1. “Measuring Assortativity”. Págs. 218-225.
 - [SMMI] 8.2. “Influence”. Págs. 225-234.

Homofilia Bibliografía:

- Básica
 - [SMMI] 8.3 “Homophily”. Págs. 234-236
 - [SMMI] 8.4-8.7. 236-244

El concepto de homofilia social fue introducido brevemente en el tema 1, como mecanismo de la teoría de correlación social.

EXAM=(2024SO.C.2)

Recomendaciones

- Básica
 - [SMMI], 9 “Recommendations in Social Media”. Págs. 245-270.

Comportamientos

- Básica
 - [SMMI], 10 “Behavior analytics”. Págs. 271-294.

Bibliografía

- Básica
 - [IMDRS] RODRÍGUEZ ANAYA, Antonio. Introducción a la minería de datos en redes sociales, 2021-02-02.
 - [SMMI] ZAFARANI, Reza, ABBASI, Mohammad Ali, LIU, Huan Liu. Social media mining: An introduction. Cambridge University Press, 2014.
- Complementaria
 - [HOML] GÉRON, Aurelien. Hands-on Machine Learning with Scikit-learn, Keras and TensorFlow. 3.^a ed. O'Reilly Media, 2022. ISBN: 9781098125967.

Licencia y atribución

License CC BY 4.0

Este trabajo está licenciado bajo la licencia **Creative Commons Atribución 4.0 Internacional**.

© 2026, Colaboradores de apuntes-muicd-uned.