

MDMS.EX.2022J2

MDMS.EX.2022J2.C.1

Enunciado MDMS.EX.2022J2.C.1

Cuestión (2 puntos)

De acuerdo con la teoría del estatus en redes sociales, describa qué se entiende por un enlace positivo entre dos personas usuarias. Explique su interpretación dentro de la red. Además, indique qué tipo de patrones o configuraciones son más probables cuando aparecen nuevos enlaces según dicha teoría.

Solución MDMS.EX.2022J2.C.1

En la teoría del estatus, un enlace positivo entre dos usuarios u_1 y u_2 es una relación dirigida en la que el signo positivo indica una valoración favorable desde el nodo origen hacia el nodo destino.

Un enlace positivo $u_1 \rightarrow u_2$ significa que el usuario u_2 posee un estatus social superior al de u_1 . Es decir, el enlace positivo implica una diferencia jerárquica en la que el usuario origen reconoce mayor prestigio, autoridad u honor al usuario destino.

Desde el punto de vista estructural:

Si $u_1 \rightarrow u_2$ es positivo, entonces $\text{estatus}(u_2) > \text{estatus}(u_1)$

Cuando se forman nuevos enlaces entre usuarios, la teoría del estatus establece que es más probable que:

- Los usuarios con menor estatus establezcan enlaces hacia usuarios con mayor estatus.
- La dirección de los nuevos enlaces siga una jerarquía ascendente.

Por tanto, los nuevos enlaces tienden a formarse desde nodos de bajo estatus hacia nodos de alto estatus, reforzando la estructura jerárquica de la red.

MDMS.EX.2022J2.C.2

Enunciado MDMS.EX.2022J2.C.2

Cuestión (2 puntos)

En el aprendizaje supervisado se trabaja con una variable objetivo o de clase. Esta variable puede tomar valores categóricos finitos o valores numéricos continuos. Indique qué familias de algoritmos son adecuadas cuando la variable

de clase es continua. Justifique su respuesta e incluya al menos un ejemplo ilustrativo.

Solución MDMS.EX.2022J2.C.2

Cuando el atributo de clase toma valores continuos dentro de $\mathbb{R}$, el tipo de algoritmo adecuado es la regresión, que pertenece al aprendizaje supervisado.

En estos casos el objetivo no es clasificar instancias en categorías discretas, sino estimar una función:

$$f(x_i) = y$$

donde x_i representa el vector de atributos de entrada y y es una variable dependiente continua.

Los principales tipos de algoritmos que utilizan atributo de clase continuo son:

- Regresión lineal: asume una relación lineal entre las variables independientes y la variable dependiente.
- Regresión logística (cuando se modela una probabilidad, aunque su salida final sea categórica, internamente modela una variable continua).
- Redes neuronales en modo regresión, cuando la capa de salida no está discretizada.

Por ejemplo, si se desea predecir el número de intervenciones futuras de un estudiante en un foro (valor real no acotado), se utilizaría regresión lineal o una red neuronal de regresión.

La justificación radica en que los algoritmos de clasificación solo pueden asignar etiquetas discretas, mientras que los algoritmos de regresión modelan funciones continuas que permiten estimar valores reales.

MDMS.EX.2022J2.C.3

Enunciado MDMS.EX.2022J2.C.3

Cuestión (2 puntos)

Defina el concepto de matriz de adyacencia en el contexto de grafos. Describa el procedimiento general para construirla. Explique las diferencias estructurales entre la matriz asociada a un grafo dirigido y la de un grafo no dirigido. Finalmente, argumente si esta representación es adecuada para modelar grafos que cambian con el tiempo.

Solución MDMS.EX.2022J2.C.3

Una matriz de adyacencia es una representación matricial de un grafo $G(V, E)$ en la que filas y columnas representan los nodos y las celdas indican la existencia o peso de una arista entre dos nodos.

Si el grafo tiene n nodos, la matriz de adyacencia A es una matriz cuadrada de dimensión $n \times n$ tal que:

$$A_{ij} = \begin{cases} 1 & \text{si existe arista entre } v_i \text{ y } v_j \\ 0 & \text{si no existe} \end{cases}$$

En grafos con peso, A_{ij} puede tomar valores reales que representen la intensidad de la relación.

La diferencia entre grafos dirigidos y no dirigidos es:

- En un grafo no dirigido, la matriz es simétrica:

$$A_{ij} = A_{ji}$$

- En un grafo dirigido, la matriz no es necesariamente simétrica, ya que la existencia de $v_i \rightarrow v_j$ no implica $v_j \rightarrow v_i$.

Respecto a grafos dinámicos, sí es posible representarlos mediante matrices de adyacencia, pero no con una única matriz estática. Sería necesario:

- Utilizar una secuencia temporal de matrices $A(t)$.
- O bien una estructura tridimensional donde el tercer eje represente el tiempo.

Por tanto, la matriz de adyacencia permite representar grafos dinámicos siempre que se incorpore explícitamente la dimensión temporal.

MDMS.EX.2022J2.P.1

Enunciado MDMS.EX.2022J2.P.1

Problema (4 puntos)

Se le encarga diseñar una aplicación de *Learning Analytics* centrada en el análisis de interacciones entre estudiantes en foros, donde la comunicación es asíncrona y dirigida. El objetivo es seleccionar o proponer un método que permita estimar la similitud entre pares de estudiantes utilizando ejemplos históricos previamente etiquetados por el profesorado. Responda de forma razonada:

- Describa qué se entiende por similitud entre dos usuarios dentro de una red social. Indique si es posible cuantificarla y cómo podría hacerse.

- Presente con detalle su propuesta de agrupamiento o comparación entre estudiantes.
- Analice si resulta pertinente incorporar técnicas de análisis de redes sociales. En caso afirmativo, especifique qué métricas consideraría y por qué.
- Evalúe la necesidad de emplear métodos de aprendizaje supervisado y justifique su decisión.
- Evalúe la conveniencia de aplicar métodos de aprendizaje no supervisado y justifique su respuesta.

Solución MDMS.EX.2022J2.P.1

Solución MDMS.EX.2022J2.P.1.1

La similitud entre dos usuarios indica hasta qué punto dos estudiantes se parecen según sus características o su comportamiento en la red. En este caso, no se mediría solo por datos personales, sino por sus interacciones en los foros: a quién responden, quién les responde, con qué frecuencia participan, si intervienen en los mismos hilos, si tienen vecinos comunes, etc.

En análisis de redes sociales, la similitud entre dos nodos puede entenderse como equivalencia estructural, es decir, como el parecido entre sus vecindarios. Una forma sencilla de cuantificarla es contar cuántos vecinos comparten ambos nodos.

Se calcularía la similitud entre estudiantes a partir de un vector de atributos para cada estudiante o cada par. Adicionalmente, se pueden aplicar algoritmos de agrupamiento.

Solución MDMS.EX.2022J2.P.1.2

Como propuesta de agrupación, se podría construir una red dirigida donde cada estudiante es un nodo y se añade una arista dirigida cada vez que un estudiante responde a otro, estableciendo la dirección de la respuesta. El peso de la arista sería el número de respuestas.

Solución MDMS.EX.2022J2.P.1.3

Sería necesario en análisis de redes sociales porque el problema se centra en las interacciones entre estudiantes, no solo en atributos individuales. El análisis de redes sociales permite modelar esas interacciones como un grafo y extraer métricas útiles para describir la posición de cada estudiante y la relación entre pares de estudiantes.

Se propone emplear estas métricas:

- **Grado de entrada / de salida:** puede interpretarse como sociabilidad.

- **Intermediación:** Detecta estudiantes que hacen de puente entre grupos o conversaciones/
- **Cercanía:** mide si un estudiante está cerca del resto de la red y puede acceder fácilmente a información.
- **PageRank:** ya que el grafo es dirigido, permite valorar la importancia del estudiante según quién interactúa con él.
- **Reciprocidad:** ya que el grafo es dirigido, permite comprobar si el usuario responde o si es respondido.

Todas ellas se consideran métricas de red útiles para medir la importancia o posición de los nodos.

Solución MDMS.EX.2022J2.P.1.4

El enunciado indica que hay ejemplos pasados etiquetados manualmente por profesores, por lo que la opción principal debe ser aprendizaje supervisado.

Se puede construir un conjunto de datos de pares (u, v) con etiqueta “similares / no similares” y aplicar clasificación (árboles de decisión, regresión logística, redes neuronales).

Solución MDMS.EX.2022J2.P.1.5

También puede ser útil aprendizaje no supervisado para detectar comunidades implícitas mediante clustering y validar la coherencia estructural de los grupos detectados.
