

MDMS.EX.2023SO

MDMS.EX.2023SO.C.1

Enunciado MDMS.EX.2023SO.C.1

Cuestión (2 puntos)

En la minería de datos aplicada a medios sociales aparece el llamado dilema de la evaluación. Explique en qué consiste este problema, por qué surge y cuáles son sus implicaciones a la hora de validar resultados. Argumente su respuesta.

Solución MDMS.EX.2023SO.C.1

El dilema de la evaluación en minería de datos de medios sociales consiste en que los procedimientos estándar para evaluar patrones o modelos (por ejemplo, dividir los datos en conjuntos de entrenamiento y prueba) no suelen ser directamente aplicables debido a la propia naturaleza de los datos sociales.

Las razones principales son:

- Los datos están enlazados (dependencias entre usuarios, relaciones y contenidos), por lo que la separación en subconjuntos rompe dependencias estructurales y puede introducir sesgos o fugas de información entre entrenamiento y prueba.
- La información suele ser incompleta y ruidosa, lo que dificulta definir un “ground truth” estable y representativo para validar resultados.
- El acceso a los datos suele ser parcial (por ejemplo, por limitaciones de APIs), de modo que no se puede asegurar que el conjunto disponible sea representativo del fenómeno real, y por tanto la evaluación puede no generalizar.

En consecuencia, se necesita algún medio alternativo para evaluar la calidad de los patrones inferidos (validación externa, validación temporal, experimentos controlados, evaluación con expertos, métricas indirectas), porque sin evaluación no se puede estimar la validez y utilidad de los resultados.

MDMS.EX.2023SO.2

Enunciado MDMS.EX.2023SO.C.2

Cuestión (2 Puntos)

El análisis de redes sociales es una herramienta habitual para estudiar entornos educativos en línea. Las interacciones entre participantes pueden modelarse como una red donde los nodos representan personas y los enlaces representan

sus intercambios. Dentro de este marco se emplean métricas de centralidad para caracterizar el papel de cada participante. Describa las principales métricas de centralidad, su definición y qué información aportan sobre la estructura de la red.

Solución MDMS.EX.2023SO.C.2

Las métricas de centralidad cuantifican la importancia de un nodo dentro de una red. Capturan diferentes nociones de “relevancia” según cómo se define el papel del nodo en la estructura.

- Centralidad de grado: mide la importancia por número de conexiones directas. En grafos no dirigidos es el número de aristas incidentes; en grafos dirigidos se distingue:
 - Grado de entrada (in-degree): número de aristas que llegan al nodo (popularidad).
 - Grado de salida (out-degree): número de aristas que salen del nodo (sociabilidad).
- Centralidad de cercanía (closeness): mide lo cerca que está un nodo del resto, como inverso de la suma de distancias más cortas desde el nodo a todos los demás. Refleja capacidad de acceso rápido a la información en la red.
- Centralidad de intermediación (betweenness): cuantifica cuántas veces un nodo actúa como puente en los caminos más cortos entre otros pares de nodos. Un nodo con alta intermediación controla o facilita el flujo entre partes de la red.
- Centralidad del vector propio (eigenvector): asigna alta centralidad a nodos conectados a otros nodos también importantes. No solo cuenta conexiones, sino la “calidad” estructural de a quién se está conectado.
- PageRank: variante para grafos dirigidos que reparte la importancia de un nodo entre sus enlaces salientes, evitando que la autoridad se transfiera íntegra a todos los vecinos. Mide relevancia global en redes dirigidas.
- HITS: asigna dos puntuaciones por nodo, authority (ser destino de buenos hubs) y hub (apuntar a buenas authorities), capturando roles complementarios en grafos dirigidos.

MDMS.EX.2023SO.C.3

Enunciado MDMS.EX.2023SO.C.3

Cuestión (2 puntos)

Explique las diferencias entre los procesos de extracción de atributos y el muestreo en el análisis de datos. Incluya un ejemplo que ilustre cada uno de

estos procesos.

Solución MDMS.EX.2023SO.C.3

La extracción de atributos y el muestreo son procesos distintos porque actúan sobre dimensiones diferentes del dataset:

- Extracción de atributos: transforma el espacio de características construyendo nuevos atributos a partir de los existentes, con el objetivo de representar mejor la información relevante, reducir redundancia o capturar estructuras latentes. El número de instancias suele mantenerse, pero cambian los atributos (se sustituyen o se añaden transformaciones).
 - Ejemplo: a partir de mensajes de foro, crear atributos como TF-IDF por término, embeddings, número de respuestas emitidas/recibidas, centralidades de red, o transformar múltiples variables en componentes principales.
- Muestreo: reduce el número de instancias (filas) seleccionando un subconjunto del total cuando el conjunto es grande o el procesamiento es costoso, suponiendo que la muestra es representativa. Los atributos se mantienen (o se mantienen esencialmente), pero se reducen los observables.
 - Ejemplo: de todos los hilos del foro del curso, seleccionar aleatoriamente un 20% de hilos para análisis exploratorio; o seleccionar una muestra estratificada de alumnos (por actividad baja/media/alta) para entrenar un modelo inicial.

MDMS.EX.2023SO.P.1

Enunciado MDMS.EX.2023SO.P.1

Problema (4 puntos)

Forma parte de una empresa dedicada al software educativo y debe desarrollar un sistema que analice las interacciones del alumnado para supervisar el trabajo en equipo e identificar grupos con alto nivel de cohesión. El escenario educativo presenta estas características: aprendizaje colaborativo, equipos de hasta ocho integrantes, comunicación mediante foros donde se registra quién responde a quién, evaluación automática del rendimiento grupal, y la idea de que un equipo cohesionado muestra interacción completa entre sus miembros y niveles similares de participación y relevancia. Diseñe un procedimiento de análisis lo más automatizado posible para evaluar la cohesión de cada equipo. Indique qué datos emplearía, qué técnicas aplicaría y cómo estructuraría el algoritmo de evaluación, justificando sus decisiones.

Solución MDMS.EX.2023SO.P.1

El objetivo es evaluar automáticamente la cohesión de cada equipo a partir de las interacciones del foro. Para ello, representaría cada foro como una red social dirigida y ponderada: cada alumno sería un nodo y cada respuesta de un alumno a otro sería una arista dirigida. El peso de la arista podría representar el número de respuestas entre ambos.

Datos utilizados Para cada equipo recogería:

- alumno que escribe;
- alumno al que responde;
- número de respuestas o interacciones;
- fecha de los mensajes;
- equipo al que pertenece cada alumno.

Con estos datos construiría una red independiente para cada equipo.

Técnicas de análisis Aplicaría técnicas de **análisis de redes sociales** para medir la cohesión interna del equipo:

- **Densidad:** mide si los miembros se comunican con muchos de los demás. Si todos interactúan con todos, la densidad será alta.
- **Reciprocidad:** comprueba si las relaciones son mutuas, es decir, si no solo un alumno escribe a otro, sino que existe intercambio.
- **Grado de entrada y salida:** permite medir la actividad de cada alumno. El grado de salida indica cuánto responde; el grado de entrada, cuánto le responden.
- **Centralidad de grado:** ayuda a comparar la participación de los miembros.
- **PageRank o HITS:** miden la relevancia o prestigio de cada alumno dentro del equipo.
- **Intermediación:** permite detectar si la comunicación depende demasiado de uno o pocos alumnos puente.

Además, compararía la variabilidad de estas métricas entre los miembros. Un equipo estará más cohesionado si todos tienen niveles parecidos de actividad y relevancia.

Algoritmo de análisis de la cohesión El procedimiento automático sería:

1. Separar los mensajes por equipo.
2. Construir para cada equipo un grafo dirigido y ponderado.
3. Calcular su matriz de adyacencia.
4. Calcular densidad, reciprocidad, grados de entrada y salida, PageRank/HITS e intermediación.
5. Normalizar las métricas para poder compararlas.

6. Medir la desigualdad entre alumnos mediante la desviación típica de sus grados y centralidades.
7. Asignar una puntuación final de cohesión.

La puntuación podría seguir esta idea:

cohesión = alta densidad+alta reciprocidad+baja desigualdad en actividad+baja desigualdad en relevancia−a

Un equipo bien cohesionado sería aquel en el que casi todos los alumnos interactúan con todos, las comunicaciones son recíprocas y ningún alumno concentra toda la actividad o relevancia. En cambio, un equipo poco cohesionado tendría baja densidad, alumnos aislados, participación desigual o comunicación centralizada en uno o dos miembros.

Por tanto, la aplicación evaluaría la cohesión calculando métricas de análisis de redes sociales sobre cada foro y combinándolas en un índice automático de cohesión.