

MDMS.EX.2024SO

MDMS.EX.2024SO.C.1

Enunciado MDMS.EX.2024SO.C.1

Cuestión (2 puntos)

Dentro del análisis de redes sociales existen múltiples métricas para caracterizar la relevancia de los nodos. Una de ellas es el algoritmo HITS. Explique su fundamento, qué magnitudes calcula y cómo se interpretan sus resultados en una red.

Solución MDMS.EX.2024SO.C.1

HITS (Hypertext Induced Topic Selection) es un algoritmo de análisis de enlaces para grafos dirigidos que asigna a cada nodo dos puntuaciones:

- Authority (autoridad): mide cuán valiosa/relevante es la información del nodo. Un nodo tendrá alta autoridad si recibe enlaces de nodos que son buenos hubs.
- Hub (concentrador): mide la calidad de los enlaces salientes del nodo. Un nodo será buen hub si enlaza a nodos que son buenas autoridades.

La idea es de refuerzo mutuo: los buenos hubs apuntan a buenas autoridades y las buenas autoridades son apuntadas por buenos hubs.

Si A es la matriz de adyacencia dirigida (con $A_{ij} = 1$ si $i \rightarrow j$), las actualizaciones típicas se expresan como:

$$a = A^T h h = A a$$

Tras iterar y normalizar, se obtienen los valores finales de a (autoridades) y h (hubs) que permiten identificar nodos “referencia” (authority) y nodos “distribuidores” (hub) en la red.

MDMS.EX.2024SO.C.2

Enunciado MDMS.EX.2024SO.C.2

Cuestión (2 puntos)

Suponga que la homofilia entre dos nodos de una red social se interpreta como la cercanía entre ellos dentro de un espacio relacional implícito, donde menor distancia implica mayor afinidad. Describa cómo podría estimarse este coeficiente utilizando técnicas de análisis de redes sociales y justifique el procedimiento.

Solución MDMS.EX.20243SO.C.2

La homofilia social es la tendencia de los usuarios similares a establecer relaciones entre sí. Para calcular un coeficiente de homofilia entre dos nodos, se puede representar a cada usuario en un espacio implícito construido a partir de la información de la red, por ejemplo, sus relaciones, vecinos comunes o patrones de interacción.

Una vez representados los usuarios u_i y u_j en dicho espacio, se calcula la distancia entre ellos, por ejemplo mediante una distancia euclídea:

$$d(u_i, u_j)$$

Como el enunciado indica que una homofilia más fuerte corresponde a una distancia menor, el coeficiente debe variar de forma inversa a dicha distancia. Una posible definición normalizada es:

$$H(u_i, u_j) = \frac{1}{1 + d(u_i, u_j)}$$

De este modo, si dos usuarios están muy próximos en el espacio implícito, su distancia será pequeña y su coeficiente de homofilia será alto; si están alejados, el coeficiente será bajo.

La justificación es que, según la teoría de correlación social, los usuarios similares tienden a relacionarse. Por tanto, para dos usuarios que todavía no estén conectados, un coeficiente de homofilia elevado indicaría una mayor probabilidad de que en el futuro se forme un enlace directo entre ellos.

MDMS.EX.2024SO.C.3

Enunciado MDMS.EX.2024SO.C.3

Cuestión (2 Puntos)

Uno de los desafíos del aprendizaje no supervisado es evaluar la calidad de los resultados cuando no se dispone de etiquetas de referencia. Explique qué factores deben considerarse para llevar a cabo una verificación adecuada y razone su respuesta.

Solución MDMS.EX.20243SO.C.3

El principal problema del aprendizaje no supervisado es la verificación porque no existe una etiqueta de clase que permita comparar directamente el resultado con un “valor correcto” esperado.

Para una verificación adecuada hay que considerar principalmente:

- Cohesión intra-cluster: interesa que las instancias dentro de cada grupo estén cerca entre sí. En términos de clustering, equivale a baja dispersión o baja distancia media al centroide. Cuanto mayor cohesión, más consistente el grupo.
- Separación inter-cluster: interesa que los clusters estén bien separados entre sí. La verificación debe asegurar que los centroides (o distribuciones) de los clusters estén suficientemente lejos, evitando solapamiento excesivo entre grupos.
- Índice de silueta: compara, para cada instancia, la distancia media a su propio cluster con la distancia media al cluster más cercano, ofreciendo una medida global de calidad. Valores altos indican buena cohesión y buena separación.

La razón de estos factores es que, sin etiquetas, la “calidad” del clustering se evalúa por propiedades geométricas/estructurales: grupos compactos y bien diferenciados son más plausibles como patrón útil, mientras que grupos dispersos y solapados suelen ser artefactos.

MDMS.EX.2024SO.P.1

Enunciado MDMS.EX.2024SO.P.1

Problema (4 puntos)

Una compañía que gestiona la red de metro de una gran ciudad solicita un análisis basado únicamente en la estructura de su red. Las estaciones se modelan como nodos y las conexiones bidireccionales entre estaciones como enlaces. Se pide elaborar un informe que permita responder razonadamente a las siguientes cuestiones:

1. Identificar qué estaciones pueden considerarse más representativas dentro de la red.
2. Determinar en qué estaciones una interrupción del servicio tendría mayor impacto global.
3. Señalar qué estaciones podrían sufrir una interrupción con el menor efecto sobre el funcionamiento general.

Describa el enfoque de análisis que utilizaría y justifique sus decisiones.

Solución MDMS.EX.2024SO.P.1

Representaría la red de metro como un **grafo no dirigido**, donde cada estación es un **nodo** y cada conexión directa entre dos estaciones es una **arista**. Como las conexiones funcionan en los dos sentidos, no sería necesario usar un grafo dirigido.

Al tener solo información de la estructura de la red, el análisis debe basarse en

métricas de análisis de redes sociales, especialmente métricas de centralidad.

1. Estaciones más representativas del metro Para identificar las estaciones más representativas usaría medidas de **centralidad**.

En primer lugar, calcularía la **centralidad de grado**, que mide cuántas conexiones directas tiene cada estación. Una estación con grado alto conecta con muchas otras estaciones, por lo que puede considerarse importante dentro de la red.

También calcularía la **centralidad de cercanía**, que mide qué tan cerca está una estación del resto de estaciones de la red. Una estación con alta cercanía puede llegar al resto de la red mediante pocos pasos, por lo que sería una estación muy representativa del sistema en conjunto.

Además, podría utilizar **centralidad del vector propio** o **PageRank**, para detectar estaciones importantes no solo por tener muchas conexiones, sino por estar conectadas con otras estaciones también importantes.

Por tanto, las estaciones más representativas serían aquellas con valores altos de grado, cercanía y centralidad del vector propio/PageRank.

2. Estaciones donde un problema sería más grave Para detectar las estaciones donde un corte sería más problemático usaría sobre todo la **centralidad de intermediación**.

La intermediación mide cuántos caminos mínimos entre pares de estaciones pasan por una estación concreta. Si una estación tiene alta intermediación, significa que actúa como puente entre distintas zonas de la red. Por tanto, si se corta, puede dificultar mucho la comunicación entre partes del metro.

También comprobaría si la estación es un **punto de articulación**, es decir, si al eliminarla la red queda dividida en componentes desconectados. En ese caso, el problema sería especialmente grave, porque algunas estaciones quedarían aisladas o habría que hacer grandes rodeos.

Por tanto, las estaciones más críticas serían aquellas con alta intermediación y cuya eliminación aumente mucho la distancia media entre estaciones o desconecte partes de la red.

3. Estaciones donde un corte sería menos problemático Las estaciones donde un problema sería menos problemático serían las estaciones periféricas o redundantes.

Estas estaciones tendrían normalmente:

- baja centralidad de grado;
- baja centralidad de intermediación;
- baja centralidad de cercanía;

- poca participación en caminos mínimos;
- rutas alternativas cercanas.

Si una estación tiene baja intermediación, significa que pocos trayectos entre otras estaciones dependen de ella. Por tanto, su cierre afectaría sobre todo a esa estación o a una zona pequeña, pero no al funcionamiento general de la red.

También serían menos problemáticas las estaciones que no sean puntos de articulación y cuya eliminación no desconecte la red ni aumente mucho las distancias entre estaciones.

Conclusión Usaría el grafo no dirigido del metro y calcularía métricas de centralidad. Las estaciones más representativas serían las más centrales según grado, cercanía y PageRank/vector propio. Las estaciones más críticas ante un fallo serían las de mayor intermediación o las que actúan como puntos de articulación. Finalmente, las estaciones menos problemáticas serían las periféricas, con baja intermediación y cuya eliminación no rompa la conectividad global de la red.