

SGD - Práctica - Apache Knox en AWS

Uso de AWS Academy

La primera práctica se desarrolla en un entorno de nube AWS a través de la AWS Academy.

Introducción al entorno AWS Academy

Cada curso, el profesorado hace llegar al correo de la UNED de cada alumno un enlace de registro a AWS Academy. En caso de no recibirlo, se puede reclamar en el foro de la asignatura.

El uso de AWS Academy supone costes, por lo que se recomienda ver todos los tutoriales y comprender el sistema de costes antes de empezar a operar con el entorno virtual.

Se accede a la AWS Academy introduciendo las credenciales en la pantalla de acceso de AWS Academy.

La interfaz que se muestra en los vídeos varía respecto a la que se encuentra en la actualidad.

Las instrucciones sobre el uso de la AWS Academy se encuentran en formato vídeo en este enlace: <https://agora.uned.es/mod/lesson/view.php?id=715704>

- Uso de la consola AWS desde AWS Academy
- Instancias Linux en EC2 con AWS Academy
- Acceso SFTP a una instancia EC2
- Acceso a una instancia EC2 usando el cliente SSH Putty

Una vez dentro de AWS Academy, se abre la consola yendo a la pestaña “Contenidos” > “Lanzamiento del Laboratorio para el alumnado de AWS Academy”. Cargará un terminal incrustado en la web.

En el panel de la derecha, en la pestaña “AWS Details” se pueden leer las instrucciones de uso y los servicios ofrecidos.

Pulsar “Start Lab” arriba a la derecha para cargar el laboratorio. Puede llevar unos minutos.

Las **credenciales** se encuentran en el panel de la derecha, en la pestaña “AWS Details”, bajo el apartado “AWS CLI”. Estos datos serán necesarios para algunos de los pasos.

Las **claves privadas para SSH** se encuentran en el panel de la derecha, en el campo “SSH Key”. Es descargable en formato PEM y PPK.

El consumo de importe y duración figura en la parte de arriba.

Un comando que se puede probar en la consola es:

```
aws ec2 describe
```

Una vez que se arranca la consola, se pulsa sobre el text “AWS” con un indicador verde, sobre la consola de administración de AWS.

Cuando se finalice el uso del laboratorio, se debe pulsar el botón “End Lab” junto a la consola, pues de manera contraria se quedará consumiendo recursos.

Gestión de instancias EC2

En la consola de administración, se introduce el texto “EC2” para cargar las instancias dadas de alta.

Para crear una nueva instancia pulsar sobre el botón “Lanzar instancias” a la derecha.

Como paso inicial se debe escoger el sistema operativo de la instancia a crear. Las plantillas de Ubuntu suelen tener un nombre tipo Cloud9Ubuntu.

Se debe escoger un tipo de instancia. A continuación se ejecutará un asistente en varios pasos.

Se recomienda usar la última generación de cada máquina.

Se recomienda 20 GB para cada instancia de las prácticas.

Se recomienda poner una etiqueta tipo “Propietario” con valor tu nombre, para identificar para quién es el usuario.

Si se pone el entorno 0.0.0.0 se indica que está abierto a todo el mundo.

Como último paso se seleccionan las claves a creadas.

Se vuelve a la pantalla de instancias, donde aparecerá la nueva instancia creada.

En el panel de instancias hay un desplegable llamaod “Estado de la instancia” donde están las opciones “Detener instancia” y “Terminar instancia”.

Acceso SFTP a una instancia EC2

En esta sección se explica cómo conectarse a una instancia EC2 mediante SFTP

Para realizar esta tarea es necesario tener instalado en local un cliente SFTP, como por ejemplo FileZilla.

Al gestionar una conexión en el cliente SFTP se deben introducir los siguientes datos:

- URL: la indicada en la instancia en Public DNS (IPv4)
- IP: UO d eka ubstabcu, Debe actualizarse cada vez que se reanude una instancia.
- Puerto: se rellena automáticamente
- Modo de acceso: archivo de claves
- Usuario: **ubuntu** (por defecto en máquina virtual)

- Archivo de claves: introducir el fichero generado.

Al conectarnos, se debe aceptar la licencia.

Una vez configurado, se transfieren archivos de la misma manera.

Acceso con SSH a una instancia EC2

En esta sección se explica cómo conectarse a una instancia SSH, que permite operar con la instancia a través

Para realizar esta tarea es necesario tener instalado en local un cliente

- Linux
 - Comando `ssh` en la terminal.
- Windows
 - Comando `ssh` de PowerShell, disponible en el paquete OpenSSH.
 - Aplicación PuTTY.
 - Aplicación MobaXTerm

Cuando en una instancia le damos al botón “Conectar” se muestra un comando `ssh`.

El cliente SSH se debe configurar:

- IP: IP de la instancia. Debe actualizarse cada vez que se reanude una instancia.
- Puerto: puerto de la instancia.
- SSH > Clave privada: subir fichero PPK
- Usuario: ubuntu

En algunos casos, aparece un aviso de seguridad antes de conectarse.

PuTTY solo trabaja con claves privadas en formato .ppk. La aplicación PuTTY Key Generator convierte una clave privada formato .pem en .ppk.

Creación de un clúster EMR

Bibliografía:

- Creación de un clúster EMR en AWS - Parte 1
- Creación de un clúster EMR en AWS - Parte 2

Un clúster **Amazon Elastic MapReduce (EMR)** es una plataforma de big data gestionada en la nube nativa de AWS. Incluye Hadoop y Apache Spark.

Conviene comprobar los servicios incluidos en la suscripción.

Desde la consola de administración de AWS se debe introducir “EMR”.

Pulsar sobre el botón “Crear clúster”.

Ponerle un nombre tipo emr-custer-napellido.

Seleccionar la última versión del EMR y las aplicaciones por defecto. Para la práctica de la asignatura se recomienda usar Spark ya que se va a trabajar sobre Hadoop, YARN y Zeppelin.

El tipo de instancia viene relleno por defecto, y debe corresponderse con los servicios incluidos. Por ejemplo es `m5.large`.

EMR genera 5 instancias, donde una es el máster.

No está recomendado acceder a las instancias esclavo por separado. Se debe gestionar una instancia esclavo por separado.

Se debe configurar una pareja de claves para instancias EC2. Se debe buscar en la lista de la izquierda “Key pairs”. Como nombre puede tener `emr-cluster-master-node-keypar`.

Si se va a usar PuTTY, se puede descargar directamente en formato `ppk`.

A continuación se detalla cómo **configurar los grupos de seguridad** para que admita conexiones por SSH.

- Ir a la pantalla de seguridad de la instancia EMR.
- Seleccionar el grupo de seguridad del máster (`-master`).
- Darle a (*Edit inbound rules*)
- Añadir la regla para SSH en el puerto TCP 22 y fuente *custom* y el bloque CIDR `0.0.0.0/0` (o el rango que se quiera dar, que debería ser más pequeño).

Tomar el DNS público principal del clúster EMR y el fichero de claves.

Acceder con SSH al nodo máster del clúster EMR, introduciendo el DNS público principal y el fichero de claves.

Al conectarse por SSH, es posible que se pida actualizar el nodo máster.

Se puede ejecutar una de las aplicaciones de ejemplo de PiPy.

```
spark-submit /usr/lib/spark/examples/src/main/python/pi.py
```

Se requiere un bucket de S2 para almacenar la información del backlog. La URL viene bajo la etiqueta `event log directory` del historial del servidor (*History Server*), al que se llega desde el enlace “IU del servidor de historial de Spark”.

En “Pasos”, se añade un paso:

- Tipo de paso: Aplicación de Spark
- Nombre: Nombre descriptivo del paso

- Modo de implementación: Clúster
- Opciones de `spark-submit`: la URL de antes

Tarda como medio minuto en ejecutarse.

Se pueden crear bloc de notas interactivos en la sección de “Bloc de notas” del EMR.

Recordar parar las instancias asociadas al cláster. Para ello, hay que ir a instancias y parar el máster. Seleccionar los nodos esclavos y seleccionar “Instance State” > “Stop”.

Una vez parados los esclavos, se debe parar el nodo *master*.

Instalación de Apache Knox en nodo maestro clúster EMR

Bibliografía:

- <https://knox.apache.org/books/knox-2-1-0/user-guide.html#Quick+Start>

Configuración de Apache Knox

Verificación del funcionamiento de Knox

Licencia y atribución

License CC BY 4.0

Este trabajo está licenciado bajo la licencia **Creative Commons Atribución 4.0 Internacional**.

© 2026, Colaboradores de apuntes-muicd-uned.